基于 Hadoop 的电商离线数据挖掘系统设计

高　健[1]　杨　慧[2]

（1. 西安交通工程学院，陕西 西安　710300；2. 陕西师范大学校医院，陕西 西安　710062）

摘　要：随着数据爆炸式增长，大数据技术得到广泛应用。Hadoop 平台大数据处理技术得到长足发展，Hadoop 为不同场景功能需求提供丰富的工具，电商行业积累的数据不断增多，如何处理好存储订单与仓库数据成为电商行业的重要问题。文章介绍了 Hadoop 平台与数据挖掘相关技术，提出电商离线数据挖掘处理系统方案。设计数据处理平台系统架构，完成电商公司订单数据的数据仓库（Extract Transform Load，ETL）和入库。

关键词：Hadoop；电商；离线数据挖掘系统

中图分类号：TP311.4　　**文献标识码：**A　　**文章编号：**1003-9767（2023）15-135-03

Design of an Offline Data Mining System for E-Commerce Based on Hadoop

GAO Jian[1], YANG Hui[2]

(1. Xi´an Traffic Engineering Institute, Xi´an Shaanxi 710300, China;
2. Hospital of Shaanxi Normal University, Xi´an Shaanxi 710062, China)

Abstract: With the explosive growth of data, big data technology has been widely applied. The Hadoop platform´s big data processing technology has made significant progress. Hadoop provides rich tools for different scenario functional requirements, and the e-commerce industry has accumulated more data. How to handle platform storage order and warehouse data has become an important issue in the e-commerce industry, and using big data driving force to make it a consensus new growth point. Research and introduce Hadoop platform and data mining related technologies, and propose an e-commerce offline processing system solution. Design a data processing platform system architecture to complete the ETL and warehousing of order data for e-commerce companies.

Keywords: Hadoop; online retailers; offline data mining system

0　引言

随着互联网的迅速发展，信息化改变人们的行为模式，网络中的数据源源不断产生，如何获取互联网海量数据中有价值的信息成为重要的研究课题。随着信息化的发展，数据体量急速增加，如何有效利用现有数据成为当下企业的核心重点。Hadoop 分布式计算平台具有高可靠性与高效性。以淘宝等为代表的购物网站迅速发展，电商创造新的经济增长点。电商的不断发展，产生了海量交易记录，云计算以其强大的计算能力为数据挖掘提供可行的解决方案。

1　Hadoop 平台数据挖掘技术

Hadoop 是可处理海量数据的开源框架，Google 最早提出大数据框架用于搜索领域，Doug Cutting 开发开源的 Map Reduce 框架的 Hadoop，Hadoop 平台成为大数据处理平台的主流 [1]。互联网公司开始大量使用 Hadoop 平台，国内企业巨头百度在线网络技术 (北京) 有限公司、阿里巴巴集团控股有限公司、深圳市腾讯计算机系统有限公司等部署 Hadoop 大数据应用平台，很多公司基于 Hadoop 平台定制应用开源。Hadoop 生态圈内工具可以按照功能分类，高级数据处理工具包括 Pig、Hive

收稿日期：2023-06-12

作者简介：高健（1983—），男，辽宁本溪人，硕士研究生，讲师。研究方向：电子商务服务。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

等，工作流管理工具有 Oozie 等。Hadoop 分布式文件系统（Hadoop Distributed File System，HDFS）是大规模分布式处理设计文件系统，将大数据集存储为单个文件，数据存储元数据存储在 namenode 节点。Hadoop 组成如图 1 所示。

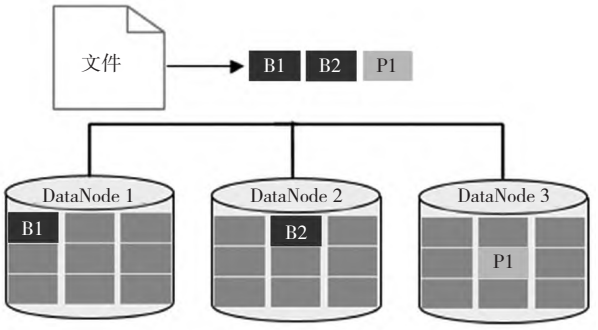

图 1　Hadoop 组成

数据挖掘是人工智能研究的热点问题，也是利用系列相关算法技术从大数据中提取行业所需知识的过程[2]。数据挖掘时要根据实际需求获取不同结构类型的数据源，原始数据集中要清理删除一些重复错误的数据，数据集的算法处理涉及数据可视化、数理统计等多个技术领域。数据挖掘的主要任务分为描述和预测，数据挖掘功能包括特征化区分、关联分析与分类等。数据挖掘是从大量数据集合中探索数据间的特殊关系发现规律输出值的迭代过程，执行过程包括陈述问题阐明假设、数据收集与预处理解析模型等。数据挖掘是复杂的过程，其体系结构包括数据挖掘引擎与用户界面。数据挖掘融入许多学科领域知识技术，以不同挖掘目的为分类包括聚类分析法、关联规则法与偏差分析等。

2　Hadoop 电商离线数据挖掘系统设计

互联网技术的迭代更新，使得依托于互联网技术的电商迅速发展。随着网络技术的不断普及，电商市场日益繁荣，如何有效管理现有数据成为研究的重点[3]。电商可以应用于各行业，电商企业要想创造更大效益需要开发潜在客户。随着电商的迅速发展，需要不断完善大数据工具为电商企业大量挖掘数据提供技术支持。

电商公司的核心是仓储与物流方面，其内部有不同的系统负责不同的数据管理，通过不同部门的分析明确功能需求[4]。销售部门的主要参考数据有订单和库存，通过与销售部门互动总结功能需求。电商数据挖掘系统集中各部门的数据，为不同部门提供需要的数据报表，离线数据挖掘系统性能要求对不同部门进行平台开发，为用户提供统一的操作界面，保证数据的完整性及可靠性。电商离线数据挖掘系统业务流程涉及数据导入存储与展现等过程。由于平台数据量随着业务不断快速发展出现爆炸式增长，目前 Hadoop 平台成为数据挖掘的主流平台。从计算框架等方面考虑进行大数据平台选型，Hadoop 的生态圈中工具丰富，有利于满足小型公司对大数据的需求。Hadoop 生态圈中的 Hive 用于数据仓库（Extract Transform Load，ETL）与视图，Oozie 用于 Hadoop 平台任务流的管理与调度。分布式存储和并行计算集群如图 2 所示。

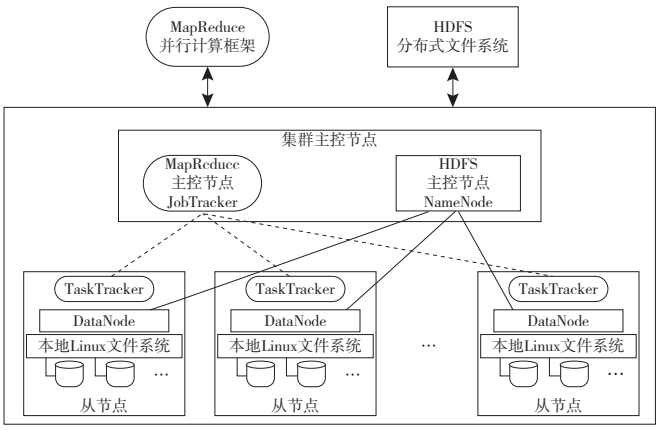

图 2　分布式存储和并行计算集群

Hadoop 是基于存储 HDFS 和计算框架 MapReduce 的平台，从 Hadoop 生态圈中选择不同工具满足企业需求，选择 Sqoop、Hive 等作为平台业务工具[5]。电商数据挖掘系统架构模型中展现数据流处理计算的过程，各层次间以数据流动方向为衔接。

随着数据量的增多，原来解决方案无法满足当前需求，因此提出电商数据挖掘系统架构，提出满足电商数据挖掘系统的功能点，主要实现功能包括导入数据的存储、数据平台任务流管理、多数据源异构数据源的导入等。电商离线数据挖掘系统功能模块包括数据源、数据分析与展现等。Hadoop 集群可以支持多节点，通过增加节点数据满足需求。

3　Hadoop 电商数据挖掘系统实现测试

随着电商迅速崛起，正确利用海量数据为电商企业提供决策支持是向数据驱动转型的重要手段，多源异构大数据多维分析给传统数据仓库带来巨大挑战，关系型数据库无法处理网站埋点信息非结构化数据，需要借助主流的大数据相关技术对海量异构数据进行多维分析处理[6]。根据不同目的将挖掘算法与云计算平台相结合挖掘海量数据中的潜在信息，并将数据挖掘算法移植到 Hadoop 平台实现并行化处理，实现对大数据的挖掘分析。

研究基于 Hadoop 集群数据挖掘平台实现，MapReduce 计算框架提供多种方式供开发者对 HDFS

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

中存储的数据进行操作，目前主要数据操作方法包括 HiveQL、原生态的 MadReduce 等[7]。根据需要选择数据操作方法进行 Hadoop 平台数据操作，Streaming 采用 Python 语言提高开发效率。电商离线数据挖掘系统功能模块包括数据转换存储、数据 ETL 模块等。目前，各部门数据存储在关系型数据库 MySQL 中，需要将各部门数据转存到 HDFS 文件系统中，且数据以文档存储，通过特殊分隔符进行个字段分割。系统框图如图 3 所示。

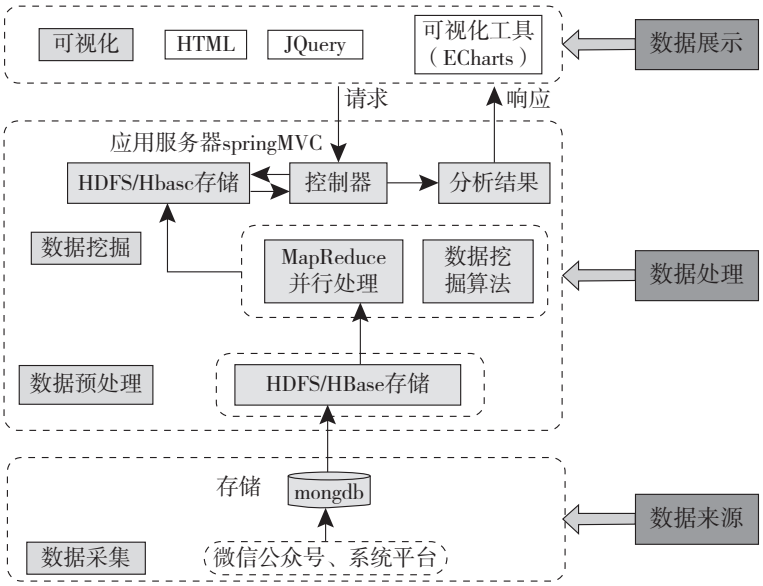

图 3　系统框图

在测试环境上进行数据转存等功能测试，数据 ETL 基于 MapReduce 框架实现数据 ETL 过程，电商离线数据挖掘系统采用 MapReduce 测试平台 ETL 过程的可靠性。数据转存测试电商离线数据挖掘系统数据转存功能，分析数据转入分布式存储文件系统的可靠性。Hadoop 平台经过数据转存后可以通过平台挖掘订单数据，测试日均销量统计与热销库存进出计量单位（Stock Keeping Unit，SKU）的二元组合数据挖掘测试，通过实验发现商品近期销售情况。数据转存功能通过 Sqoop 将 MySQL 存储数据批量转存到 HDFS。

4　结语

随着电商企业的快速发展，如何利用企业海量数据为运营提供决策支持是电商公司转向数据驱动服务的前提。文章首先基于 Hadoop 框架设计开发电商离线数据挖掘系统，其次通过 HDFS 存储采集海量历史数据，实现对海量异构多元数据实时采集处理，再次通过 Hive 设计搭建数据仓库，基于电商企业业务需求对海量历史数据进行离线分析，最后基于 MAP File 实现小文件存储优化方案。

参考文献

[1] 张煜杨 . 电商大数据处理平台的设计与实现 [D]. 上海 : 华东师范大学 ,2023:13.

[2] 杨要行 . 基于数据仓库的数据挖掘在电商 ERP 的应用研究 [D]. 北京 : 北京交通大学 ,2022:14.

[3] 高学伟 . 数字孪生建模方法及其在热力系统优化运行中的应用研究 [D]. 北京 : 华北电力大学 ,2021:15.

[4] 楚江涛 . 基于 Hadoop 的电商大数据分析系统的设计与实现 [D]. 西宁 : 青海师范大学 ,2021:28.

[5] 李存正 . 基于 ELK 与 Spark 的可扩展征信日志挖掘系统研究与实现 [D]. 淮南 : 安徽理工大学 ,2020:17.

[6] 黎燕 . 基于 Hadoop 的电商数据挖掘技术的研究与应用 [D]. 西安 : 西安科技大学 ,2018:24.

[7] 曹佳豪 . 基于 Hadoop 的报文数据挖掘研究与应用 [D]. 武汉 : 武汉邮电科学研究院 ,2018:20.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net