文章编号: 1007-1423(2024)03-0112-05 DOI: 10.3969/j.issn.1007-1423.2024.03.018

基于Hadoop的离线电商数据分析系统的设计与实现

潘杰恒，蔡群英*

（韩山师范学院计算机与信息工程学院，潮州 521041）

摘要：随着互联网的普及和人们不断增长的消费需求，电子商务平台已成为人们生活不可或缺的一部分，由此产生大量数据。基于Hadoop，设计并实现一个离线电商数据分析系统，从系统架构、数据采集、传输、存储、分析处理和可视化等方面作了介绍，系统具有一定的数据分析能力，能将原本无用的数据进行整理利用，发挥数据本身的价值。

关键词：电商；离线；分析系统；大数据；Hadoop；Hive；Flume；Kafka

0 引言

随着科技的发展和互联网的广泛应用，人们热衷于网上购物，各大电商平台每日要处理的数据量非常庞大。假设一个企业平台每日活跃用户100万，每人每天平均产生100条日志记录，那么每日处理的数据量就约等于100 G。这样的大数据量的计算、分析、存储、传输，需要借助大数据技术来完成。大数据技术的目的是通过数据分析、处理和挖掘，提取出重要的、潜在的信息和知识，并将其转化为有用的模型，应用到科研、生产、运营和销售过程中，以解决实际问题[1]。

在没有大数据这个概念时，电商平台的用户行为数据没被充分地利用，而如今大数据应用越来越广泛，用户的行为记录也是企业做决策的重要依据。为捕捉并有效利用用户产生的行为数据，需要使用一系列基于大数据的工具来帮助完成。Hadoop平台是一个分布式的并行计算平台，其两个核心组件是HDFS和MapReduce[2-3]，解决了大数据分布式存储和分布式计算的问题，并由此扩展形成了功能相对完善的生态圈，包括Hive、Flume、ZooKeeper、Kafka等组件。

1 系统设计

1.1 系统架构

离线电商数据分析系统包括数据采集、数据仓库、数据可视化三个部分，系统架构如图1所示。

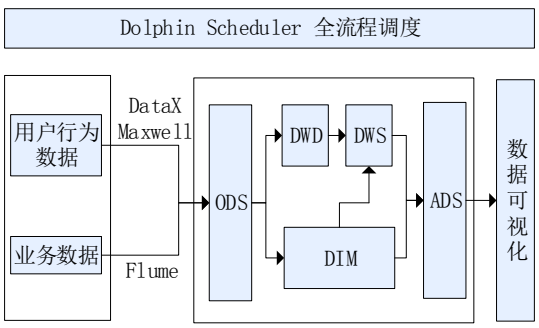

图 1 系统架构图

1.2 集群资源规划

使用CentOS作为服务器系统，基于Hadoop平台，用Flume等进行数据采集传输，Kafka作为消息缓冲队列，MySQL存储业务数据，Maxwell和DataX作为数据同步工具，ZooKeeper作为Kafka的分布式协调，HDFS作为数据存储工具，Hive作为数据仓库，Superset进行数据可视化，

收稿日期：2023-07-29 **修稿日期：**2023-10-20

作者简介：潘杰恒(2000—)，男，广东佛山人，在读本科生，主要研究方向为大数据、电商数据处理；*通信作者：蔡群英(1975—)，女，广东潮州人，高级实验师，主要研究方向为Web应用、人工智能，E-mail：hscaiqy@hstc.edu.cn

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

DolphinScheduler进行定时调度。本文使用测试集群，资源规划见表1。

1.3　系统处理流程

电商平台的数据包括业务数据和用户数据。业务数据指的是用户在电商网站中登录、下单、支付等过程中，和网站后台数据库进行增删改查交互所产生的数据，业务数据通常存储在MySQL、Oracle等数据库中。用户数据指的是电商网站通过设置埋点在收集用户访问网站的过程中所产生的数据，比如页面浏览、点击、停留、评论、点赞、收藏等，这些数据通常以日志文件的形式存储在服务器中。

离线电商数据分析系统通过数据采集平台将数据采集、传输到数据仓库，数据仓库对数据进行清洗整合，最后将整合好的数据进行可视化，数据处理流程如图2所示[4]。

表1　集群资源规划表

服务名称	子服务	服务器hadoop102	服务器hadoop103	服务器hadoop104
HDFS	NameNode	√		
	DataNode	√	√	√
	SecondaryNameNode			√
Yarn	NodeManager	√	√	√
	ResourceManager		√	
ZooKeeper	ZooKeeper Server	√	√	√
Flume(采集日志)	Flume	√	√	
Kafka	Kafka	√	√	√
Flume(消费Kafka日志)	Flume			√
Flume(消费Kafka业务)	Flume			√
Hive		√	√	√
MySQL	MySQL	√		
DataX		√	√	√
Spark		√	√	√
DolphinScheduler	ApiApplicationServer	√		
	AlertServer	√		
	MasterServer	√		
	WorkerServer	√	√	√
	LoggerServer	√	√	√
Superset	Superset	√		

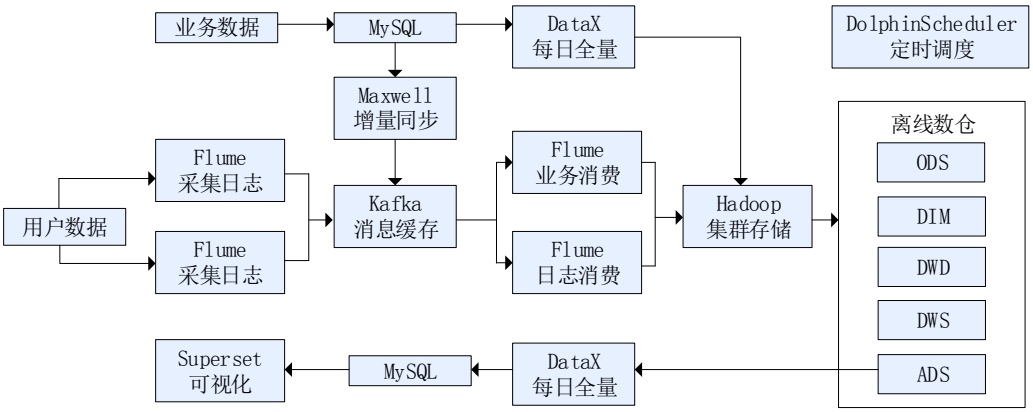

图2　数据处理流程图

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

1.3.1　用户行为数据处理流程

需要采集的用户行为日志文件分布在Hadoop102、Hadoop103服务器上，需要在这两台服务器上配置Flume采集日志，为防止数据激增，使用Flume将日志文件的数据采集到Kafka中，再继续使用Flume采集Kafka的数据，将数据发送到Hadoop的HDFS中，数据通道如图3所示。

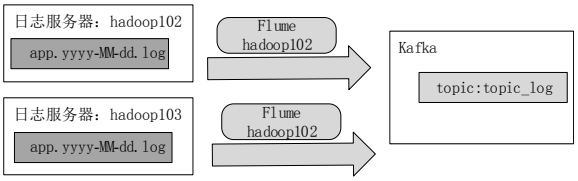

图3　用户行为数据通道图

用户行为数据由Flume从Kafka直接同步到HDFS，后续搭建数据仓库时再将数据转换到相应的目录上，数据流如图4所示。

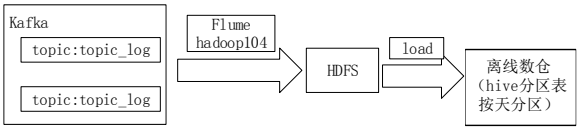

图4　用户行为数据同步数据流图

1.3.2　业务数据处理流程

业务数据处理分为两种：每日全量同步和增量同步。

每日全量同步的业务数据处理流程如图5所示，数据通过DataX从MySQL同步到HDFS，这适用于不常发生变化的业务表。

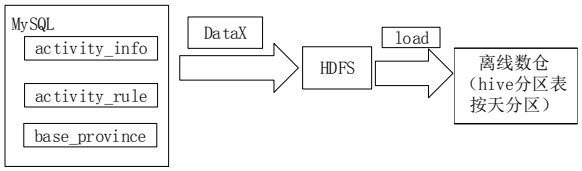

图5　全量表同步数据流程图

增量同步的业务数据处理流程如图6所示，对于那些不适合每日全量同步的数据采用Maxwell，以增量同步的形式，把新增的数据同步到Kafka中，最后再继续用Flume，把数据采集到Hadoop集群中。

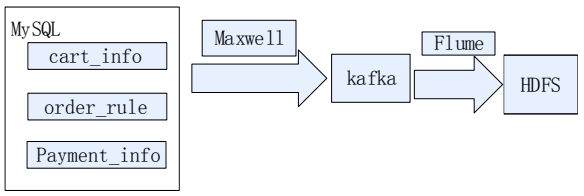

图6　增量表数据同步数据通道图

1.3.3　数据仓库建模

数据仓库依次分为ODS层（原始数据层）、DIM层（公共维度）、DWD层（明细数据层）、DWS层（汇总数据层）、ADS层（数据应用层）。首先将Flume和DataX的数据原封不动地放在ODS层中，用于备份。DIM层存储维度表，DWD层用于数据清洗，DWS层用于预先聚合，ADS层用于指标统计[5]。

1.3.4　数据可视化

数据从Hadoop经过ODS层、DWD层、DWS层后已经满足指标统计的条件，将需要统计的指标存储在ADS层中，后续可直接使用DataX把ADS层的数据同步到MySQL上，最后使用SuperSet进行可视化。

2　离线数据分析

离线电商数据分析系统可以完成各类指标的统计[6]，如访客数、会话平均停留时长、会话平均浏览页面数、会话总数、路径分析、各分类商品购物车存量Top10、交易订单总额、交易订单数、交易订单人数、交易退单数等等，表2列出了部分指标的统计周期、统计粒度和有关说明。

表2　统计指标表

统计周期	统计粒度	指标	说明
最近1/7/30日	渠道	访客数	统计访问人数
最近1/7/30日	渠道	会话平均停留时长	统计每个会话平均停留时长
最近1/7/30日	渠道	会话平均浏览页面数	统计每个会话平均浏览页面数
最近1/7/30日	渠道	会话总数	统计会话总数
最近1/7/30日	渠道	跳出率	只有一个页面的会话的比例

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

经过前面的数据采集、数据仓库建模，到了统计阶段，以各渠道流量统计为例，编写Hive建表语句，如下，这时会基于DWS层的预聚合表构建ADS层。

```
DROP TABLE IF EXISTS ads_traffic_stats_by_
  channel;
CREATE EXTERNAL TABLE ads_traffic_stats_
  by_channel
(
  'dt' STRING COMMENT '统计日期',
  'recent_days' BIGINT COMMENT '最近天数,
    1:最近1天,7:最近7天,30:最近30天',
  'channel' STRING COMMENT '渠道',
  'uv_count' BIGINT COMMENT '访客人数',
  'avg_duration_sec' BIGINT COMMENT
    '会话平均停留时长,单位为秒',
  'avg_page_count' BIGINT COMMENT
    '会话平均浏览页面数',
  'sv_count' BIGINT COMMENT '会话数',
  'bounce_rate'DECIMAL(16,2) COMMENT
    '跳出率'
) COMMENT '各渠道流量统计'
ROW FORMAT DELIMITED FIELDS TERMINATED
  BY '\t'
LOCATION '/warehouse/gmall/ads/ads_traffic_
  stats_by_channel/'
```

经过以上处理后ADS层已经得到了处理好的统计指标，以各渠道流量统计为例(ads_traffic_stats_by_channel)，如图7所示。

dt	recent_days	channel	uv_count
2020-06-17	1	web	32
2020-06-20	7	huawei	103
2020-06-15	7	xiaomi	181
2020-06-23	1	web	27
2020-06-20	30	360	119
2020-06-25	1	vivo	12
2020-06-23	30	web	335
2020-06-17	7	Appstore	580
2020-06-18	7	Appstore	705
2020-06-14	30	xiaomi	94
2020-06-16	7	wandoujia	90
2020-06-18	7	oppo	286

图7　ads_traffic_stats_by_channel表图

3　数据的可视化

接下来，用上面这些统计指标来进行数据可视化，可视化采用的是Superset，由Python语言编写的Web应用，对接的数据源为MySQL数据库。

以下是近7天的渠道流量统计图，如图8所示。

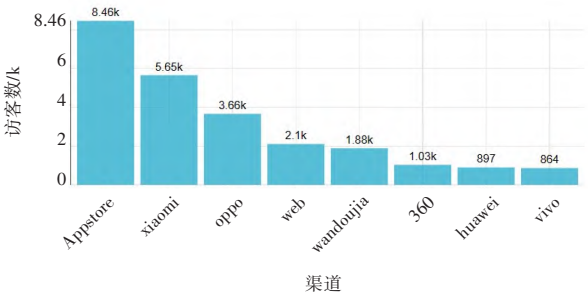

图8　近7天的渠道流量统计图

以下是近7天用户路径分析图，如图9所示。

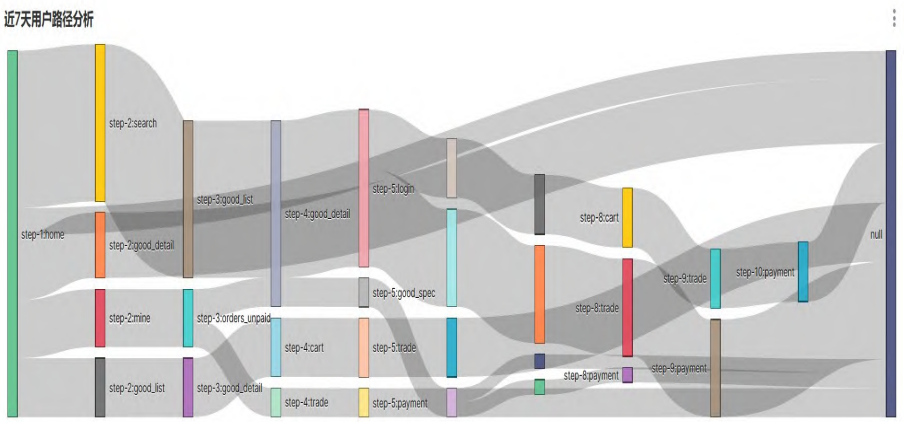

图9　近7天用户路径分析图

注：灰色底图表示用户行为路径，home表示浏览主页面，search表示搜索，good_detail表示浏览商品详情页，mine表示浏览“我的”页面，good_list表示浏览商品列表页，cart表示浏览购物车页面，trade表示浏览下单页面，login表示登录，good_spec表示浏览商品收藏页面，payment表示支付。

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

4 结语

本文就电商平台大数据的问题进行研究，基于Hadoop设计开发了一个能采集、传输、清洗、整合、可视化的离线电商数据分析系统，致力于解决数据的利用问题，做到了将杂乱的数据进行高效地整理，使本身不具有利用价值的数据产生经济效益。

参考文献：

[1] 候春俊. 基于大数据视角的电子商务产业发展研究[J]. 价值工程，2020(11)：231-232.

[2] GHEMAWAT S, GOBIOFF H, LEUNG S-T. The Google file system[J]. ACM SIGOPS Operating Systems Review，2003，37(5)：29-43.

[3] DEAN J, GHEMAWAT S. MapReduce: simplified data processing on large clusters[J]. Communications of the Association for Computing Machinery，2008，51(1)：107-113.

[4] 农佳明. 基于Hadoop的电商数据分析系统设计与实现[J]. 电子技术，2023，52(3)：67-69.

[5] 楚江涛. 基于Hadoop的电商大数据分析系统的设计与实现[D]. 西宁：青海师范大学，2021.

[6] 贾翼. 基于Hive的电商多维分析系统的设计与实现[D]. 杭州：浙江工业大学，2020.

Design and implementation of offline e-commerce data analysis system based on Hadoop

Pan Jieheng, Cai Qunying*

(College of Computer and Information Engineering, Hanshan Normal University, Chaozhou 521041, China)

Abstract: With the popularization of the Internet and the growing consumer demand of the people, e-commerce platforms have become an indispensable part of people, generating a large amount of data. Based on Hadoop, design and implement an offline e-commerce data analysis system. This article introduces the system architecture, data collection, transmission, storage, analysis and processing, and visualization. The system has certain data analysis capabilities and can organize and utilize previously useless data, leveraging the value of the data itself.

Keywords: e-commerce; offline; analysis system; big data; Hadoop; Hive; Flume; Kafka

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net