北京交通大學

硕 士 专 业 学 位 论 文

基于 Spark 框架的新闻日志分析系统的设计与实现

Design and Implementation of News Log Analysis System Based on Spark

作者：高志远

导师：包尔固德

北京交通大学

2022 年 12 月

中国知网 https://www.cnki.net

学校代码：10004　　密级：公开

北京交通大学

硕士专业学位论文

基于 Spark 框架的新闻日志分析系统的设计与实现

Design and Implementation of News Log Analysis System Based on Spark

作者姓名：高志远　　学　　号：20140533

导师姓名：包尔固德　　职　　称：副教授

专业领域：软件工程　　学位级别：硕士

北京交通大学

2022 年 12 月

中国知网 https://www.cnki.net

摘要

目前市场上存在多种新闻客户端，移动端的新闻应用更是成为咨询传播的主战场，用户获取新闻的主要途径，这就引发了惨烈的市场竞争，各家新媒体公司在不断优化自身移动媒体服务的同时，还开始考虑为用户推荐更优秀的内容，服务的优化就需要对新闻日志数据进行挖掘分析。我们能够发现，新闻客户端的高质量开发离不开海量、多维的日志数据挖掘和分析，因此深入分析用户的查询日志是一项非常有意义的工作，整理出一套有效可行的算法，帮助企业在新闻市场取得竞争力。

考虑到上述问题和需求，本文以新闻日志为例，设计并开发了一个基于 Spark 存储计数系统的新闻日志数据采集平台。平台主要分为四层：分别是数据源层、数据存储层、数据挖掘层和数据可视化层；它包括五个主要功能模块：日志数据管理模块、用户管理模块、日志分析模块、日志数据挖掘模块和可视化模块。全文介绍了平台的整体架构设计，集群的整体规划部署、对于各个功能模块具体的设计方案以及对于各个功能模块的实现过程，以及 Hadoop 和 Spark 环境中流行的组件用于数据分析和处理，并且利用 Spark 框架进行数据分析计算任务；使用 Spark Streaming 流计算框架处理即时数据信息等。离线的数据信息挖掘主要是采用的是 MLlib 机器学习库中的协同过滤算法、Kmeans 聚类算法、朴素贝叶斯算法，对用户查询的新闻日志数据进行深维度的挖掘处理。系统可视化模块主要是使用百度开源的可视化图表 Echarts 结合 Java Web 开发，把日志数据分析模块与日志数据挖掘模块的处理结果可视化显示，方便数据分析工作人员更加清晰、更加便捷的了解用户搜索行为。

本文设计了一个基于 Spark 分布式内存计算框架的日志数据分析处理平台，有效解决了日志统计分析和数据挖掘过程中的问题，提高了工作效率；新闻日志的多维分析，帮助相关业务人员及时了解新闻客户端网络流量状态，高效的统计用户的行为信息。构造了推荐效果较好的基于时间权重和用户兴趣变化的协同过滤预测模型，完成了对新闻日志的相似性计算和推荐，能够更真实挖掘用户的活动意愿，从而提高公司的核心竞争力，平台通过测试已成功上线运行。

关键词：新闻日志; 离线分析; 实时分析; 协同过滤

中国知网 https://www.cnki.net

ABSTRACT

Currently there are a variety of news clients on the market, and mobile news applications are becoming the main battleground for advice dissemination and the main way for users to get news, which has led to fierce market competition. While each new media company is constantly optimising its own mobile media services, it is also starting to consider recommending better content for users, and the optimisation of services requires the mining and analysis of news log data. We were able to find that the high quality development of news clients cannot be achieved without the mining and analysis of massive, multi-dimensional log data. Therefore, it is a very meaningful task to deeply analyse the query logs of users and collate a set of effective and feasible algorithms to help companies achieve competitiveness in the news market.

Considering the above problems and needs, this paper designs and develops a news log data collection platform based on Spark storage counting system, taking news logs as an example. The platform is divided into four main layers: data source layer, data storage layer, data mining layer and data visualisation layer respectively; it includes five main functional modules: log data management module, user management module, log analysis module, log data mining module and visualisation module. The whole paper introduces the overall architecture design of the platform, the overall planning and deployment of the cluster, the specific design scheme for each functional module and the implementation process for each functional module, as well as the popular components in Hadoop and Spark environment for data analysis and processing, and the use of Spark framework for data analysis and calculation tasks; the use of Spark Streaming stream computing framework for processing instant data information, etc. Offline data information mining is mainly used is the MLlib machine learning library of collaborative filtering algorithm, Kmeans clustering algorithm, plain Bayesian algorithm, the user query of the news log data for deep dimensional mining processing. The system visualisation module mainly uses Baidu's open source visualisation chart Echarts combined with Java Web development to visualise the processing results of the log data analysis module and the log data mining module, facilitating data analysis staff to understand user search behaviour in a clearer and more convenient way.

This paper designs a log data analysis and processing platform based on Spark distributed memory computing framework, which effectively solves the problems in the process of log statistical analysis and data mining and improves work efficiency;

中国知网 https://www.cnki.net

multi-dimensional analysis of news logs helps relevant business personnel understand the state of news client network traffic in a timely manner and efficiently count the behavioral information of users. A collaborative filtering prediction model based on time weights and changes in user interests with better recommendation effects was constructed, and the similarity calculation and recommendation of news logs was completed, enabling more realistic mining of users' activity intentions and thus improving the company's core competitiveness, The platform has been successfully put online through testing.

KEYWORDS: News log, offline analysis, real-time analysis, data mining

中国知网 https://www.cnki.net

目　录

1 引言.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....2
1.3 论文内容.....3
1.4 论文结构安排.....4
2 系统相关技术简介.....7
2.1 HADOOP 框架.....7
2.1.1 分布式文件系统 HDFS.....8
2.1.2 分布式计算架构 Map Reduce.....9
2.1.3 数据仓库 Hive.....9
2.2 SPARK 框架.....11
2.2.1 Spark Streaming 流处理.....12
2.2.2 Spark 数据分析.....12
2.3 数据挖掘算法.....13
2.3.1 朴素贝叶斯.....13
2.3.2 Kmeans 聚类.....13
2.3.3 协同过滤算法.....14
2.4 JAVA WEB 技术.....14
2.4.1 Spring boot.....14
2.4.2 ECharts.....15
2.5 本章小结.....15
3 新闻日志系统需求分析.....17
3.1 系统功能性需求分析.....17
3.1.1 用户管理模块.....18
3.1.2 日志管理模块.....18
3.1.3 日志分析模块.....18
3.1.4 离线数据挖掘模块.....19
3.1.5 日志数据展示功能需求.....19
3.2 系统非功能需求分析.....20
3.3 本章小结.....20
4 系统概要设计.....21
4.1 系统整体架构设计.....21
4.2 系统数据流程设计.....22
4.3 系统集群资源规划设计.....23

中国知网 https://www.cnki.net

4.4 系统功能模块设计.....24
4.5 数据库设计.....25
4.5.1 E-R 图设计.....25
4.5.2 基础表设计.....26
4.6 本章小结.....28
5 协同过滤算法设计与实现(TACF).....29
5.1 算法概述.....29
5.2 数据准备.....30
5.3 算法训练.....31
5.4 算法实验结果.....33
5.5 本章小结.....34
6 新闻日志系统详细设计与实现.....35
6.1 用户管理功能实现.....35
6.2 日志管理模块设计.....37
6.2.1 日志采集模块设计.....38
6.2.2 数据预处理模块设计.....41
6.3 日志分析模块.....42
6.3.1 实时分析.....42
6.3.2 离线分析.....45
6.4 数据挖掘模块.....46
6.4.1 日志数据分类具体设计与实现.....46
6.4.2 日志数据聚类具体设计与实现.....48
6.4.3 日志数据协同过滤推荐具体设计与实现.....50
6.5 可视化模块.....51
6.5.1 日志信息展示.....52
6.5.2 热点新闻展示功能实现.....53
6.5.3 实时话题统计展示.....54
6.5.4 实时搜索时段流量展示.....55
6.5.5 话题点击最优 rank 频率展示.....56
6.5.6 搜索关键字词模块展示.....57
6.5.7 离线搜索时段流量展示.....58
6.5.8 实现效果图.....59
6.6 本章小结.....60
7 系统测试.....61
7.1 开发环境.....61
7.2 功能性测试.....62
7.3 非功能性测试.....66
7.3.1 性能测试.....66

中国知网 https://www.cnki.net

7.3.2 可靠性.....67
7.3.3 可扩展性和可维护性.....67
7.4 本章小结.....67
8 总结与展望.....69
8.1 全文总结.....69
8.2 未来展望.....69
参考文献.....71

中国知网 https://www.cnki.net

1 引言

本章首先从中国网络用户获取信息的新形式入手，提出新闻日志分析系统的基本概念，接着介绍了新闻日志分析系统在新媒体产品中所能起到的作用，并研究了目前在国内外日志分析工作发展状况，然后介绍了整篇文章的研究内容以及文章提出的平台的意义，在本章第四部分介绍了论文结构安排。

1.1 研究背景及意义

随着二十世纪五十年代计算机与电子科学技术的蓬勃发展，现如今，网络技术已经较为完善和稳定。网络给人类的日常生活也造成了巨大的改变，创造了电子邮件、万维网络、互联网协议语音电话、视频会议、博客、论坛、社交网络以及电子商务平台等产品。从互联网信息中心(CNNIC)的第 44 次统计报告的发布情况可以看到，截止时间在 2019 年 6 月份，我国的互联网在线注册人数达到了 8.54 亿，增长了 2598 万，另外互联网的普及率持续快速增长，达到 61.2%，就用户规模而言，搜索引擎占的比例规模最大，占整体用户的 81.3%，达到 6.95 亿[1]，我们可以看出互联网冲浪已经与我们的生活息息相关，我们对网络的依赖性也越来越高。另外由于近年来智能手机的迅猛发展，一个全新改变已经来临。人们开始习惯于移动互联网时代所提供的各种便捷，享受着网上阅读、娱乐新闻咨询、商品在线购买等各项业务。

在这个数据飞速增长、信息高速传播的时代，人们生活的各个方面都受到了大数据科技的巨大影响。大数据技术拥有 4 V 技术特点[2]，即海量的数据、快捷的信息处理速率、多形式的数据处理情况、精准的数据分析结果(Volume、Velocity、Varirty、Veracity)，这将是未来大数据分析发展主要方向。由于大数据分析的出现，人们不再像过去一样只知道追寻因果关系，而是更注重于研究事物之间的关联。

在大数据时代，由于新闻网站信息的爆炸式增长，从新闻文章中提取新闻日志数据成为一项有趣的挑战。为此，我们需要数据挖掘技术，它可以从这种非结构化类型的文本数据中提取相关信息。另外，在线新闻是一种特殊类型的公共信息，主要是因为新闻来源很多，新闻更新速度很快。在这段时间里，产生的新闻日志数据，也是有着很庞大的信息量。因此，可以处理，分析和分类网络新闻日志的自动系统不仅对于管理网络新闻文章的系统而且对于用户推荐任务都是必不可少的。新闻日志数据挖掘工具，技术和算法正在兴起。有许多技术可以帮助分析信息溢出并从新闻日志来源提取价值知识。然而，由于这些信息不断增长和变

中国知网 https://www.cnki.net

化，这些技术必须比过去支持更多地浏览和搜索信息。

目前市场上存在多种新闻客户端[3]，移动端的新闻应用更是成为咨询传播的主战场，用户获取新闻的主要途径。这就引发了市场的激烈竞争，各家媒体公司在不断优化自身移动媒体服务的同时，还开始考虑为用户推荐更优秀的内容，服务的优化就需要对新闻日志数据的进行数据挖掘分析。我们能够发现，新闻客户端的高质量发展在海量多维度的日志数据挖掘分析中是承担着重要的角色，因此，深入分析用户的查询日志是一项非常有意义的工作，整理出一套有效可行的方法，帮助企业在新闻市场的取得新闻价值挖掘的竞争力。

1.2 国内外研究现状

二十世纪九十年代，大量搜索日志数据信息被国外的互联网搜索引擎生成[6]，国外的学者研究推测用户行为研究是未来发展的一种趋势。Silverstein 等人对研究 AltaVista 中大量的日志数据，他们认为其中包含着重要的信息，因此选择对搜索引擎的日志进行了分析和处理[7]。研究内容主要包括对每次查询的字数和用户平均查询长度进行统计分析，得出传统查询方法需要改进的结论，最重要的搜索词是固定短语。文献分析了不同类型的网络安全设备生成的报警日志，可以从不同的设备收集日志数据，并具有预警功能[8]。后来，日志数据分析理论不断丰富，研究和分析的重点已经从最初的查询会话转移到客户的行为特征。对于海量日志数据，专家学者开始使用大数据技术处理。常见的日志框架是 Chunkwa[9]，使用 MapReduce 计算海量日志数据的采集分析工作，具有一定的稳定性和高效性。Duan 等人的研究提高搜索词自动纠错的准确性和召回率[10]，而他们的研究方式是通过对查询词纠错过程中的错误案例进行了数据挖掘操作。文献实现了基于 Spark 日志分析与挖掘平台，机器学习算法研究日志的相似性[11]。文献设计了多源大数据日志分析系统，融合业务规则分析，实现了多源日志的综合分析[20]。Huang 等人提出一种基于项目的协同过滤实时流推荐系统,利用人口统计学聚类算法解决数据稀疏性问题[35]。

在本世纪初，在大量国外学者的研究搜索引擎日志开始传入国内后，国内学者开始关注挖掘其信息，并开始对它们进行研究[12]。由于汉字在语法、情感、语义等方面固有的复杂性和多样性，国内学者在深入研究中遇到了巨大挑战，取得了相关研究成果[13]。彭波、王继民等人分析了北京大学天网搜索引擎用户浏览的关键数据，发现用户浏览的不同 URL 量符合堆积统计定律。同时，他们给出了一种使用点击日志定义相应搜索关键词的方法[14]。通过对搜狗搜索日志的数据分析，余惠佳、刘益群等人明确表示，在搜索词的长度、频率的因素和每个会话中的搜

中国知网 https://www.cnki.net

索次数的影响用户在浏览过程中的重要因素[15]。陈志敏等人在计算用户相似过程中引入全新时间函数，进行重点数据分析，为了更好的找到用户的搜索偏好，在数据分析中增加了分词技术得到了很好的结果，进而又增加了中文分词技术，果不其然得到了出乎意料的好的结果[16]。赵文涛等人主要对用户相似度进行改进，提出用户特征属性与时间权重进行加权计算，在新的模型下更好的求出目标用户的偏好[17]。魏慧娟利用 K-Means 聚类算法分别对用户特征和项目属性进行聚类.在对项目属性聚类的基础上利用基于项目的协同过滤算法预测出用户对未评分项目的评分值,然后对评分矩阵中的缺省值进行填充,更新用户的评分矩阵.该算法有效地缓解了评分数据稀疏带来的影响[36]。何明等人利用 K-Means 算法对项目集进行聚类，并基于用户兴趣偏好阵查找待估值项所对应的近邻用户，并在此基础上,通过结合项目相似度的加权 Slope One 算法在每一个项目类镇中对稀疏矩阵进行填充，以缓解数据稀疏性问题[34]。何美惠等人由于数据挖掘技术的兴起，他们注重研发和开发以用户为中心的数据挖掘技术，降低大部分运营商的生产成本，也为运营商提供了业务的准确性的依据[18]。国内互联网企业大量采用分布式框架的系统进行高吞吐量的业务需求计算，在公司业务评估和用户服务制定方面有着不错的表现。综合来看，日志收集分析系统可以对各类数据源、数据类型进行分析处理，已成为互联网业务中不可缺少的一部分。

1.3 论文内容

本文的研究内容通过收集资料设计和研发一个用户日志分析与数据挖掘系统，其目的在于满足新闻客户端需求，对日志进行采集存储并完成相关维度的数据分析工作。运用软件工程的思维从日志数据采集的现实需求入手，运用 Spark 并行计算框架处理日益增长数据的优势[4]，搭建了日志分析平台，研究内容包括以下三个部分：

新闻日志分析系统可行性研究，调研用户行为分析的各种工具，国内外知名开源系统 Hadoop、Spark、Scribe、Kafka、flume、Splunk 等原理研究。分析日志收集框架、中央存储系统等核心业务场景的框架选择，分别能够解决哪些实际问题。接着针对数据挖掘，分析了论文用到的三个算法的特点并分析技术可行性。

新闻日志分析系统的需求分析与总体设计。在需求分析中，本文提出的平台主要分为四层：数据源层、数据存储层、数据挖掘层和数据可视化层；它包括五个主要功能模块：日志数据管理模块、用户管理模块、日志分析模块、日志数据挖掘模块和可视化模块。对于新闻日志分析系统总体设计，本文介绍了平台的总体架构设计、集群的总体规划和部署、每个功能模块详细的设计方案，以及每个

中国知网 https://www.cnki.net

功能模块的实现过程，使用 Hadoop 和 Spark 环境中流行的组件进行数据分析和处理，以及使用 Spark 框架的数据分析与计算任务；使用 Spark Streaming 流计算框架处理实时数据信息等。离线的数据信息挖掘主要是采用的是 MLlib 机器学习库中的协同过滤算法、Kmeans 聚类算法、朴素贝叶斯算法，对用户查询的新闻日志数据进行深维度的挖掘处理。系统可视化模块主要是使用百度开源的可视化图表 Echarts 结合 Java Web 开发，把日志数据分析模块与日志数据挖掘模块的处理结果可视化显示，方便数据分析工作人员更加清晰、更加便捷的了解用户搜索行为。

本文设计了基于 Spark 分布式内存计算框架的日志数据分析与处理平台，有效解决了日志统计分析和数据挖掘过程中的问题，提高了工作效率；新闻日志的多维分析有助于相关业务人员及时了解网络流量状况，更有效地统计用户行为信息。构造了推荐效果较好的基于时间权重和用户兴趣变化的协同过滤预测模型，完成了对新闻日志的相似性计算和推荐，能够更真实的挖掘用户的活动意愿，从而提高公司的核心竞争力。

1.4 论文结构安排

第一章：绪论。本章主要介绍项目背景及重要意义，然后介绍了国外研究的状况以及国内研究进展，最后的主要研究内容是用户行为分析系统的相关介绍。

第二章：相关技术介绍。本章介绍了大数据系统的可行技术选择。首先介绍了数据仓库 Hive、分布式存储数据库 HBASE、分布式文件系统 Hadoop、分布式计算架构 Spark 等大数据技术，然后对于在数据挖掘领域运用的专业知识，计算工具等进行了详细的介绍，为系统的总体设计和详细实现提供了理论依据。

第三章：系统的需求分析。本章节主要结合具体的新闻业务对系统进行需求分析，功能性需求包括用户管理功能需求分析、日志管理功能需求分析、日志分析功能需求分析、日志挖掘功能、web 可视化功能需求分析。同时通过新闻日志分析系统的具体应用场景，从系统的稳定性、高效性、易用性、精确性等方面考虑，提出对系统的非功能需求，使得系统可以平稳有效的运行。

第四章：概要设计。概要设计是依据需求分析结果对系统进行设计，主要是对系统进行逻辑架构设计、技术架构设计、系统功能模块设计。并根据需求分析进行数据库设计。

第五章：数据挖掘算法设计与实现。本章主要从算法整体概述、数据处理、算法训练等方面进行介绍。并给出相应算法效果对比。

第六章：新闻日志系统功能模块的详细设计与实现。本章主要是对新闻日志分析系统的五个功能设计的实现进行详细的介绍，分别详细的阐述了每个功能模

中国知网 https://www.cnki.net

块具体实现方法。

第七章：系统测试。本章主要对系统进行验证是否满足预先规定，会从功能性测试和非功能性测试两个方面加以检验。

第八章：总结与展望。本章对论文所完成的工作进行分析和总结，并指出本文所研发的日志分析系统存在的缺陷与待完善之处，并针对存在的问题制定进一步研究方向。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

2 系统相关技术简介

对新闻日志分析系统在实际应用中可行性技术在本章将会进行详细的介绍。在数据的处理方面介绍了当前比较主流的大数据框架 Hadoop，并详细介绍了 Hadoop 生态系统中的数据仓储 Hive、分布式文件系统 HDFS、数据库系统 HBASE。然后对 Spark 生态系统进行了重点介绍。在数据挖掘方面介绍了 MLlib 库中的应用算法协同过滤等。最后介绍了可视化相关的技术。

2.1 Hadoop 框架

Hadoop 是 Apache Foundation 开发的一个大型的分布式的大型运算机[5]，它可以进行大量的数据的处理。Hadoop 由于其自身的优点，在很多方面都得到了广泛的运用，尤其是在不同的应用中。Hadoop 采用 Java 技术，可以在 Linux 上运行，其特性如下：

（1） 高可靠性。Hadoop 支持冗余数据存储。底层自动保存数据副本。当一个副本失败时，其他副本将确保数据不会丢失。

（2） 高效率。将大任务划分为小任务是 Hadoop 的工作原理，并将它们分配给多台机器进行同时处理。也正是因为这种分布式计算方法，在处理 Pb 级数据时，得到了意想不到的结果，让其能够有效地处理。

（3）高容错性。在整个作业中，如果让失败的节点继续运行，这个时候 Hadoop 的作用发挥出来，Hadoop 能继续运行，这是因为通过它的智能性，使其将失败的任务重新分配给其他有效的节点。

（4）高可扩展性。对于部署 Hadoop，使得可以在少数的机器上运行的程序可以扩展到多个设备并且也可以扩展到成千上万个节点中，其中可以在低成本集群中进行。

对于 Hadoop 来讲，其核心内容是分布式文件系统(HDFS)，以及分布式计算框架(MapReduce)。Hadoop1.0 也是最先发布的版本，时的 HDFS 为主从结构，其主节点 NameNode 节点，从节点就是 Data Node 节点。主节点有且只有一个，因此面临着备份延时的问题，而如果将主节点全部挂掉，就可能会造成信息的大量损失。而此时的 Map Reduce 也是由一个主 Job Tracker 和几个从的 Task Tracker 所构成，它既承担了资源管理调度工作，也管理分布式的计算。Hadoop2.0 版根据 Hadoop1.0 中出现的问题，作了一定的完善。这种架构才存在扩展性问题和性能问题，不仅造成资源的浪费而且在 MapReduce 编程模型上的支持并不好。提出了高可用 HA，

中国知网 https://www.cnki.net

多个 NameNode 管理不同的目录实现横向扩展和访问隔离。最关键的是 Hadoop2.0 中添加了 YARN 框架，专门负责调配资源，从此 Map Reduce 就只作为计算架构而出现。Hadoop2.0 之后的版本发展就比较平稳。

在 Hadoop 项目结构的不断发展过程中，一个更加完整和全面的生态系统管理将逐渐形成。在该系统中，基于 HDFS 的分布式文件管理系统是基础，集群管理操作系统 YARN 是基于 HDFS。由于开发者可以在 YARN 上使用许多不同的计算架构，因此可以将 YARN 视为一个操作系统。YARN 可以使用统计仓库 Hive、流数据库系统 Pig、数据挖掘与数据挖掘的 Mahout 等。Flume 还可以实现大量的记录和扩展，Sqoop 也被用来进行 Hadoop 和常规数据库之间进行数据交换。Hadoop 的各组成部分分工明确，相互协作，相互约束，它为大数据中的 Hadoop 应用程序开发带来了无限的可能性。 Hadoop 生态系统如图 2-1 所示。

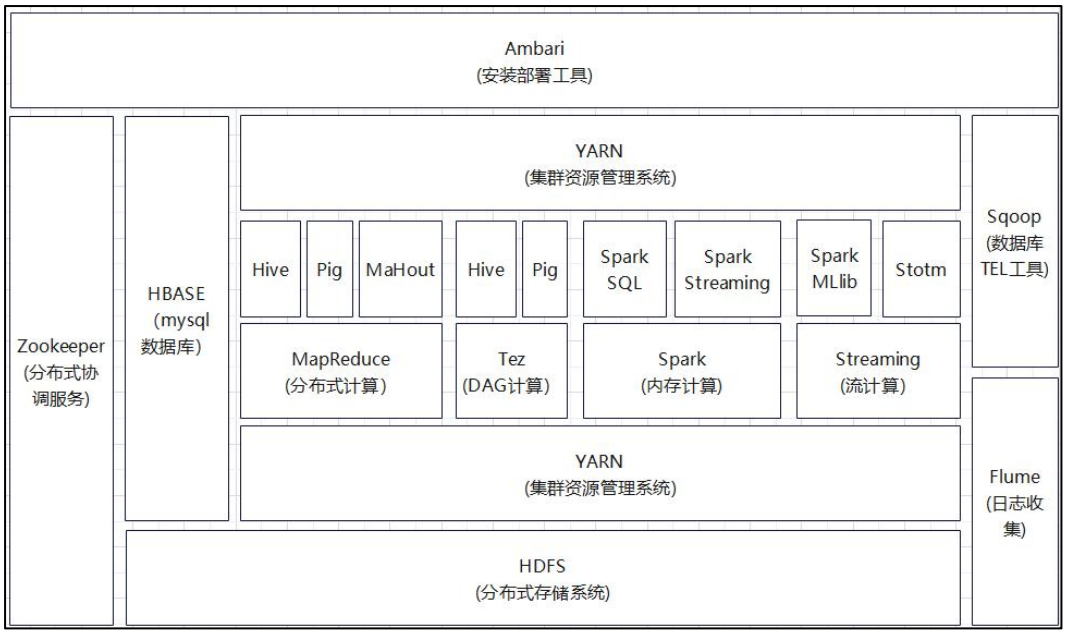

图 2-1 Hadoop 生态系统
Figure 2-1 Hadoop ecosystem

2.1.1 分布式文件系统 HDFS

分布式文件系统可以跨多台计算机存储文件，因此 Hadoop 分布式操作系统也称为 HDFS（Hadoop Distributed File System）[26]。HDFS 采用最有效的“一写多读”访问方法。使用流数据访问存储大文件[24]。

数据块是从硬盘读取的最小数据单元。与磁盘的文件系统结构类似，HDFS 也

中国知网 https://www.cnki.net

将数据存储在块中。块的默认大小为 64MB。HDFS 上的数据分为多个块，每个块单独存储。与其他存储系统不同，如果 HDFS 的文件大小小于最小读取单位，则不会浪费整个空间资源组。HDFS 子部门的引入，不仅提高了系统设计的质量，而且提高了数据纠错能力。如果无法访问出现故障的块，请从其他位置读取另一个副本，以避免数据丢失。

计算机集群中的多个节点中是分别存储着不同的文件，这种存储于计算机集群的方式时是通过 HDFS 分布式文件管理系统的方式进行，集群中有两种类型的节点。它们以管理者-工作者模式运行。一种类型名为 NameNode，属于管理员。NameNode 作为管理器发挥着重要作用。作为文件系统管理节点。NameNode 是管理文件系统中的所有目录和文件和树中的所有文件和目录。记录每个文件中每个节点的位置以及在该文件中操作的完整记录。此信息存在于 Fsimage 文件和 Editlog 文件中，并永久保存在本地文件中。另一种类型称为 DataNode，属于 Staff。DataNode 是一个工作节点。它主要负责查询和存储数据块。同时，NameNode 必须定期向 NameNode 报告自己保存的数据块列表，是因为它要是出现故障会引起丢失文件数据的问题。就是因为这样的情况来讲对于提高 NameNode 的容错性来讲，其是至关重要。

2.1.2 分布式计算架构 MapReduce

作为经常用于数据分析的编程设计模型。MapReduce 将作业的字符处理分为映射阶段和还原阶段两个处理阶段。输入和输出是键值。运行 MapReduce 处理数据时，输入数据集被划分为大小和长度相同的切片。每个切片创建并执行其自己的映射任务。执行任务的进程基于用户定义的函数方法执行。显示操作完成后，输出将写入磁盘，而不是 HDFS。这是因为反射结果只是中间结果，而不是最终结果。中期成果在任务结束后失效。因此，无需备份 HDFS。MapReduce 通过两个节点执行任务：Job Tracker 和一系列 Task Tracker。Job Tracker 主要用于监视和调度资源。Task Tracker 用于执行任务。

2.1.3 数据仓库 Hive

为了简化 MapReduce 程序，使用简单的语句操作进行数据查询，就引入了 Hive。虽然 Hive 和传统的关系数据库也有重要的区别。因为 Hive 不存储数据，而是集成 HDFS 来完成这项工作，并且不处理数据，它的作用是将其提交给 MapReduce。配置单元为用户提供配置 Hive QL 查询语句，然后将配置 Hive QL

中国知网 https://www.cnki.net

语句转换为要运行的MapReduce作业。因此，它旨在避免用户学习成本。MapReduce很难实现查询逻辑的开发。

Hive 的用户接口层，CLI（command line inteface）即 shell 终端执行是在 Hive 集成 JDBC 运行的服务器端，使用者在这接入 HiveServer 的 WUI 服务器，并使用 web 浏览器登录 Hive。MetaStore：元数据储存，元数据信息主要包括了文档的名字、表的行列、分组结构和属性、表的属性（是不是外部表等）、表的内容以及所在目录等等。MetaStore 存放着 Hive 中文件的元数据信息，将自身的元数据信息存放到关系型数据库中，并支持把 Metastore 单独放到远程的集群计算机上，使 Hive 更为健壮。Diver：该组件包括了执行器器、编译器、优化器完成 Hive QL 查询语句。生成的查询计划存储在 HDFS 中，并在随后有 MapReduce 调用执行。Hive 架构图如图 2-2 所示。

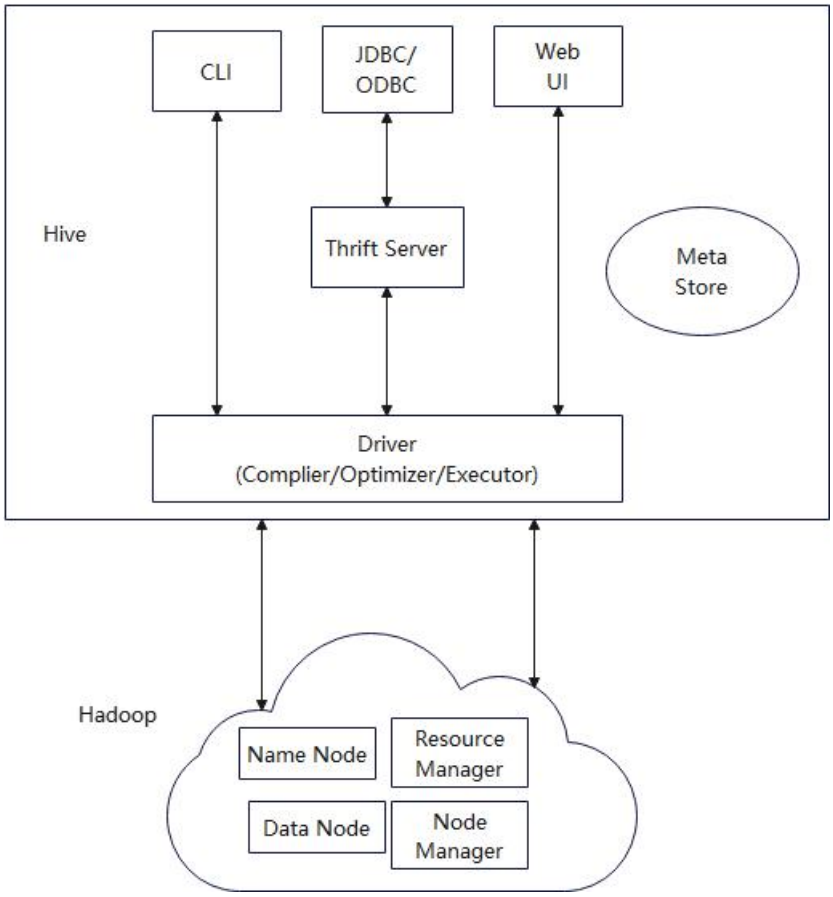

图 2-2 Hive 架构图

Figure 2-2 Hive read file

中国知网 https://www.cnki.net

2.2 Spark 框架

Spark 是一个基于内存的分布式并行计算框架，可用于大规模数据挖掘相关应用。Spark Framework 的诞生提供了一个更佳、更通用的大数据平台。基于磁盘的 MapReduce 不于与传统 Hadoop 的使用，Spark 的特点是分布式，是内存计算，具有更高的执行效率。对于 Spark 的适用方面，它可以适用于图形操作、实时流和其他脚本。本文选择作为测量分析的有力工具 Spark。不仅可以网络外的日志数据信息进行及时的分析、处理，还可以深入获取日志信息，大大扩展了该工具的功能[25]。Spark 生态环境如图 2-3 所示。

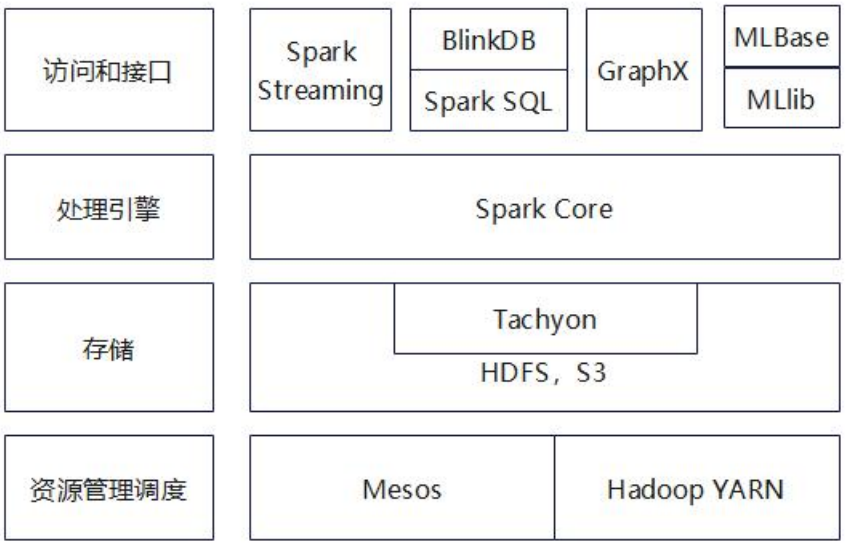

图 2-3 park 生态环境

Figure 2-3 Spark ecological environment

Spark 相对 MapReduce 主要优势，首先 Spark 基于内存迭代式计算，适合低延迟类型的作业，可以通过缓存共享 RDD 即弹性分布式数据集、DataFrame，提升效率。而 MapReduce 中间结果落地，需要大量的磁盘 IO，任务调度和启动开销大，不适合低延迟作业类型，因此一般多用于离线数据处理。另外 MR 编程不够灵活，仅支持 map 和 Reduce 两种操作，代码量也相对较多。Spark 支持多线程模型，每个 worker 节点运行一个或多个 executor 服务，每个 task 作为线程运行在 executor 中，task 间可共享资源。支持多种编程语言，并支持丰富的 transformation 和 action 的算子。虽然 Spark 相对于 MapReduce 有很多优势，但并不代表 Spark 目前可以完全取代 MapReduce。往往在数据量超大时 Hive 的原生引擎 MapReduce 会运行的更好，技术的对比要有深入的了解和实际业务场景需求，灵活使用。

中国知网 https://www.cnki.net

2.2.1 Spark Streaming 流处理

作为 Spark 的核心组成部分之一，为了能让 Spark 上的计算框架可以进行实时操作，一般来讲现在最主流的方式时通过 Spark Streaming 的方式进行的，它可以对实时统计流执行高吞吐量和容错流计算。对于各种不同的数据源，Spark Streaming 一般的数据操作可以在上面进行[27]，数据操作的结果可以存储在不同的容器中。您还可以使用自己的处理器处理数据流。Spark Streaming 具有 RDD 编程模型，通过批处理数据起到 RDD 编程模型的作用；Spark 运行流程图如图 2-4 所示。

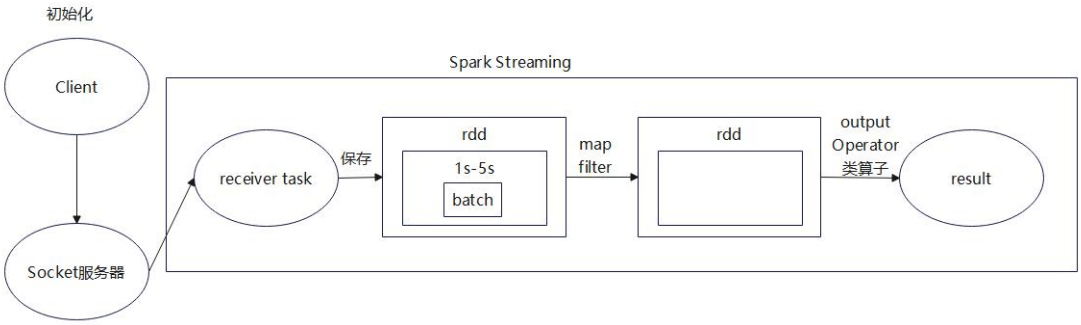

图 2-4 Spark 运行流程图

Figure 2-4 Spark operation flow chart

连续的离散数据流 DStream（Discretized Stream）的解释含义。Spark Streaming 的最核心思想，最重要的技术就是将大量繁重的计算任务分解为很多简单的任务，并按块执行。这意味着将根据工作表输入的数据拆分为独立的数据流，并最终转换为 RDD。因此，数据流操作成为 Spark 转换为 RDD 分组管理的一部分。在 Spark Streaming 处理的整个过程中，并行接收数据，然后将其缓存在工作节点的 Worker Node 的存储器中。Spark 在设计上是非常的精妙，这样的原因是因为它的设计是区别于传统的，连续的算子模型。可以根据不同的数据源和资源动态同时分配需要大量工作的节点。

2.2.2 Spark 数据分析

Spark 的编程语言是 Scala[28]，代码非常简洁，在 Spark 的早期版本，Spark 的核心代码仅三万行。但是除了 Scala 语言之外，Spark 同时还支持多种编程语言，如 Java，Python 等，极大地提高了程序开发的效率。具有通用的的计算引擎，在

中国知网 https://www.cnki.net

一般的数据分析和数据处理中提供不可代替的功能，也足以显现出的功能的强大，超出了统计或矩阵代数的范围。作为 Spark 的内置库，Mllib 提供了一些常用的机器学习算法，如聚类、分类、回归、协同过滤等，这些在机器学习的工作中都是十分重要的。

Spark 的 RDD 模型与机器学习模型训练的迭代计算非常兼容。一经应用，它就在一些场景中带来了重要的性能改进。由此可以得出，Spark 本质上是一个比 Hadoop 的 MapReduce 计算速度更快的基于内存的批处理程序，通过足够快的批处理来完成各种场景应用。

2.3 数据挖掘算法

2.3.1 朴素贝叶斯

贝叶斯分类器的本质是属于一类分类算法的[29]，属于有监督学习的过程。贝叶斯分类均以贝叶斯定理为基础，对于朴素贝叶斯，其是贝叶斯分类中简单实用的一种基于基于贝叶斯定理分类方法，也是基于特征条件独立假设的一种分类方式。有时使用概率要比那些硬规则有效的多，贝叶斯准则和贝叶斯定理就是利用已知值来估计未知概率的方法。使用概率论进行分类，首先从一个最简单的概率分类器开始，进而给出一些假设来学习朴素贝叶斯分类器。之所以称之为“朴素”，是因为在整个过程当中我们都使用的是最原始，最简单的假设。

在所有的机器学习分类算法中，朴素贝叶斯与其他大多数的分类都有所不同。绝大多数分类算法，比如说决策树，KNN，逻辑回归，支持向量机等，它们都是采用判别方法，也就是直观的解出了特征输出 Y 和特征输入 X 之间的关联公式，比如是决策函数 Y=f(X)，或者是条件分布 P(Y|X)。但是朴素贝叶斯却是采用生成方法，用 P(Y|X)=P(X,Y)/P(X)得出该概率大小。也就是直观找出关于特征输出 Y 和特征输入 X 的联合分布 P(X,Y)。

2.3.2 Kmeans 聚类

机器学习所有“新算法”中产生影响最多、最突出的研究领域应该是聚类（clustering）算法，其中一个重要的原因是聚类算法不存在客观规则，给定数据集总能从特定角度发现以往算法未覆盖的特定目标。K 均值聚类（Kmeans）作为无监督聚类算法中的典型代表，该算法的主要功能是把特征相似的样本自动归到某个类别中。所谓的是否是监督算法，就是输入样本是否有对应的标签。把每个

中国知网 https://www.cnki.net

对象分配给离它最近的聚类中心所代表的类别中，全部分配完毕即得到初始化聚类结果，聚类中心连同分配给它的对象作为一类。

两种情况下我们可以考虑聚类算法：（1）当我对研究对象所知甚少的时候，可以先聚类分析，看看样本里有没有“群体”，甚至是有意义的群体；（2）当我们对研究对象所知甚少，但是又必须对它们进行分组(分类，聚合等称呼都可以)时，可以用聚类算法来做。比如内容是关于李宇春的一次舆情事件分析。任务里包含对微博评论列表内容的分析，由于评论数据量好几万，业务人员分析不过来。就可以考虑用词向量特征做了一个聚类，先按照内容对这些评论分组(聚类结果一般是若干组样本，一个组通常成为“簇”)；然后交给业务人员，他们从聚出来的簇中寻找有意义的，然后概括了一下，就成了评论分析结果报告。

2.3.3 协同过滤算法

推荐算法具有许多应用场景和价值。现在最主流的方式，协同过滤算是一种，在工业中得到了广泛的应用。协同过滤(Collaboration Filtering)推荐算法一般包括 3 种，一种是面向于用户的，第二种是是面向于项目的[22]，第三种是基于模型的。协同过滤是一种经典的推荐算法方法，是基于用户的协同过滤推荐算法通过相似用户进行推荐，如加了两个好友就会互相推荐对方喜欢查阅的新闻；而基于项目的协同过滤则通过相似物品进行推荐[23]，如啤酒和尿布同时被奶爸所需要，所以一起出售；第三种是基于模型的协同过滤通过相似的模型进行推荐。使用机器学习对现有稀疏数据进行建模和求解，预测空白项目与数据之间的得分关系，并找到得分最高的项目推荐给用户。简单来说协同过滤的本质和 KNN 算法原理是相似的，都是经过数据、学习、和决策三个步骤进行系统推荐。用户协同过滤(UserCF)的计算方式与项目协同过滤(ItemCF)的计算方式类似，不同的是两两物品的相似度，转换成两两用户的相似度。两种方法在使用过程中适用于不同的领域，具有不同的性能，同时还存在着不同的缺点。

2.4 Java Web 技术

2.4.1 Spring boot

Spring 是 Java EE 系统设计的主要框架之一[19]，它是一种轻量级的框架，对软件开发的通用模块进行封装，大大提高软件开发工作的质量。Pivotal 团队旨在根据 Spring 自行开发的新 Spring Boot 框架简化新应用程序的初始开发和开发过程。

中国知网 https://www.cnki.net

框架配置不需要开发人员定义模板配置。我们使用了 Spring Boot 之后，由于父工程有对版本的统一控制，所以大部分第三方包，我们无需关注版本，个别没有纳入 Spring Boot 管理的，才需要设置版本号，Spring 中大量复杂的 XML 配置文件封装在默认的个人简介中，提高了程序员的开发效率。

Spring Boot 的主要特性包括遵循习惯优于配置的原则。使用 Spring Boot 我们只需要配置较少的东西，大多数使用默认配置即可。本着“约定优于安装”的设计原则，大大减少了对安装文档的应用。提供了监控系统使用的组件。项目快速搭建。Spring Boot 帮助开发者快速搭建 spring 框架，可无需配置的自动整合第三方框架。与云计算天然集成。内嵌 servlet 容器，降低了对环境的要求，可用命令直接执行项目。

2.4.2 ECharts

新闻日志分析系统需要对新闻日志数据统计分析的结果做出数据分析显示，这部分通过 ECharts 数据分析可视化框架实现的[21]。与其他的数据分析可视化框架比较，ECharts 的最大优点就是它的轻便特性,而且因为是用 JavaScript 语言所编写的，使得它的数据包数量非常少，不过 ECharts 同时也具备了庞大的数据分析表格库。几乎常见的数据分析图表类型,在 ECharts 中都可以得到实现。同时由于 ECharts 具备了极强的兼容性,因此目前市面上大部分的浏览器都能够采用 ECharts 数据可视化框架。而采用 ECharts 数据可视化框架也能够使得新闻日志的统计分析结果更加的简单明了。通过图表对新闻日志分析数据加以展现,使新闻日志数据的分类与表现更为精准。

2.5 本章小结

本章从系统行为日志获取、传输、保存、分析、挖掘、可视化展示等步骤分别介绍了系统应用的技术特点，分析了日志收集分析系统的技术上的可行性，为后续系统的开发工作与技术选择做了详细的铺垫。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

3 新闻日志系统需求分析

需求分析是软件开发过程中科研的组成部分。需求和目标作为其核心部分，通过在项目中阐述需求分析，深入了解需求分析，才能进行下一步的概要设计和详细功能设计。本章从功能需求和非功能需求分析的角度详细介绍了该平台。

3.1 系统功能性需求分析

本文的新闻日志分析系统是基于新闻客户端所设计的，目的是通过日志分析系统可以解用户对该新闻客户端的实际使用情况。该新闻客户端在对用户进行新闻[32]推送时有以下 3 种方式：

(1)热点新闻推送：重点针对时下较为热点的社会活动和重大事件，及时做出适当的报道和跟进，以满足用户对热点新闻的需求感。

(2)版块新闻频道：新闻版块主要是根据不同的报道题材对新闻进行分类，在新闻客户端中新闻版块包括体育、戏剧、战争、电影、游戏等。将新闻进行适当准确的分类可以使用户根据自身的喜好快速找到新闻板块进行相应的阅读。

(3)个性化新闻推荐频道：个性化新闻定制主要是用来迎合那些对特定新闻有着较高需求的用户，其根据自身的偏好对相关新闻进行订阅。比如作为父母，常常选择教育版块进行订阅和追踪。时刻关注着孩子教育方面的新闻。推荐频道是各个客户端主打的功能之一，提升用户满意度。

新闻日志分析系统的目的主要是想研究分析用户在新闻客户端上的各种点击使用行为，从而可以对新闻推荐、热点新闻推送等业务上进行有效的数据分析，新闻日志分析系统的主要使用者，即使用用户分为两类，对于研发人员和新闻信息分析师来说，通过有效的实时新闻日志数据分析能对新闻客户端在新闻推送和新信息发布的追踪进行精准的调整。而对于新闻 APP 运营人员和相关新闻产品设计而言，通过生成的新闻日志数据，可以对新闻 APP 的整体情况进行掌握，对新闻广告的推送和投放以及产品的创新有着较大的帮助，能给予使用的用户更好的产品体验[30]。

中国知网 https://www.cnki.net

3.1.1 用户管理模块

用户管理模块主要提供用户个人信息资料的管理，包括注册登陆，账号信息管理等功能。

用户管理模块实现了用户的管理功能，用户注册登陆之后才可以使用日志分析系统的全部功能。若用户首次登录系统，则必须完成账号注册，在注册页面填报账号、密码、手机、性别等个人信息。其中手机号用于账号的注册和绑定，性别用户向用户推荐一些相关新闻。完成注册后，用户可以进行登陆，登录后进入个人信息管理模块，用户才能完成查看个人资料以及更改信息的操作。

3.1.2 日志管理模块

日志管理模块主要进行日志采集的管理工作，并支持实时日志采集，日志预处理等功能，提供日志存储的管理，包括存储到 Kafka，存储到 HBASE。

（1）日志采集功能：日志采集系统能够监测客户端服务器相应的端口，实时采集产生的日志数据后，要考虑如何将服务器上的日志进行数据汇总，将离散的服务器日志聚合到一起，如果需要人工合成汇总会降低日志收集系统的实用性。

（2）数据传输功能：在采集过程中，需要考虑到日志瞬间产生的速度会比处理速度快，分析模块堆积大量数据未处理时会造成数据丢失、服务器停止服务，因此在日志收集模块和分析模块之间需要有数据缓冲模块。还可以清除收集的日志并过滤整个日志数据。此外，数据传输模块确保从分布式服务器收集数据的完整性和一致性。

（3）存储日志信息：自保存收集的卷日志时，必须考虑数据库的容量和可靠性，并具有数据备份机制，以避免大量数据丢失。

3.1.3 日志分析模块

对日志的统计与分析，由于不同的服务团队对数据统计及时性存在着不同的服务要求，因此对于新闻日志分析系统的中的统计分析，需要细分成实时日志数据分析、离线日志数据挖掘分析两个部分。

（1）实时分析：对于研发团队和数据分析师来说，需要对热点新闻进行及时的追踪和推送，同时也需要对产品的运行上线情况做到实时的关注。所以对时效性有着较高的需求，首先要分析最直接的基础数据包括新闻的阅读量、点赞量、这些数据是管理员和读者都能看到的。当热点新闻进行推送后，可能会导致用户

中国知网 https://www.cnki.net

的访问量、点击量、评论量等指标的突然增加，需要实时对新闻 APP 进行总体流量进行监控和分析，保证服务器支持突发的流量数据。同时如果不停的对用户推送不感兴趣新闻，可能会导致新闻总体流量的迅速下降。甚至有些用户会直接将新闻 APP 进行卸载，所以对最优搜索 rank 频率也要进行分析。

（2）离线分析：离线分析是以历史数据为对象。主要是需要对海量的日志数据进行细分分析和经营分析。这部分主要运用了 Hive、Spark sql 等技术，其目的是实现多维度静态分析历史数据。其创作者后台需要查看转化率、推荐量、阅读完成率等等，给运营人员一个直观的正向反馈，保证自己的运营方向不会走偏，了解什么样的内容，适用于什么样的人群，适合在什么平台发布，几时发布获得的平台推荐量最大。对于产品经理来说，主要是需要分析离线日志数据的流量变化，了解用户对产品的使用情况，根据流量变化的判断，对产品版本进行更新和迭代。

3.1.4 离线数据挖掘模块

离线日志数据挖掘功能。在对用户行为进行实时统计和离线统计后，还要深度挖掘隐藏于海量数据中的信息，数据挖掘主要分为分类算法，聚类算法和协同过滤三大类。对于话题聚类算法，使用 Kmeans 尽可能找到数据中自然聚类的中心，并把聚类结果保存到数据库中。使用朴素贝叶斯进行分类统计，选取具有最大后验概率的类作为该对象所属的类，并把分类结果保存到数据库中。对于用户话题的推荐功能，考虑了时间权重和用户兴趣变化，推荐出更为准确的用户喜好。并把推荐的结果保存到数据库中。

3.1.5 日志数据展示功能需求

日志数据的展示功能需求主要是针对复杂的日志分析数据。新闻日志分析的数据经过实时分析和离线的数据分析与挖掘后，会产生一堆比较复杂的分析数据，直接将这些数据反馈给非技术人员是非常不友好的。日志数据的展示就是将数据分析好的结果通过页面进行可视化展示，将数据分析的结果以图表的方式展现出来能够更加直观的了解用户对新闻客户端使用情况，并且根据数据的变化趋势及时的对新闻客户端做出调整。

中国知网 https://www.cnki.net

3.2 系统非功能需求分析

非功能需求分析是功能需求以外保障日志系统开发成功的一个重要因素，非功能性需求是需求的一个重要组成部分，它影响系统的架构设计，决定软件项目成本的重要依据，在软件项目评估过程中需要重点关注。

（1）性能需求：该系统因为管理着很多的数据信息，所以需要保证系统处理数据的时间效率，系统应测量在一定时间内完成的吞吐量（吞吐量）、用户执行输入响应所需的时间（响应时间）、用户处理输出信息所需的时间（执行时间）。关注在峰值条件下是否能满足要求。系统逻辑设计符合具体新闻业务需求，此外，随着机器学习的不断发展，基于推荐系统的机器学习算法也不断增加，对于不同的推荐系统，应该有针对性的选择，并且结合用户的做法，行为的分析，除此之外，算法的召回率，精度等参数也是十分的重要。

（2）可维护性和可扩展性：该系统能够在主流操作系统上运行，需要考虑系统的可维护性，修复不仅测量修理所需的平均时间，还测量正确的修复比率。还需要考虑可扩展性，软件开发中，”变化“是常见的事情，可扩展性是系统设计阶段重点考虑的质量属性。努力取设计好的体系结构来提高可扩展性。

（3）可靠性：系统需要保持高可用特性，允许短暂中断，通过冗余实例和失效检测实现快速恢复。保持容错性，发生故障时仍可继续运行，做到零宕机时间。根据用户的喜好对系统页面进行设计和完善。

3.3 本章小结

对于基于 Spark 的新闻日志分析系统，本部分详细介绍和分析了实现需求，包括功能需求和非功能需求。在功能需求部分，重点介绍了用户管理、日志管理、日志分析、数据挖掘和可视化；围绕性能需求和可伸缩性分析非功能性需求。

中国知网 https://www.cnki.net

4 系统概要设计

新闻日志分析系统的总体设计原理是为了能够实现对新闻日志分析系统科学、有效的研究。整体的规划原理包括模块化原则、抽象化原则、可重用性原则、强内聚原则、低耦合原则。本章从系统整体架构设计、系统数据流程设计、系统集群资源规划、系统功能模块设计以及系统数据库设计等 5 个方面进行日志分析系统的概要设计。

4.1 系统整体架构设计

系统整体架构是系统的草稿图纸。系统架构旨在连接和传播各种组件，日志分析系统的逻辑架构图分为五层，数据源层、算法层、服务层、数据存储层、对象层。数据源层为系统提供日志数据，数据存储层为系统提供数据存储功能，算法层为时间权重和用户兴趣变化的组合协同过滤算法，服务层为用户提供日志查看、离线分析、实时分析、数据挖掘等四个服务，本系统面向的对象是新闻客户端的业务人员。如图 4.1 所示是日志分析系统整体架构图。

图 4-1 日志分析系统整体架构图

Figure 4-1 Overall architecture of log analysis system

中国知网 https://www.cnki.net

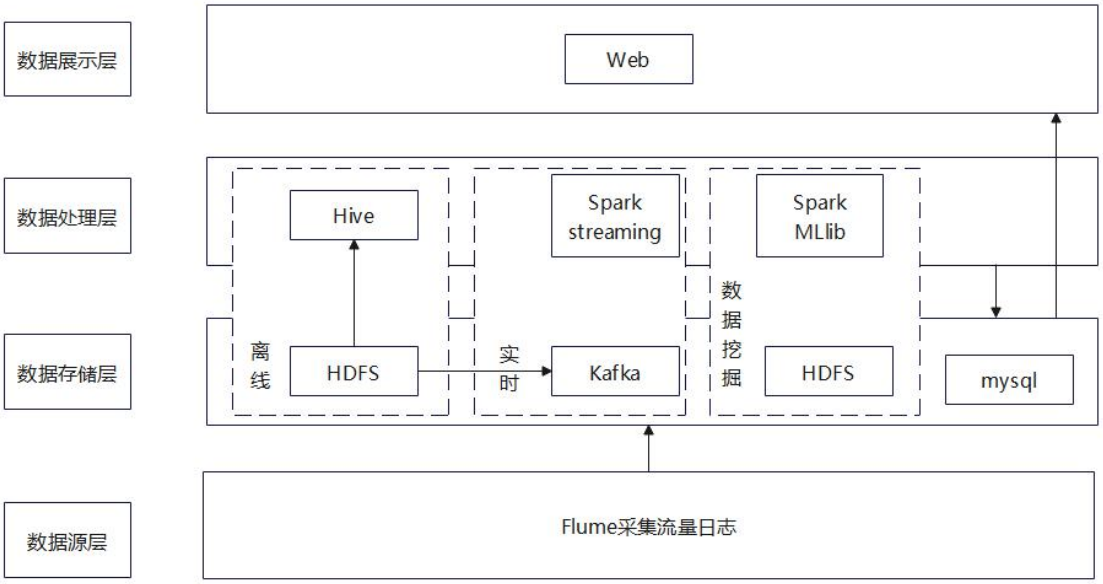

图 4-2 日志分析系统技术架构图
Figure 4-2 Technical architecture of log analysis system

按照分层设计的思想，系统从下到上分为四层：数据源层、数据存储层、数据处理层和数据显示层。数据源层。该层主要作用是采集新闻应用程序的用户搜索日志。数据存储层。该层由 MySQL、Kafka 和 HDFS 文件系统组成。在数据存储层中它的主要作用是存储日志分析系统的全部数据。并且 HDFS 作用是，里面是存储着原始数据中，MySQL 中存储着元数据和通过日志分析系统分析出的并通过相应的算法计算得到的结果。作为消息中间件，Kafka 充当消息缓冲区，临时存储数据流中生成的日志信息。数据处理层。使用 Kafka 集成 Spark 流实时数据分析。离线数据查询和分析采用 Spark 框架，Hive 用于读取和写入数据库中的数据。机器学习算法，如机器学习库中的协同过滤，完成数据挖掘。数据显示层。一般来讲，前端 Web 界面为了展示数据的结果以及很多相应的数据趋势，在本系统中运用了 Java 作为后端的开发语言，前端 Web 界面运用了 Echarts 等工具展示表格，图数据的展示，显示的图或者表格的数据是通过后端 Java 调用数据库数据和前端进行数据交互实现的动态展示。

4.2 系统数据流程设计

数据处理流程，部署三台 FLume 日志采集节点，实现对日志数据的采集和汇聚，并把数据存储到相应数据库中。使用 Structured Streaming 对 Kafka 集群中的数据流进行处理，实时分析会按照时间设置对数据库进行刷新计算，并将数据保

中国知网 https://www.cnki.net

存到数据表中，实现数据可视化。离线分析会使用不同的组件，对用户历史数据进行细分分析和维度分析，将这些数据存入数据表中，实现数据的可视化。

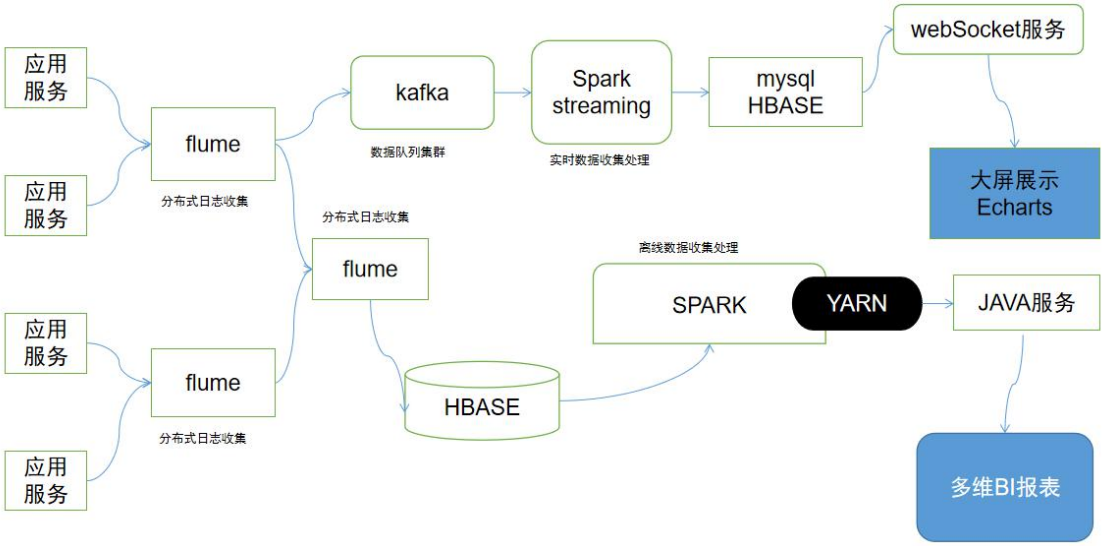

图 4-3 日志分析系统数据流程图

Figure 4-3 Data flow chart of log analysis system

4.3 系统集群资源规划设计

采用三台机器部署集群，基于架构设计、数据流程图来设计集群资源规划，涉及到的模块有 HDFS、YARN、Zookeep、Kafka、HBASE、Flume、Hive、Mysql、Spark 以及 Hue。使用高可用自动故障迁移的原理，设置了两个 master 节点，当主节点发生故障时，无法给备节点发送心跳消息，如果别节点无法继续监测来自主节点的心跳。就会调用自身的接管系统，接管主节点的 ip 资源和服务系统。系统集群资源表如表 4-1 所示。

表 4-1 系统集群资源规划表

Table 4-1 System cluster resource planning

	master	**Slave1**	**Slave2**
HDFS	NameNode	DataNode	DataNode
YARN	NodemManager	ResourceManager	NodeManager
Zookeeper	Zookeeper	Zookeeper	Zookeeper
Kafka	Kafka	Kafka	Kafka
HBASE	Master	Regionserver	Regionserver
FLUME	FLUME	FLUME	FLUME
HIVE			HIVE
MYSQL			MYSQL

中国知网 https://www.cnki.net

表 4-2 （续表）
Table 4-2 (Continue)

	master	Slave1	Slave2
SPARK		SPARK	
Hue			Hue

4.4 系统功能模块设计

以上一小节的系统架构为依据，本文为该平台设计了用户管理模块、日志管理模块、日志分析、可视化、数据挖掘五个功能模块。图 4.4 是系统的功能模块结构图。

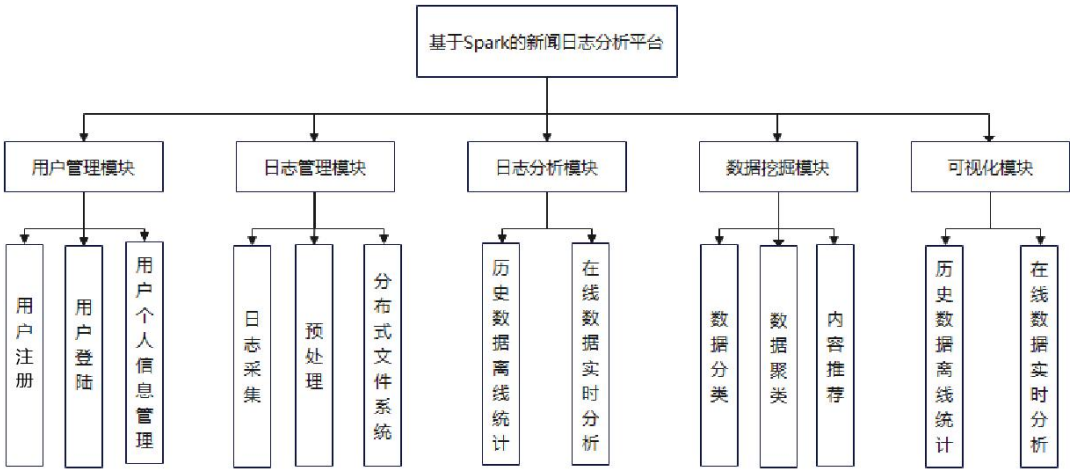

图 4-4 系统功能结构图
Figure 4-4 System function structure

用户管理模块包括首先包括用户注册功能，然后是用户登录功能，在用户通过注册到数据库的数据进行登录系统后，可以进入到个人信息管理功能。用户可以对自己的个人信息进行管理，包括电话、性别等。只有登录的用户才可以使用日志分析系统。

日志管理模块包括日志采集、数据传输、日志存储、预处理四个功能。采用分布式文件系统 HDFS 和数据库 MySQL。HDFS 用于存储大型数据。HDFS 充当存储默认日志数据的默认文件柜。文件被写入块中，简化了管理，日志可读性差，Hadoop 使用 HDFS 存储数据，Hive 则是把 HDFS 数据文件映射成数据表，通过 Hive SQL 操作 HDFS 中的数据，其中 Hive 将 SQL 语句转换成 MapReduce 任务进行，因此 Hive 实质就是一个基于 HDFS 的 MapReduce 计算框架，对存储在 HDFS 中的数据进行分析和管理。

中国知网 https://www.cnki.net

分析模块主要包括离线日志分析和实时日志分析。实时日志分析按照固定的时间来轮询，对每个时段的新闻情况进行统计，对总体的话题数量进行统计，对查询词 url 最优的 rank 频率统计分析。并且计算的数据保存到数据库中。离线新闻日志结果分析需要对日志进行预处理，对数据进行排查，将脏数据进行剔除，保证数据的可靠性，数据分析的准确性。对于离线日志的分析主要是将有用的日志数据筛选出来，直接采集下来的日志数据并不都是有效数据，清除之后可以减少数据存储的压力，同时日志的数据分析工作量也得到了一定程度的减弱。连线分析主要是查询关键字词云以及时段流量分析。分析完成后将这些数据存入数据库中数据的可视化。在 HBASE 中创建表，存储离线数据，然后设计离线数据存储，表结构如图 4.5 所示。

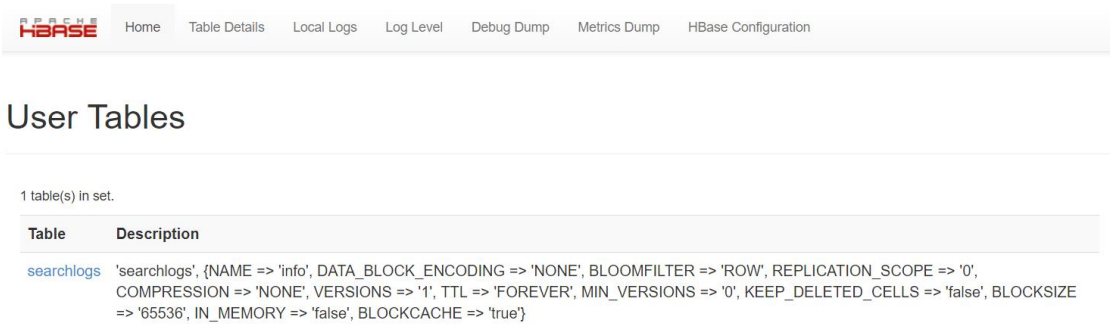

图 4-5 HBase 表结构图

Figure 4-5 Structural diagram of HBase Table

数据挖掘模块主要是使用 MLlib 中通用的学习算法以及工具。利用了 Spark 的内存计算适合迭代行计算的优势，有效应对海量数据挖掘的问题。协同过滤模块给用户兴趣变化带来的影响，实现快读、准确的为用户推荐有用资源，是通过考虑项目类型、时间和距离这三个因素的影响。

可视化模块负责分别把离线日志分析与实时数据分析以图表的形式展示给业务人员，业务人员可以选择想查看的数据维度。

4.5 数据库设计

4.5.1 E-R 图设计

为了更清晰、准确地展示新闻业务方的需求，在数据展示层应设置相应的数据表。日志数据分析的结果数据可以稳定存储。支持日志分析系统的读写。显示

中国知网 https://www.cnki.net

层数据应创建概念数据模型实体关系图（Entity-Relation Diagram），对于数据库的概念设计一般常常转换为 E-R 图进行设计。E-R 图描绘的数据模型也可以相应地称为 E-R 模型。设计数据库的 E-R 模型图，确认需求信息的正确和完整。确定每个局部应用包含哪些实体，实体包含哪些属性，实体之间的联系。确定每个局部应用包含哪些实体，实体包含哪些属性，实体之间的联系。

新闻日志分析平台，用户实体具有用户 Id,用户名、密码、邮箱、电话等属性，离线日志具有新闻 Id、url、标题、排名次数、点击次数、用户等属性。实时日志具有日志 ID、url、时间、实时数据等实体。新闻分类实体具有 Id、分类名称、话题数量等属性。一个用户可以管理多个离线日志实体，具有一对多的关系。一个用户可以管理多个实时日志实体，具有一对多的关系。离线日志可以转化为实时日志，是一对一的关系。

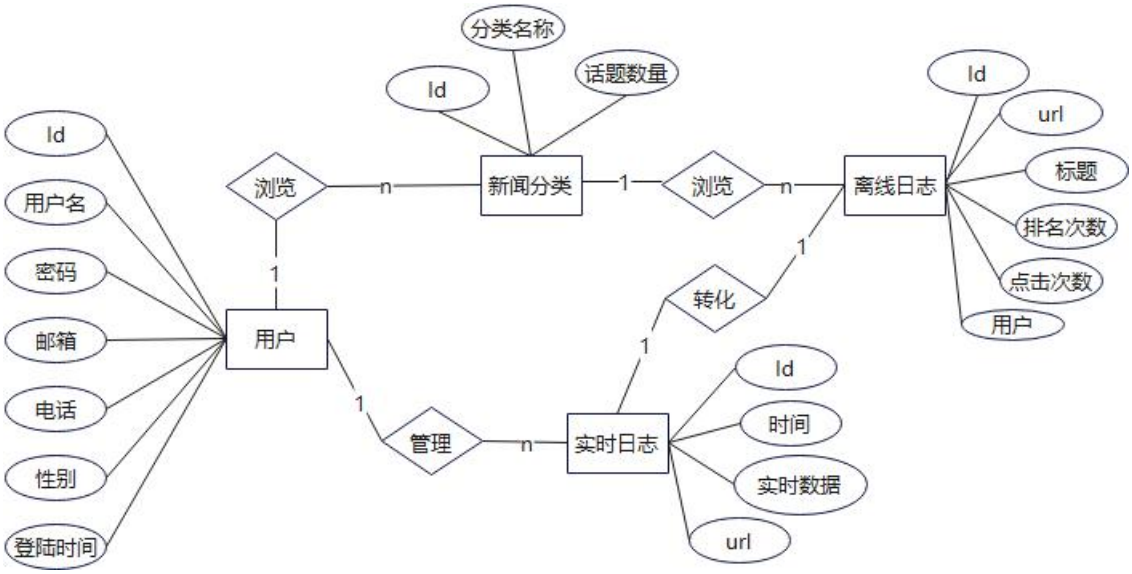

图 4-6 日志分析系统 E-R 图

Figure 4-6 E-R diagram of log analysis system

4.5.2 基础表设计

本次数据库是采用了 Mysql 数据库，根据上述 E-R 图进行数据库表的结构设计。表的设计主要由字段名、数据类型、长度、是否为空、主键、外键、注释构成，具体设计如下：

（1）实时话题汇总表。该表主要用于实时统计的话题和话题数进行汇总。实时话题汇总表结构如表 4-2 所示。

中国知网 https://www.cnki.net

表 4-2 实时话题汇总表

Table 4-2 Summary of real-time topics

字段名称	数据类型	是否允许为空	字段描述
title	Varchar(255)	否	查询话题
title_count	Integer	否	查询话题数

（2）用户信息表（user）,用于存放用户信息，包括用户昵称、登录名称、密码等信息。用户信息表结构如表 4-3 所示。

表 4-3 用户信息表（user）

Table 4-3 User information(user)

字段名称	数据类型	是否允许为空	字段描述
Id	Integer	否	ID
Login_time	datatime	否	登陆时间
user_name	Varchar(255)	否	用户名
user_pwd	Varchar(255)	否	密码
user_phone	Varchar(20)	否	手机号
user_sex	Char(2)	否	性格
user_email	Varchar(30)	否	电子邮箱

（3）实时话题汇总表。该表主要汇总了查询的实时话题和查询的实时话题数。实时话题汇总表结构如表 4-4 所示。

表 4-4 实时话题汇总表

Table 4-4 Summary of real-time topics

字段名称	数据类型	是否允许为空	字段描述
title	Varchar(255)	否	查询话题
title_count	Integer	否	查询话题数

（4）离线话题汇总表。在离线数据统计分析时，该表记录了离线数据的 Id，查询话题和查询话题数，而其中的数据主要是前 30 热门搜索数据，离线话题汇总表结构如表 4-5 所示。

中国知网 https://www.cnki.net

表 4-5 离线话题汇总表

Table 4-5 summary of offline topics

字段名称	数据类型	是否允许为空	字段描述
Id	Integer	否	ID
ol_title	Varchar(255)	否	查询话题
ol_title_count	Integer	否	查询话题数

（5）URL 点击排行榜汇总表。在离线数据统计分析时，该表统计前 10 的 URL 点击排，下面是表的结构如 4-6 所示。

表 4-6 URL 点击排行榜汇总表

Table 4-6 Summary of URL click ranking

字段名称	数据类型	是否允许为空	字段描述
Id	Integer	否	ID
url	Varchar(255)	否	URL 名称
url_count	Integer	否	数量

（6）查询话题分类表。朴素贝叶斯分类后，该表统计话题对应分类的话题数量。下面是表的结构如 4-7 所示。

表 4-7 查询话题分类表

Table 4-7 Query topic classification

字段名称	数据类型	是否允许为空	字段描述
Id	Integer	否	ID
title_type	Varchar(100)	否	查询话题类型
type_count	Integer	否	数量

4.6 本章小结

本章详细介绍了系统的总体设计。从系统逻辑架构设计、数据流设计、集群规划设计、功能模块设计和数据库设计五个方面介绍了总体设计。在逻辑架构设计中，从业务逻辑层设计系统架构。在数据流设计中，根据数据流方向详细介绍了数据流，并根据数据流的方向合理配置了集群资源。功能模块设计根据需求分析划分模块。最后，根据需求划分，使用 E-R 图建立概念模型，从而设计数据库表的结构。

中国知网 https://www.cnki.net

5 协同过滤算法设计与实现(TACF)

5.1 算法概述

协同过滤是指一个通过集合中最接近用户或项目的集合进行推广的方式,在现今各大推广算法当中,它的推广效果都相当高,而且使用范围也较为广阔。而协同过滤的核心理念为“物以类聚，人以群分”。推广体系主要由三种方式组成,依次是根据信息的、协同过滤的或者混合型的推广方式。而采用协同过滤的推广方式是最常见的个性化推广技术，在生活实践中还存在一些明显的缺陷。比较突出的是应用冷启动、数据稀疏性、可扩展性等难题,且传统的协同过滤算法在实现个性化推荐时较难获取用户兴趣,基于这些问题，国内外学者都做出了巨大的努力，主要总结为未顾及用户特征和时间变化这 2 种因素给应用用户兴趣变化所造成的影响。

因为传统推荐算法主要基于用户对项目的评价分数,通过相似度公式估计使用者和使用者之间的相似程度,项目类别属性对用户兴趣变化所产生的影响可能会被忽略。比如新闻项目就带有“教育”、“战争”、“动物”等多种属性。对于数据挖掘来考虑，这些属性在兴趣爱好评价上影响使用者，从而得到更为精准的最近邻居集。从而降低用户兴趣改变对推荐结果的影响。

时间信号也是十分关键的一个信号[31]，它对使用者的个人兴趣也产生着很大的影响。使用者的兴趣爱好与活动也会跟着时间的改变而发生变化。例如，程序员应用时在工作初期比较偏向于选择先阅读入门专业类别的教程书，而根据时间的累积，逐步将入门类别转化为专业层次更高的图书；此外，由于使用者对项目管理的行动还会受到季节效应的负面影响，因此使用者在不同的时节对不同的项目表现的兴趣程度也有所不同。因此一般人们都会认为,使用者最近浏览的项目即是其感兴趣的项目。

本文实现一种将时间权重与用户兴趣变化组合在一起的混合协同过滤方法[33]TACF(time and interests collaborative filtering)。通过对用户兴趣进行一种分布矩阵的搭建，得到新的用户兴趣分布向量，运用新的用户兴趣分布向量计算用户间存在的兴趣相似度；然后，根据时间的变化引入全新的时间函数，计算基于时间权重的用户评分相似度；将两种相似度进行线性加权，通过衡量用户新人度来判断最终对目标用户的推荐，产生 Top-N 推荐。引入全新时间函数如公式（1）所示：

中国知网 https://www.cnki.net

$$\mathrm{w}(t_{u,i}) = \frac{1}{1+\exp(-t_{u,i})} \tag{1}$$

其中，t 取值范围为[0-1]，$\mathrm{w}(t_{u,i})$取值范围为(0-1)。由公式知，$\mathrm{w}(t_{u,i})$函数是一个单调递增函数，其值随时间 t 增加而增加，但不会超过 1；$(t_{u,i})$表示在时刻 t 时用户 u 对项目 i 的评分值。

采用 pearson 相关系数计算相似度的方法来计算用户评分相似度$\mathrm{sim}_2(u,v)$,具体计算如公式（2）所示：

$$\mathrm{sim}_2(u,v) = \frac{\sum_{i\varepsilon I_{uv}} (R_{ui} \times \omega\ (\mathrm{t}_{u,i}) - \overline{\mathrm{R}}_u)(R_{vi} \times w(t_{v,i}) - \overline{R}_v)}{\sqrt{\sum_{i\varepsilon I_{uv}} (R_{ui} \times w(t_{u,i}) - \overline{R}_u)^2} \sqrt{\sum_{i\varepsilon I_{uv}} (R_{vi} \times w(t_{v,i}) - \overline{R}_v)^2}} \tag{2}$$

在$\mathrm{sim}_2(u,v)$函数中 u 表示用户，而这个函数的意义是表示用户 u 和 v 之间基于时间权重的用户评分相似度；$\mathrm{w}(t_{u,i})$表示用户 u 对项目 i 评分的时间权重。

5.2 数据准备

本文的实验环境为一台 PC 机，机器的配置为 Intel Core i9-13900K 16GB,操作系统为 Windows 10。本文选择 MovieLens 数据集作为实验的测试数据集 MovieLens 是明尼苏达大学 GroupLens 小组搜集的电影评价数据，通过用户对电影的评分(1~5 进行电影推荐。MovieLens 数据集提供了 4 种量级的数据 10 万条评分 100 万条评分、1000 万条评分、2000 万条评分。本算法数据集来自实际应用环境下用户搜索和点击的结果,943 位用户对 1682 个项目打分产生了 10 万条评分数据，由此得出的计算的数据稀疏度，大约为 94%。用户 id 的范围 1-6040，新闻 id 的范围 1-3952，评分的范围 1-5。每个用户至少都有 20 个评分（即每个用户至少对 20 个项目进行打分）。下面是查询日志的格式和样例数据。

表 5-1 数据集表

Table 5-1 Data set table

用户 ID	项目 ID	评分	时间戳
186	302	3	891717742
22	377	1	878887116
244	51	2	880606923
166	346	1	886397596
298	474	4	884182806

中国知网 https://www.cnki.net

为了更好地验证推荐模型的有效性，将所有实验数据平均分为五组，随机抽取一组作为训练集，其余四组作为测试集，主要用于创建推荐模型参数，测试集主要用于验证模型的推荐有效性。

5.3 算法训练

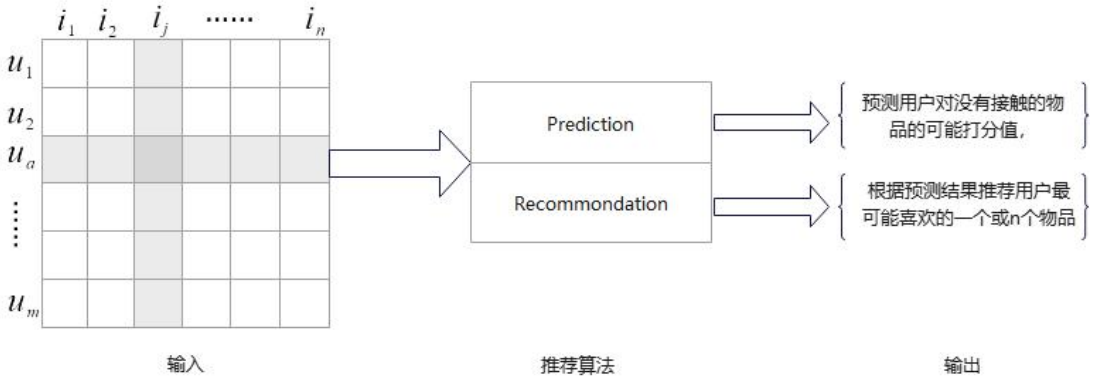

图 5-1 算法推荐原理

Figure 5-1 Algorithm recommendation principle

在推荐算法中，用 m×n 的矩阵表示用户对项目的喜爱程度，一般用打分表示使用者对项目的喜好程度，分数越高说明越喜欢这个项目，0 表示没有使用过该项目。图中行表示一个使用者，列表示一个项目，R_{aj} 表示使用者 a 对项目 j 的打分情况。CF 包括两个过程，一个为预测过程，另一个为推荐过程。预测过程是预测使用者对没有选择过的项目的最可能打分情况，推荐是根据预测阶段的结果推荐用户最可能感兴趣的 1 个或 Top-N 个项目。

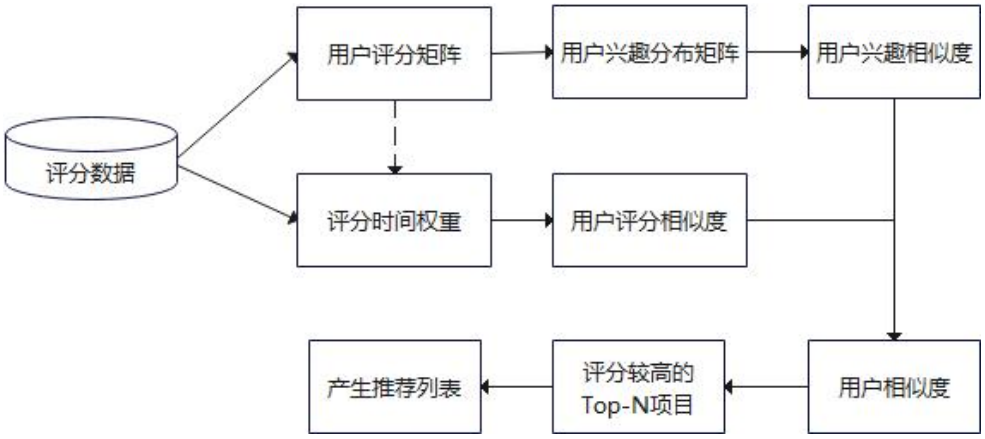

图 5-2 TACF 算法流程图

Figure 5-2 TACF algorithm flow chart

中国知网 https://www.cnki.net

首先加载数据集，获得用户-评分矩阵数据，然后获得模型的输入，再通过新建立的用户兴趣矩阵，得到用户兴趣分布向量，最后通过优化的余弦相似度计算两个使用者之间的兴趣相似度。引入时间权重法，即认为用户最近浏览的项目就是其感兴趣的项目。根据用户-评分矩阵计算，首先通过 pearson 相关系数估算用户评分相似度。最后组合基于用户兴趣和基于时间权重的相似度，再通过线性加权的方法计算总的相似度，产生推荐列表，得到模型的预测结果。并使用改进公式进行评分预测。流程图主要分为 3 部分，具体挖掘流程如图 5.2 所示。

模型调优。为了使推荐算法能够在最佳参数下推荐应用，我们进行了 TACF 在超参数不同取值表现评测，其中我们测评的目的是获得最佳的α参数，使得 MAE 达到最小值，我们将α参数的取值分别取为 0.1、0.2、0.3 到 0.9，测试 TACF 算法在不同α值下的 MAE 值。 我们可以从下图得知，在α参数为 0.1 时，MAE 达到最大，而接近 0.25 时可以发现随着α值得不断增大，MAE 值开始下降，当α为 0.5 时，MAE 值取得最小值，此时 MAE 值获得最小值，而 0.5 以后 MAE 的趋势又开始增加，所以在α参数为 0.5 时，MAE 为 82 时即算法的推荐质量最高，具体数据如图 5-3 所示。

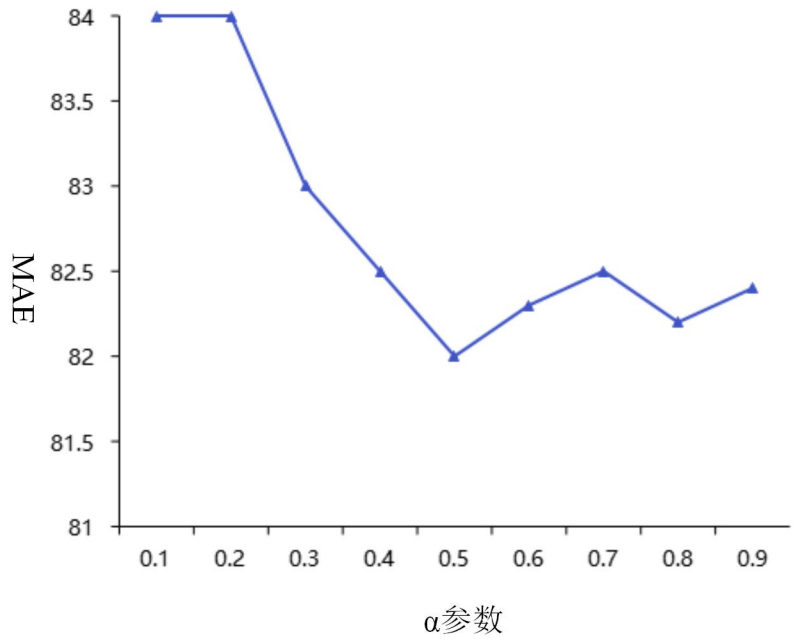

图 5-3 TACF 在超参数不同取值表现评测

Figure 5-3 Performance evaluation of TACF in different values of super parameters

中国知网 https://www.cnki.net

5.4 算法实验结果

选择平均绝对误差（MAE）作为该模型的主要评价指标。它指示系统的预测得分与实际得分之间的误差，从而判断算法推荐的准确性，具体如公式（3）所示：

$$\mathrm{MAE} = \frac{\sum_{i=1}^{n} | r_{\mathrm{ui}} - r_{ui}^{'} |}{n} \tag{3}$$

其中，r_{ui}、$r_{ui}^{'}$ 分别表示使用推荐算法计算的实际项目评估和预测评估，其中 n 表示测试对象集的项目总数。为检验本文提出算法的推荐准确率，将本文提出的算法（TACF）和 UserCF 推荐算法在不同 K 最近邻数量的情况下进行对比分析，实验数据如图 5-4 所示。

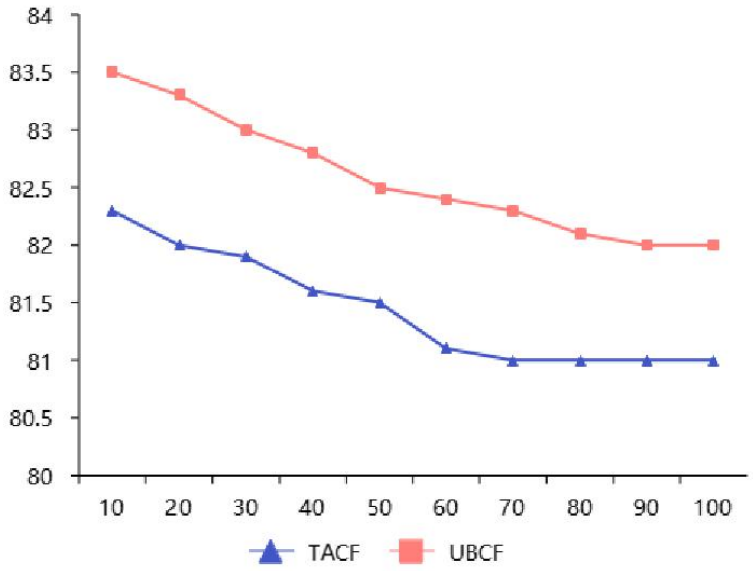

图 5-4 不同算法的 MAE 值对比

Figure 5-4 Comparison of the MAE values across the different algorithms

由图 5-4 可知，改进的 TACF 算法比 UBCF 的 MAE 值偏小。因为 MAE 值越小预测精度就越高，所以 TACF 算法比 USBCF 测精度偏高，说明了改进的方法改善了预测准确率。对于最近邻数量 K 不断增加，MAE 值不断减小,推荐精度不断提高，验证了 TACF 推荐算法确实提高了系统的推荐质量。

中国知网 https://www.cnki.net

5.5 本章小结

本节针对传统 UserCF 推荐算法中未能反映出用户自身特征和时间变化，对推荐性能产生了影响。本文提出改进的组合协同过滤算法，在测算用户间的兴趣相似度时，我们通过挖掘使用者已评价过的项目类型加以细分，研究项目类型对使用者爱好程度的反映；然后再加入时间函数预测评分，最后给出推荐。实验结果方面，对比不同算法下的 MAE 值，验证算法取得比较好的推荐效果。

中国知网 https://www.cnki.net

6 新闻日志系统详细设计与实现

系统详细设计是在系统的概要设计完成之后，还需要确定子系统和各个模块的具体实现方法，以便建立一个完善的日志分析系统。本章将采用程序流程图、类图以及时序图对用户管理模块、日志管理模块、日志分析模块、数据可视化模块进行详细设计。

6.1 用户管理功能实现

用户管理模块包括首先包括用户注册功能，然后是用户登录功能，在用户通过注册到数据库的数据进行登录系统后，可以进入到个人信息管理功能。本节将通过流程图、类图以及时序图对该模块进行详细设计，该模块流程图如图 6-1 所示。

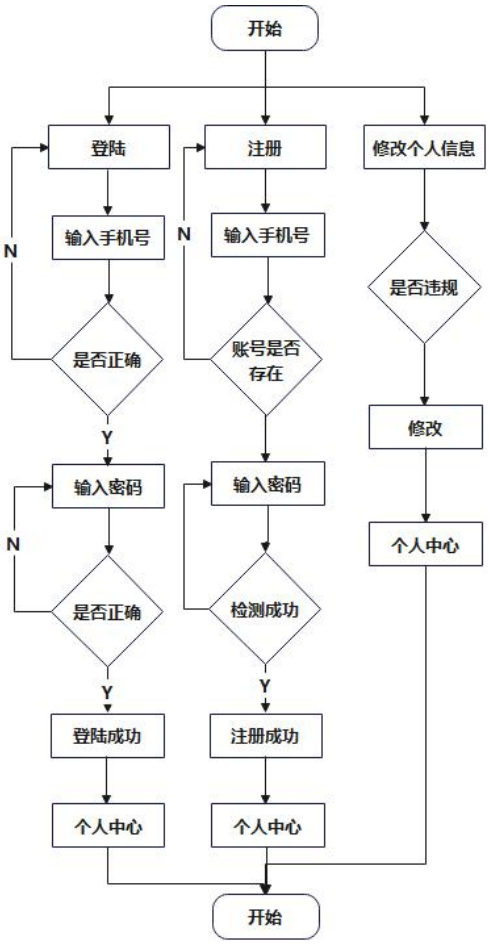

图 6-1 用户管理流程图

Figure 6-1 User management flow chart

中国知网 https://www.cnki.net

用户管理模块涉及到的实体类有 UserController、User、接口 UserService、UserDao、接口实现类 UserControllerImpl、UserServiceImpl、UserDaoImpl。如类图 6-2 所示。其中 User 为普通用户实体类，用于定义用户的基本信息。UserController 是控制类，UserService 负责处理用户注册及个人信息管理的相关请求，UserDao 是数据访问层接口。业务代码存放 UserMapper.Xml 文件中。 MyBatis 框架通过映射文件 XML 文件来读取 SQL 语句，完成对数据库的操作。该模块类图如图 6-2 所示。

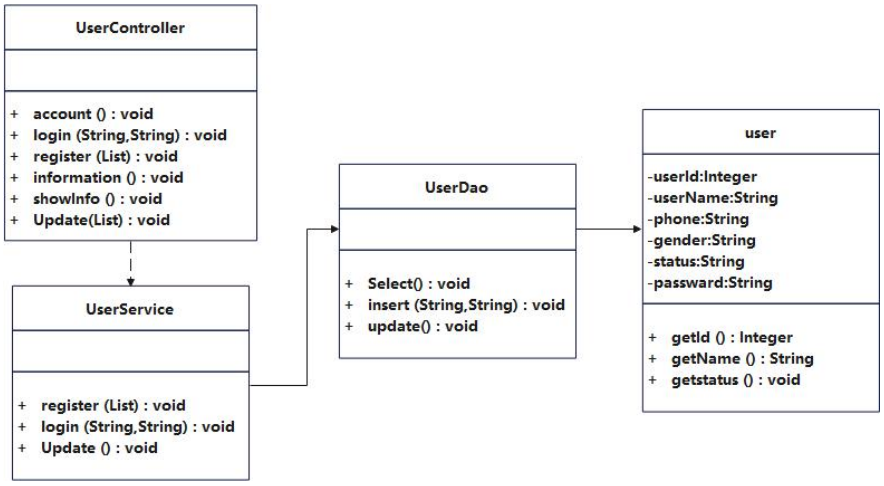

图 6-2 用户管理模块类图

Figure 6-2 Class diagram of user management module

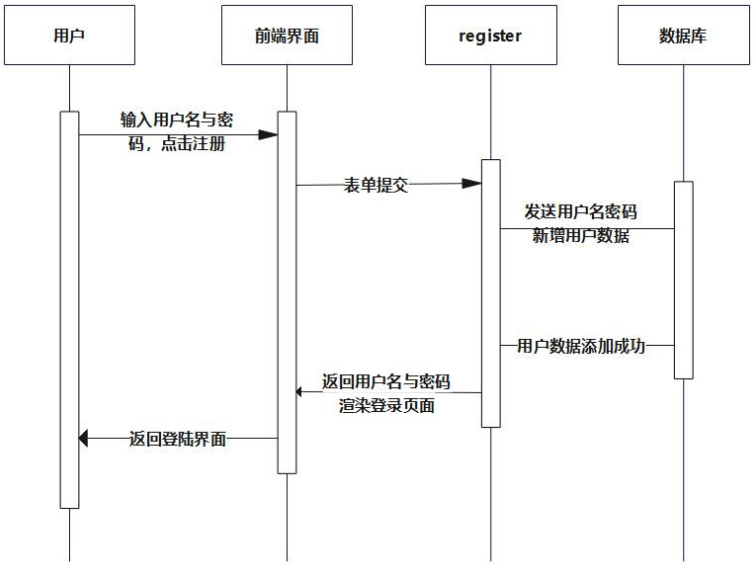

图 6-3 用户注册时序图

Figure 6-3 User registration sequence diagram

中国知网 https://www.cnki.net

用户需要在前台界面填报用户名和并对新闻日志分析系统进行注册。随后前端界面接收用户填写的注册表单，调用 register 模块，然后将表单数据发送到数据库中，当注册成功后，数据库添加用户的注册信息，并且页面切换到登录界面。该模块时序图如图 6-4 所示。

用户根据自己的注册信息，在前端界面进行登录，输入用户名和密码，前端界面对用户输入的信息进行表单的提交。然后将当用户输入的用户名和密码传入到数据库里面，并且同数据库中存储数据匹配，用户登录成功，进入到系统界面。如果用户名输入的用户名在数据库中不存在，则提示该用户不存在，返回登录界面。如果用户输入的用户名存在，但是密码与数据库中用户记录的密码并不相同时，系统提示密码错误。该模块时序图如下图 6-4 所示。

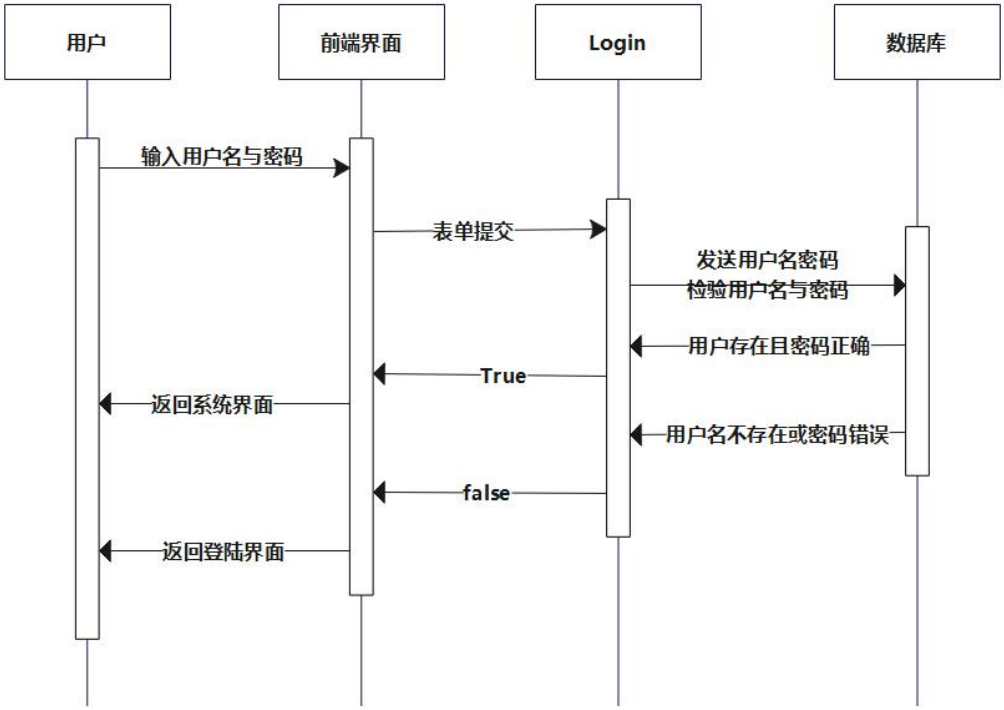

图 6-4 用户登陆时序图
Figure 6-4 User login sequence diagram

6.2 日志管理模块设计

数据采集及存储部分主要分为四个模块，分别是日志收集、数据传输、数据存储、预处理。本节将通过流程图、类图时序图以及实现效果图对该部分模块进行详细设计。

中国知网 https://www.cnki.net

6.2.1 日志采集模块设计

本系统所要采集的日志数据，大部分源自于应用在新闻客户端上的信息查询日志，但因为信息服务都部署在网络集群上，所以一旦采集到的日志数据还需要使用人工来整理的话，会严重地削弱了日志采集系统的使用性能。选取了 FLume 为日志采集的主要工具，FLume 代理可以配置到任何要采集日志的服务器上进行采集日志，然后把日志信息写在数据传输模块的消息队列中。但是，来自日志源的数据通常包含很多不必要的重复或丢失信息，这可能会影响我们今后的分析结果。为了进一步提高数据处理质量，保证计算精度，必须对原始数据进行预处理。最后保存在分布式数据库系统 HBASE 和 Kafka 中，保存到 Kafka 的数据分析一般是完成实时的大数据分析,而保存到 HBASE 的数据分析则一般是完成后期离线系统的大数据分析。为了实现 Hive 中的大数据分析，需要在 Hive 中设置临时表和分区表，并将 HBASE 中存储的历史数据临时保存在 Hive 的临时表中,以便于增加查询的有效性,将临时表的信息作为分组存放,以便于 Hive 对离线数据实施统计分析处理。该模块流程图如图 6-5 所示。

图 6-5 日志管理模块流程图

Figure 6-5 flow chart of log management module

中国知网 https://www.cnki.net

日志管理模块解决需求是日志数据通过 sink 存储到 HBASE 中，Flume 内置支持两种 HBASESink 和 AsyncHBASESink。AsyncHBASESink 使用了 AsyncHBASE API 来写 HBASE，这个 API 具有完全异步的，非阻塞的，线程安全的，高性能的特性。同时，如果 events 写入 HBASE 失败，那么此 sink 会 replay 失败事务中的所有 events。

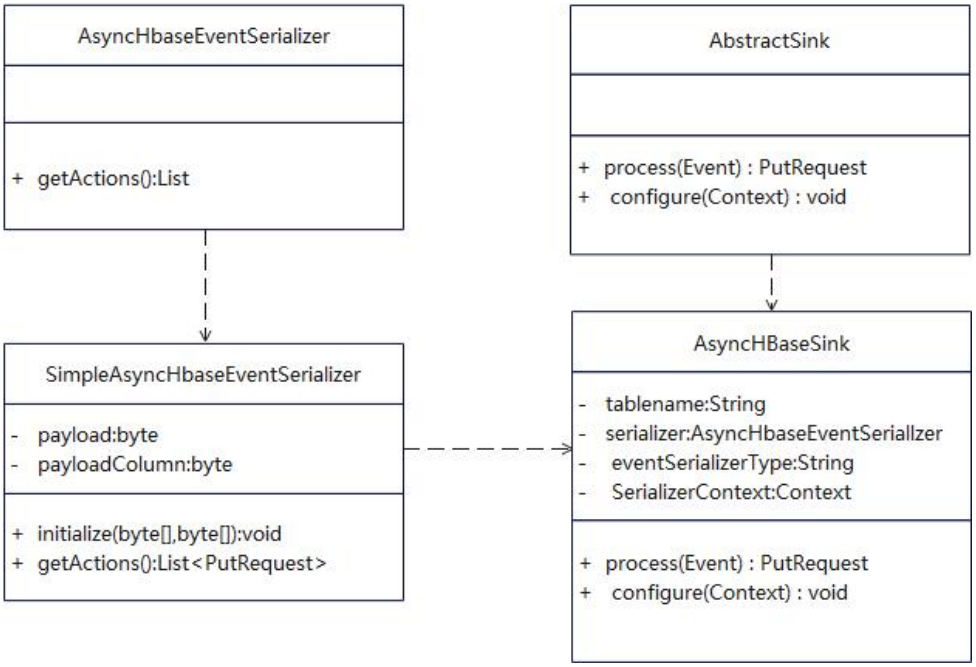

图 6-6 日志管理模块类图

Figure 6-6 Class diagram of log management module

这个类继承了 AbstractSink 这个抽象类，并实现了 Configurable 接口。主要关注下面三个字段：

（1）serializer：它的类型是 AsyncHBASEEventSerializer 接口,这个接口的作用就是让子类自己自由实现封装向 HBASE 发送数据的请求。也就是 getActions()方法。然后在 AsyncHBASESink 的 process 方法中调用 serializer.getActions()就可以得到这些请求，然后写到 HBASE 中。接口定义了如下方法：

（2）eventSerializerType： 这个就是用来从 flume 的配置文件中读取 serializer 参数。以确定使用哪个 AsyncHBASEEventSerializer 具体的实现类，然后通过反射，把 serializer 实例化成 eventSerializerType 所表示的类。

（3）serializerContext：这个字段是 Context 类型。在 flume 中，Context 内部存了一个 HashMap，保存的都是键对。所以我们可以把 Context 简单的理解为存储键值信息的一个类。通过反射实例化的 serializer 对象需要从配置文件中获取一些

中国知网 https://www.cnki.net

配置信息。所以这个对象相当于就是跟 serializer 捆绑在一起的。通过 putAll 函数把配置信息存进来。其中用到了 context 的 getSubProperties()方法。该模块的类图如图 6-6 所示。

FLume 框架中有着三个重要的组件，分别是 Source、Channel、和 Sink。日志数据的采集首先就需要对这三个组件进行配置。新闻日志分析系统数据量大，业务线多的特点，对数据采集的实现采用的是分层数据采集方法。

Source 组件负责从其他生产数据的应用中接收数据包装成事件，在本文中，如果需要获取本地文件中的日志数据，直接利用设计好的日志收集系统进行数据的收集。Source 组件类型中可以通过 ExecSource 组件来满足这样的日志收集需求。Exec Source 可以采集标准的数据格式，可以支持 linux 命令，并把本地日志文件中的数据封装成事件在 Flume 中流动。Exec Source 通过 tail-F 指令对文件系统进行监听，它能够动态将文件数据的变化写入数据日志中。

Flume 代理的 Channel 组件类似消息队列,为一次写入大量的数据做支撑，充当日志管理模块的缓冲区，缓解两个组件速度不对等的问题，起到保护作用。选取 Memory Channel 类型组件，可以看作是内存中的队列，运算在内存中，速度较快。

Flume 代理通过 Sink 将 Channel 中缓存的事件统一写入到数据传输模块 Kafka 消息队列，sink 能够将数据从缓冲区里面移除数据，Kafka Sink 在 process()方法中调用 Channel.take()方法从 Channel 中读取数据，sink 不断轮询 Channel 中的事件，将 Channel 的缓存数据写到数据存储文件中。用户不再需要自己编写实现将消息发布到 Kafka 和 HDFS。该模块时序图如图 6-7 所示。

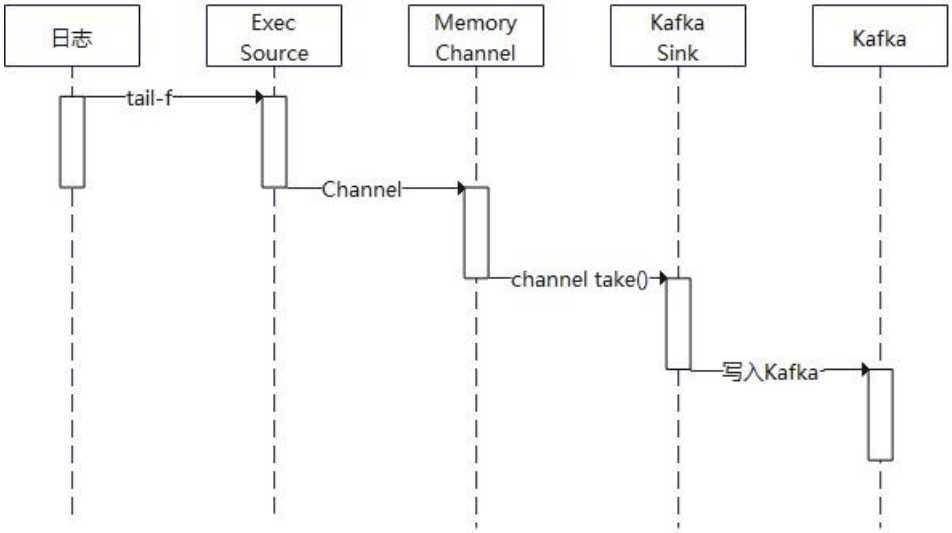

图 6-7 日志采集时序图

Figure 6-7 Log collection sequence diagram

中国知网 https://www.cnki.net

6.2.2 数据预处理模块设计

对于现有的很多原始数据，缺失信息，数据的重复，数据的冗余，数据的无效值，数据的界限都是现有很多数据集不可避免的问题，对于日志原始数据也不例外，正是因为这些低质量数据会影响后续分析结果。所以为了避免低质量数据，很多时候不得对原始数据进行预处理，使用相应预处理来提高数据的质量，并且对于实验的有效性的作用是很好的。数据预处理是数据分析和提取的前提。数据预处理的目的是消除重复信息，纠正数据错误。本文主要研究对于数据日志的一致性检查，以及当对于数据信息中的无效值进行的处理。

检查数据是否符合要求，数据值是否偏离逻辑现实，是否在规定的范围内，这些都是对于数据文件的一致性检测。日志包含大量不必要的空格或标签。我们用正则表达式代替这些不特定的数据。正则表达式提供了字符串匹配的模板。可以使用此模板检查字符串是否包含子字符串或替换子字符串。正则表达式通常用于查找与特定规则或样式匹配的文本。由于支持许多编程语言正则表达式（如 Java、Python 和 C#）来处理字符串，因此这种方法可以简单有效地应用于字符串。无法检查数据样例是否缺少字段信息，因为值处理错误。对于丢失的记录值，采取删除整个案例的方法，即记录方法的记录值为 0。该模块流程图如图 6-8 所示。

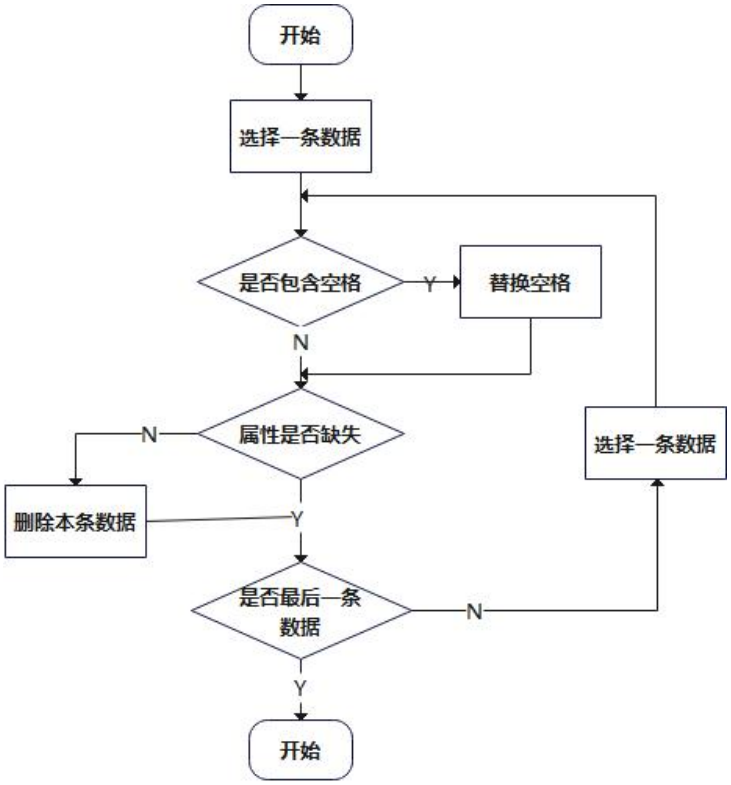

图 6-8 数据预处理流程图

Figure 6-8 Flow chart of data preprocessing

中国知网 https://www.cnki.net

日志数据的清洗部分主要由 LogClean 组件和 Mapper 组件组成。Mapper 组件主要是用于离线日志处理后的数据更新。LogClean 组件主要是用于对日志数据进行清洗。在 LogClean 中通过 logparse 方法实现对离线日志数据的解析，对于初始的离线日志数据首先需要将日志数据类型转换成 String 数据类型，这样对后续的数据分析计算有很大帮助，然后按照各个字段的不同含义，利用正则表达式对日志数据进行拆分和解析。该模块类图如图 6-9 所示。

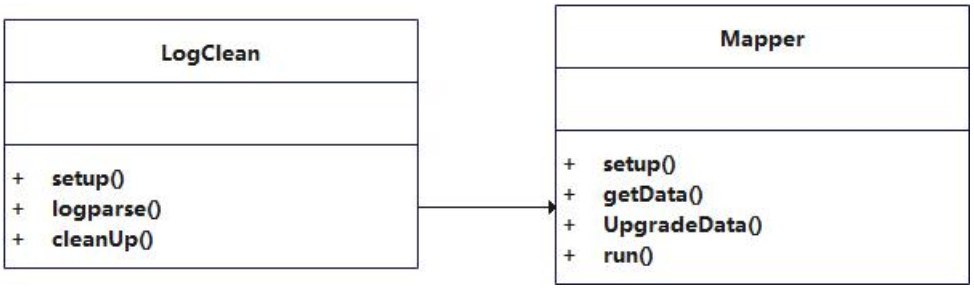

图 6-9 数据清洗类图

Figure 6-9 Flow chart of shopping cart module

6.3 日志分析模块

本节对日志统计从实时新闻日志数据分析和离线新闻日志分析进行详细的设计与实现。本节将通过流程图、类图、时序图对日志分析模块进行详细设计。

6.3.1 实时分析

实时分析新闻日志是一个对时效性要求很强的部分。按照每 5 秒一次的轮训，对搜索日志新闻访问情况进行统计，获取 Kafka 集群中 Topic 存储的数据流，不断更新数据库中的结果，从而实现对用户的话题总数和热门话题的实时统计功能。当新闻板块总体流量异常时，通过新闻板块实时的查看可以迅速找到一场产生的原因。流量的计算是通过单位时间内该内容的点击次数来计算的。通过采集到的数据进行聚合计算处理实现流量的统计。

本系统进行实时分析最直接的是对于新闻 APP 中的基础数据包括新闻的阅读量、点赞量、评论量、转发量、投币量、粉丝量，进行总体流量进行监控和分析，保证服务器支持突发的流量数据。采用的方法是通过 Spark Streaming 进行实现的。

中国知网 https://www.cnki.net

对实时新闻日志进行数据分析首先需要对 Kafka 流式数据进行读取。Spark Streaming 对 Kafka 流式数据的处理方式有两种。一种是通过接收器（Receiver）实现，另一种是直接实现 Kafka 数据的拉取。对于实现数据的实时处理，主要通过通过 Receiver 的方式。为了实现对于不同的 Group 和 topic 的数据并行操作，因此就创建多个 DStream 是有必要的，在最后将所有的 DStream 通过 union 方法统一。但是接收器接收信息存在着一个问题，在任务创建失败时，会造成数据的丢失，因此需要开启 WAL（WriteAheadLogs），而通过直接拉取实现对 Kafka 数据拉取的好处在于，在 DirectStream 中，Kafka 的 partition 与 RDD 的 partition 是直接对应的，这种映射的关系也更加的直接。所以新闻日志分析系统选择直接对 Kaka 流式数据拉取。对于消费者而言，在消费者眼里 Spark Streaming 使用 reduceByAndWindow()方法，就是利用指定窗口时间长度和滑动时间的间隔，最后将流量相关的数据进行统计并显示结果。该模块时序图如图 6-10 所示。

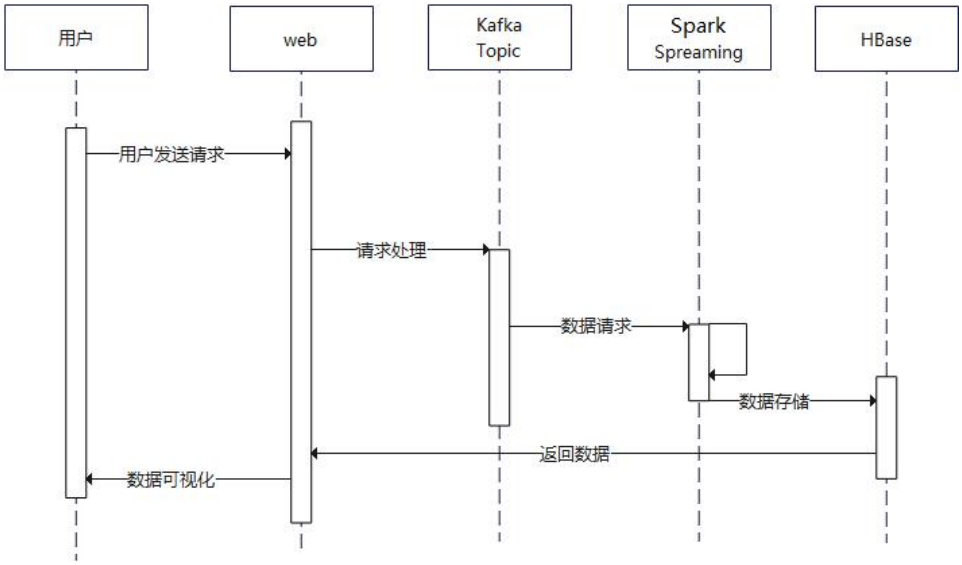

图 6-10 实时分析时序图

Figure 6-10 Real time analysis sequence diagram

对数据读取后，首先需要将接收到的服务上的消息队列生成 DirectkafkaDStream 类，DirectkafkaDStream 继承自 InputDstream，InputDstream

继承自 DStream，DStream 是一种离散型数据集，在 Spark Streaming 通过 StreamingContext 进行实例初试化，通过 CreateNewSparkContext 创建 CreateNewSparkContext 对象，同时初始化 DstreamGraph 对象，DStream 是 Spark Streaming 中所有数据流的抽象。Dstream 的本质是一段连续的 RDD，它可以实现对 RDD 的批次处理，并且它和 RDD 有着相同的 transmation 操作。通过 Dstream

中国知网 https://www.cnki.net

操作实现对 RDD 数据集的批量操作。在 Dstream 通过调用 ReceiverInputDStream 生成 InputDStream 对象，对 InputDStream 对象调用 ForEachRDD 方法，将离散化数据集转换成 RDD 数据结构。生成新的 RDD 对 RDD 数据结构通过 Sparksession.SparkContext 进行实例化。转换成 DataFrame 数据格式，最后通过调用 DataFrame 中 filter 方法的实现新闻日志数据的聚合统计。将处理好的实时新闻日志数据进行存储。该模块类图如图 6-11 所示。

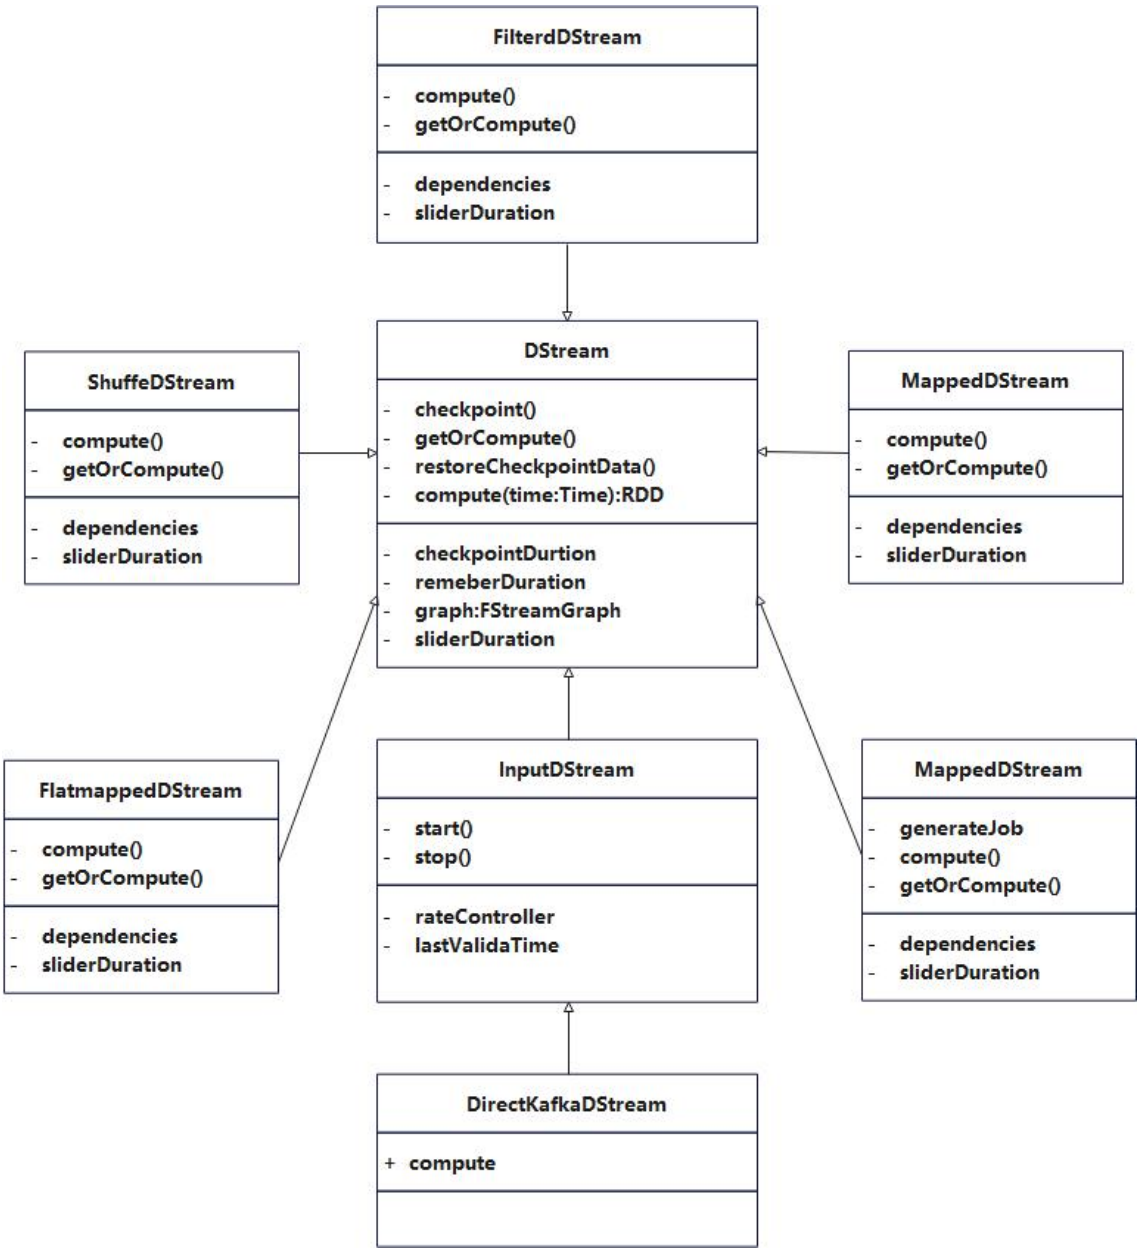

图 6-11 实时分析类图

Figure 6-11 Real time analysis class diagram

中国知网 https://www.cnki.net

6.3.2 离线分析

离线分析模块查询并统计相应的日志数据信息。查询内容包括每个时段的用户数量、热门点击的新闻主题，对于 MySQL 的作用就是将搜索到的结构保存。本部分主要结合 Hive、Spark SQL 等技术组件，实现历史数据的多维分析。对于一个整体，总的来说，Hive 在网络外的分析信息方面具有相当的优势。但是，考虑到作为计算引擎使用的映射的冗余性，从搜索返回整个搜索需要很长时间。Spark 的技术团队开发了 Hive 用来弥补这个缺陷。Spark 上的配置模块是请求将配置模块置换为 Spark 的执行器，即用 Spark 作业替换 Map Reduce 作业。这样，通过使用基于 Spark 内存的计算，缩短 HIVEQL 响应时间。此框架将 Hive 保存到 sql 语句的分析和优化中，Spark 用于执行任务。配置单元上下文是 Spark 提供的用户界面，用于访问和查询配置单元中的数据。脱机日志的数据分析部分需要通过配置单元进行脱机计算。离线数据的计算是按照小时和天进行的。该模块时序图如图 6-12 所示。

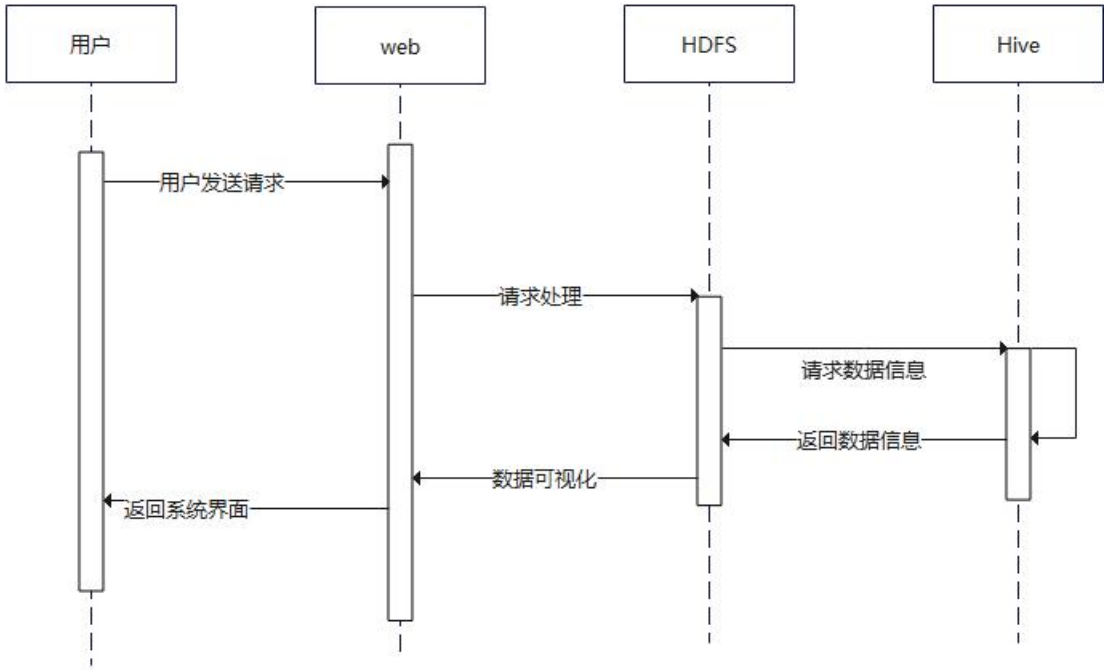

图 6-12 离线分析时序图
Figure 6-12 Offline analysis sequence diagram

在对离线数据进行分析时，需要对一部分数据进行处理，利用 Hive 的内置分

中国知网 https://www.cnki.net

区管理器、字符串捕获函数的子处理器和格式转换函数的转换允许以统一的时间格式处理传输的时间参数。时间过滤器。在过滤数据时，可以使用子查询和连接。最后通过 Insert Overwrite 将处理后的数据插入到结果表中。

接下来是对离线新闻日志数据的指标分析过程中，对新闻日志需要重点关注新闻的点击量、访问量。该模块类图如图 6-13 所示。

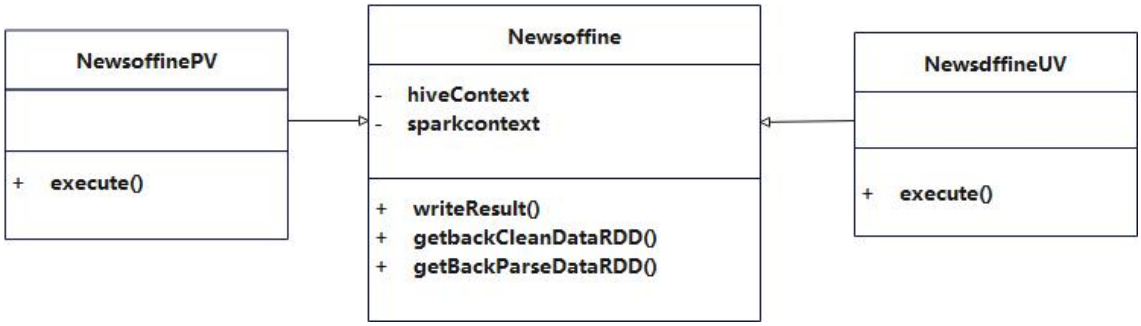

图 6-13 离线分析类图

Figure 6-13 Offline analysis class diagram

它是由 Newsofflinr 组件、NewsofflinePV 组件、NewsofflineUV 组件构成，Newsoffline 是离线新闻日志指标分析中的所有计算的父类。在类中声明了子类在计算过程中都需要用到的 HiveContext 对象和 SparkContext 对象。HiveContext 对象是计算的引擎。NewsofflinePV、NewsofflineUV 是离线日志指标的计算类型，分别对所设置的字段进行计算。计算逻辑在 execute 方法中实现。

6.4 数据挖掘模块

数据挖掘模块包括新闻分类、新闻聚类、协同过滤推荐三大功能。本节将通过流程图、模型训练、模型优化对数据挖掘模块进行详细介绍。

6.4.1 日志数据分类具体设计与实现

通过朴素贝叶斯算法实现查询分类功能。由于分类的学习过程是一种有监督的学习，因此需要通过训练建立分类器，获取训练样本以确定特征属性，计算每个类别，对于每个特征属性，及其它相应的所有划分条件概率进行计算，并选择概率最大的值作为最终分类预测。该模块流程图如图 6-14 所示。

中国知网 https://www.cnki.net

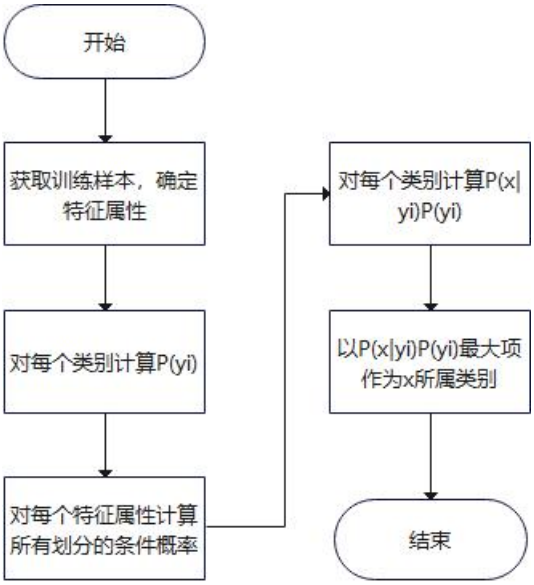

图 6-14 贝叶斯分类流程图

Figure 6-14 Bayesian classification flow chart

分类模型创建。读取分类数据集，我们使用首先使用 Spark 方法。该数据集 tran.tsv 和 test.tsv 的第 3 个字段是 alchemy_category 网页分类，是一个离散值特征，要采用 OneHotEncode 的方式进行编码转换为数值特征，其中，lines.map()表示处理之前读取的数据的每一行，map()表示读取相应字段，distinct()保留不重复数据，zipWithIndex()将第 3 个字段中不重复的数据进行编号，collectAsMap()转换为 dict 字典格式，对数值特征进行标准化。接着划分训练集、验证集及测试集。Spark Mllib 封装了 NaiveBayes 朴素贝叶斯分类器，其 train()方法训练模型，并且当我们进行模型保存的时候，使用 save()方法。分类数据集样式如下表 6-1 所示。

表 6-1 数据分类

Table 6-1 Data classification

标记	种类	标记	种类
0	动物	5	健康
1	汽车	6	财经
2	IT	7	体育
3	军事	8	教育
4	政治	9	科学

模型参数调优，对于某个数据集，我们考虑到对于某个特征 X 在训练集中没有出现，那么将会导致整个分类概率变为 0，这将会导致分类变得非常不合理，所以为了解决零概率的问题，用加 1 的方法估算没有出现过的现象,假定训练样本很

中国知网 https://www.cnki.net

大时，每个分量 x 的计数加 1 造成的影响可以忽略不计，但能够方便有效的避免零概率问题。NaiveBayes 朴素贝叶斯分类器就一个参数：拉普拉斯平滑因子 lamba 创建 trainEvaluateModel 函数包含训练与评估功能，并计算训练评估的时间。

表 6-2 模型性能表现

Table 6-2 Model performance

模型评估	数值
准确率	0.8816
精准率	0.8858
召回率	0.8816

模型的加载。使用最佳参数组合对 test.tsv 中的数据进行预测，使用 filter()函数提出字段名，取数据行，完成测试数据集的预处理，调用 map()函数进行数据标准化，最后调用。调用 NaiveBayesModel 类的 Fit()函数创建标准实例，完成模型加载。Load()方法使用数据预测方法对查询主题进行分类。

6.4.2 日志数据聚类具体设计与实现

使用 k-means 算法执行日志据聚类的功能。作为无监督学习的过程，k-means 主要通过不断地取离种子点最近均值的算法。k-means 算法的一个缺点是它对质心或均值的初始化很敏感。如果聚类的质心点选择不当，最终会导致聚类的质量非常糟糕。重点在于初始质心的选择，模型训练也是选出 K 个最优聚类中心方可结束。该模块流程图如图 6-15 所示。

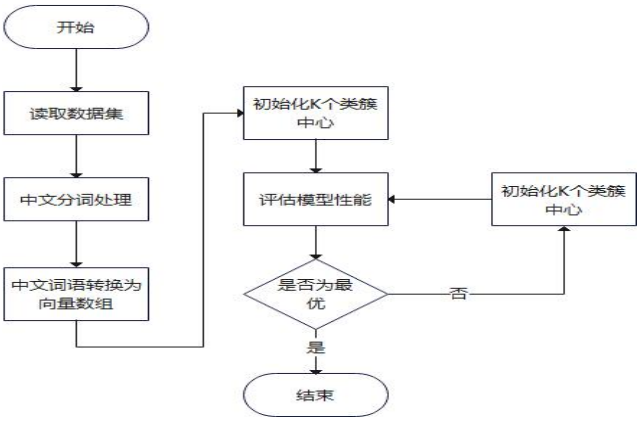

图 6-15 Kmean 聚类流程图

Figure 6-15 kmean clustering flow chart

中国知网 https://www.cnki.net

数据预处理。使用 ToAnalysis.parse(str)将字符串进行分词，会返回一个 Result，分词的结果就在它里面。然后继续 result.getTerms()获得分词结果的内容，因为是返回的多个分词，所以最终获得的是一个 List。然后遍历它，term.getName()获得的是词，term.getNatureStr()拿到的是这个词的词性。进行预处理操作，采用的是中文数据集。

特征值提取。预处理之后，查询的话题变成独立的单词，为了更好地寻找主题的含义，进行数据分析是必不可少的，一般来讲 IF-IDF 空间矢量模型是进行数据分析重要的攻击，首先对于每个词的权重的计算，其次将加权操作应用于每个缺陷词条。HashingTF 是一个 Transformer，接收词条的集合然后把这些集合转化成固定长度的特征向量。这个算法在哈希的同时会统计各个词条的词频。IDF 是一个 Estimator，在一个数据集上应用它的 fit()方法，产生一个 IDFModel。该 IDFModel 接收特征向量（由 HashingTF 产生），然后计算每一个词在文档中出现的频次。IDF 会减少那些在语料库中出现频率较高的词的权重，完成权重调节的计算。

分词处理。在进行中文分词处理的时候，把数据集随机划分为训练集和测试集，训练集用于模型训练，测试集用于检验模型的优劣，random_state 参数是指定随机种子。我们使用 jieba 库进行分词,并以空格把分词连成字符串。CountVectorizer 旨在通过计数来将一个文档转换为向量。当不存在先验字典时，Countvectorizer 作为 Estimator 提取词汇进行训练，并生成一个 CountVectorizerModel 用于存储相应的词汇向量空间。使用 CountVectorizer 把分词后的新闻文本转为向量数组。

聚类模型创建。一般来讲对于话题的查询，我们使用 KMeans 类进行聚类分析。具体流程是首先对从数据中心选择样本。初始化群集中心的基本原则是尽可能远离群集中心。计算每个采样点到初始化中心的距离，然后选择最短距离。选择最大距离点作为新群集的中心。如果计算的新中心点与原始中心点相同（重心不再移动），则结束，通过使用 fit()方法生成聚类模型，最终生成具有预测值的数据帧数据,使用的方法是 transform()方法。

参数调优。不像监督学习的分类问题和回归问题，无监督聚类没有样本输出，也就没有比较直接的聚类评估方法。聚类的效果可以从聚类内的密度程度和聚类间的分散程度来评估。常见的方法有轮廓系数 Calinski-Harabasz Index，在聚类数 k 类数的增加，选择性除法将进一步细化，各级集中度将逐步提高,这个计算简单直

中国知网 https://www.cnki.net

接，获得的 Calinski-Harabasz 分数值 s 越大则聚类效果越好。参数调优过程如下图。

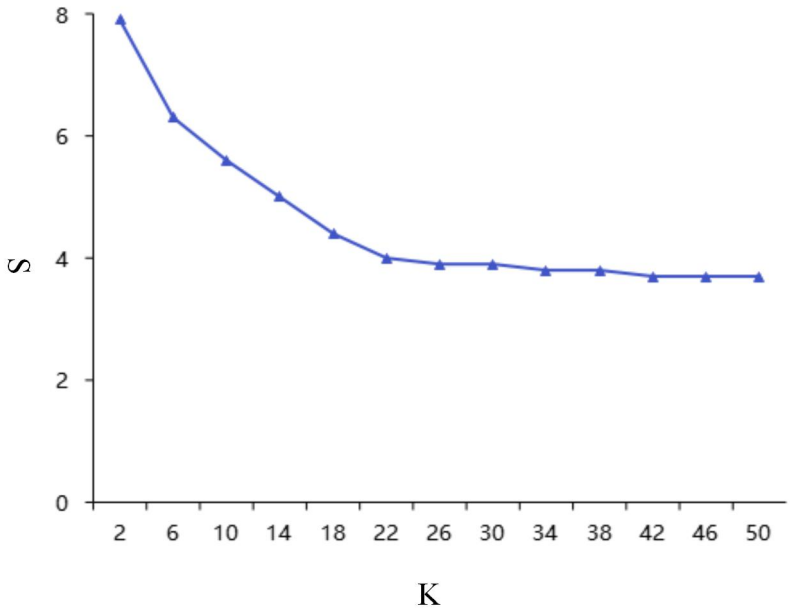

图 6-16 参数调优
Figure 6-16 Parameter tuning

6.4.3 日志数据协同过滤推荐具体设计与实现

对于日志数据协同过滤推荐，在网站上记录用户行为的最简单的形式例如，在浏览网页，点击次数，意见和新闻评论评分，用户有不同的行为。在个性化推荐系统中，用户的行为通常被定义为显性反馈行为和隐性反馈行为。显隐性反馈区别如表 6-3 所示：

表 6-3 显性/隐性反馈区别
Table 6-3 Dominant / implicit feedback distinction

	显性反馈数据	隐性反馈数据
用户兴趣	明确	不明确
数量	较少	庞大
存储	数据库	分布式文件系统
实时读取	实时	有延迟
正负反馈	都有	只有正反馈

中国知网 https://www.cnki.net

表 6-4 显性/隐性反馈数据

Table 6-4 Dominant / implicit feedback data

	显性反馈	隐性反馈
视频网站	用户对视频评分	用户查看视频日志并在视频页面上导航日志。
门户网站	用户对新闻的评分	阅读新闻的日志
电子商务	用户对音乐的评分	听歌的日志

显性反馈行为表示用户的行为明显相关的意见。显性反馈行为包括用户明确表示对新闻喜好的行为。从网站收集显性反馈数据是得到明确的评论的主要方法是评价或不喜欢。隐式反馈行为最常见的行为是浏览页面。根据反馈信息的清晰度，用户行为可以分为主要的显性反馈和隐性反馈。正反馈意味着用户的行为倾向于表示用户喜欢新闻信息，而负反馈意味着，用户的行为趋向于表示用户不喜欢新闻信息。反馈数据如表 6-4 所示。在显式反馈中，很容易区分用户的行为是正反馈还是负反馈，而在隐式反馈中则相对难以确定。该模块流程图如图 6-17 所示。

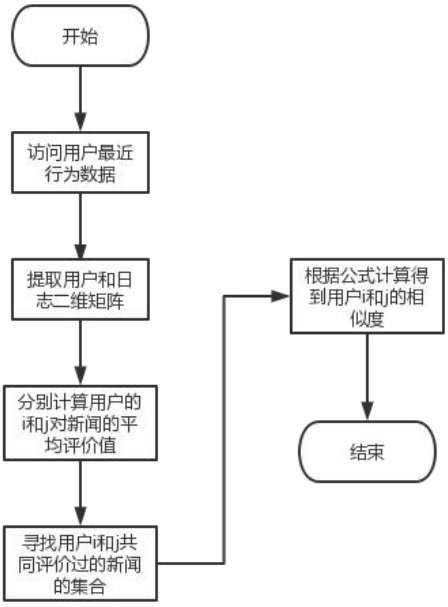

图 6-17 协同过滤推荐流程图

Figure 6-17 Recommended flow chart of collaborative filtering

6.5 可视化模块

可视化模块的主要功能是向业务人员准确、及时、清晰地显示日志数据分析结果。可视化功能可帮助您确定可视化检查系统是否有效工作。在该模块中，我们设计了显示日志数据显示、离线交通日志数据，实时日志数据和分类聚类结果

中国知网 https://www.cnki.net

显示。通过使用饼图、柱状图、折线图、词云图等图表进行统计分析并展示出来，操作人员可以更清晰、完整、快速地了解用户行为分析结果。

6.5.1 日志信息展示

业务人员登录统计数据显示模块后，进入日志显示界面，系统调用 chart_ log() 方法从 HBASE 读取日志数据。日志展示功能的时序图如图 6-18，日志展示功能的界面见 6-19。

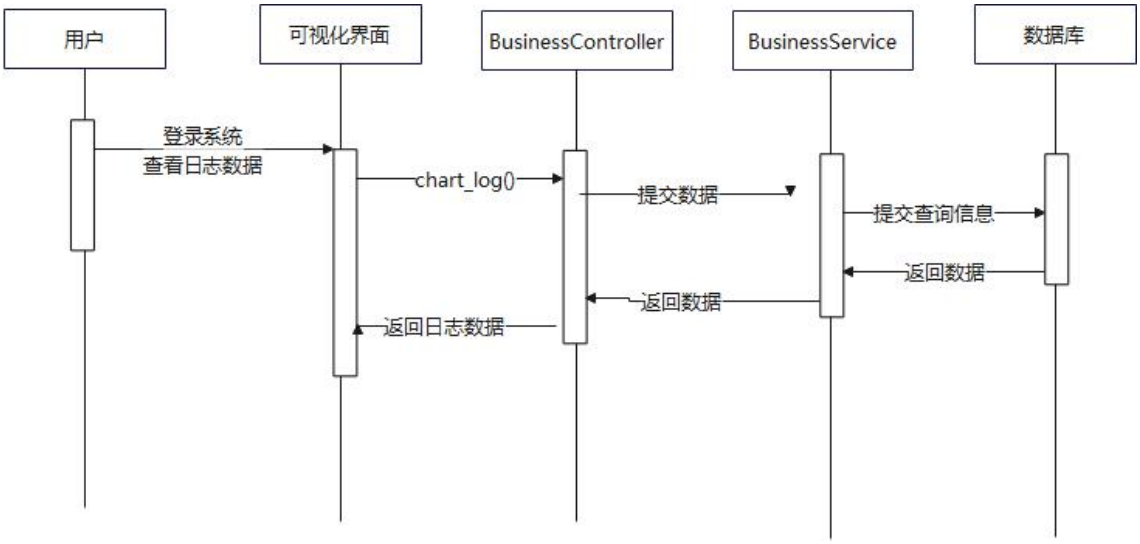

图 6-18 日志信息展示时序图

Figure 6-18 Log information display sequence diagram

```
1  00:00:00  2982199073774412  [360安全卫士]  8 3  download.it.com.cn/softweb/software/firewall/antivirus/20067/
2  00:00:00  0759422001082479  [哄抢救灾物资]  1 1  news.21cn.com/social/daqian/2008/05/29/4777194_1.shtml
3  00:00:00  5228056822071097  [75810部队]  14 5  www.greatoo.com/greatoo_cn/list.asp?link_id=276&title=%BE%DE%
4  00:00:00  6140463203615646  [绳艺]  62 36  www.jd-cd.com/jd_opus/xx/200607/706.html
5  00:00:00  8561366108033201  [汶川地震原因]  3 2  www.big38.net/
6  00:00:00  2390814038614871  [莫衷一是的意思]  1 2  www.chinabaike.com/article/81/82/110/2007/2007020724490.htm
7  00:00:00  1797943298449139  [星梦缘全集在线观看]  8 5  www.6wei.net/dianshiju/????\xa1\xe9|????do=index
8  00:00:00  0071772592458284  [闪字吧]  1 2  www.shanziba.com/
9  00:00:00  4141621901895211  [霍震霆与朱玲玲照片]  2 6  bbs.gouzai.cn/thread-698736.html
10 00:00:00  9975666857142764  [电脑创业]  2 2  ks.cn.yahoo.com/question/1307120203719.html
11 00:00:00  2160337461907744  [111aa图片]  1 6  www.fotolog.com.cn/tags/aa111
12 00:00:00  7423866288265172  [豆腐的制成]  3 13  ks.cn.yahoo.com/question/1406051201894.html
13 00:00:00  0616877776407358  [tudou.com+禁播电影]  2 9  topic.bindou.com/1487/
14 00:00:00  3933365481995287  [最佳受孕时间]  6 3  ks.cn.yahoo.com/question/1407051001276.html
15 00:00:00  8242389147671512  [捷克民歌土风舞++教案]  2 3  shwamlys.blog.sohu.com/76558184.html
16 00:00:00  8248403977107859  [pdf]  1 1  download.it168.com/18/1805/13947/13947_3.shtml
17 00:00:00  6239728533154822  [喷嚏乐团lonely+day]  7 9  www.songtaste.com/song/266563/
18 00:00:00  6551182914925117  [尼康相机报价]  6 4  product.it168.com/list/b/03050171_1.shtml
19 00:00:00  2345161545038265  [哄抢救灾物资]  2 1  pic.news.mop.com/gs/2008/0528/12985.shtml
```

图 6-19 日志展示

Figure 6-19 Log display

中国知网 https://www.cnki.net

对于离线分析来讲，除了记录用户的查询日志表，用户数据表，查询话题分类表和离线话题汇总表一般被存储在 MySQL 数据库，因为他们的数据量不大。由于 Hive 需要进行联表查询，它们必须传递到 Hive 中去，Hive 查询结果如图 6-20 所示。

```
Total MapReduce CPU Time Spent: 11 seconds 150 msec
OK
searchlogs.searchname   count
[哄抢救灾物资]  958
[汶川地震原因]  885
[封杀莎朗斯通]  287
[印尼排华是怎么回事]    270
[杨丞琳辱华惨痛下场]    132
[朝鲜能不能打败韩国]    106
[gay]   96
[印尼残害女华人+图片]   91
[杨丞琳辱华事件]        90
[莎朗斯通+免费电影]     88
```

图 6-20 Hive 查询日志结果图

Figure 6-20 Hive query log result diagram

6.5.2 热点新闻展示功能实现

业务人员登录系统后，可以选择查看实时新闻排行，系统会调用 topicAll()方法从 Kafka 中调取监控的 Topic 列表，统计当前热门新闻的点击率，每隔 5 秒刷新。Chart_top()方法对应从数据库表中读取数据并绘制成柱状图。

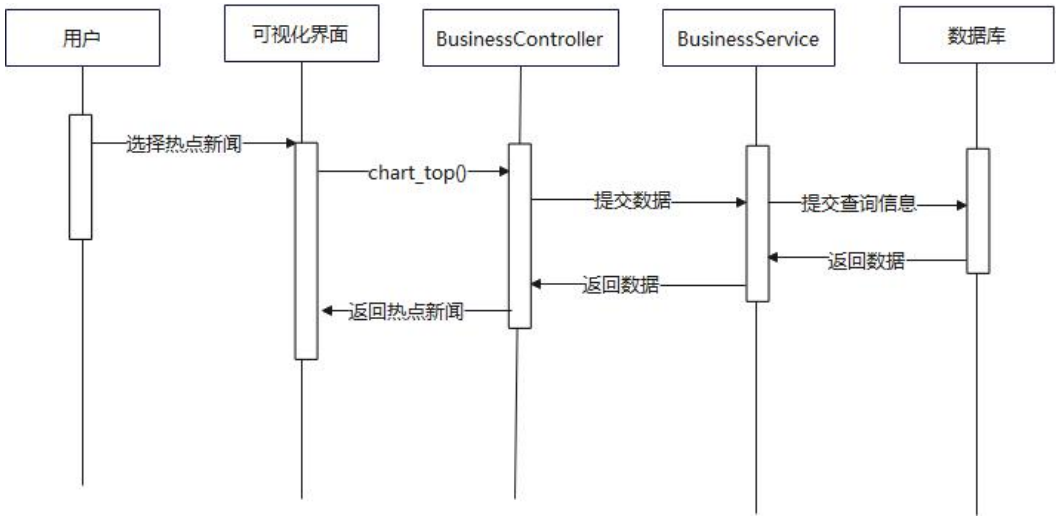

图 6-21 热点新闻时序图

Figure 6-21 Sequence diagram of hot news

中国知网 https://www.cnki.net

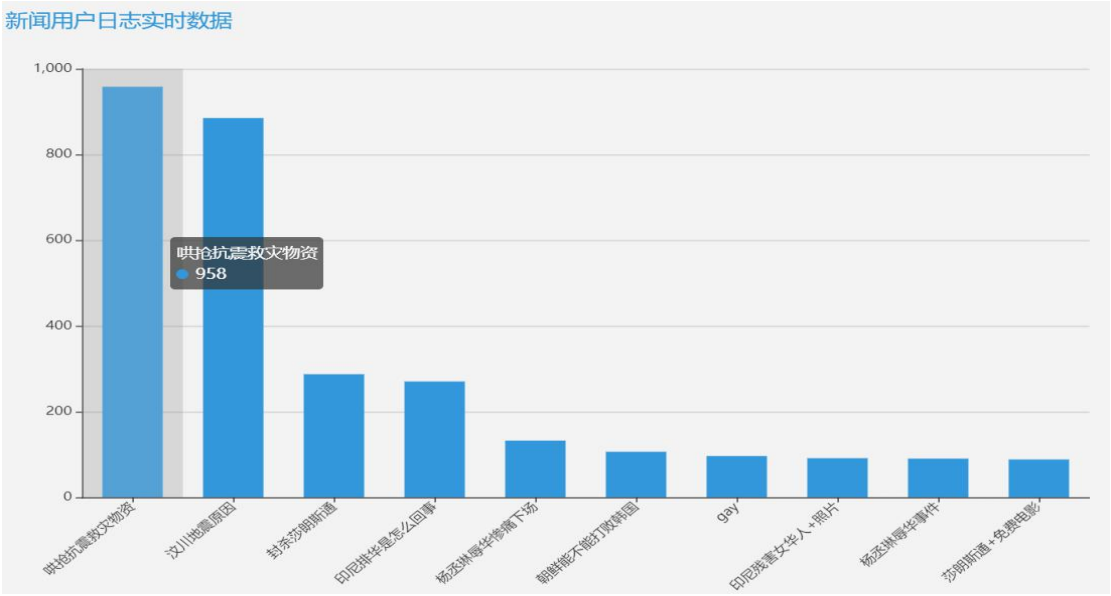

图 6-22 热点新闻展示

Figure 6-22 Hot news display

6.5.3 实时话题统计展示

统计热点新闻之后，业务人员可以进一步查看新闻话题总体数量，模块调用chart_all()方法从数据库表中读取并绘制成饼状图。每隔 5 秒刷新话题数量，便于业务人员监测话题投放。热点新闻的展示功能的时序图如图 6-23，界面见图 6-24。

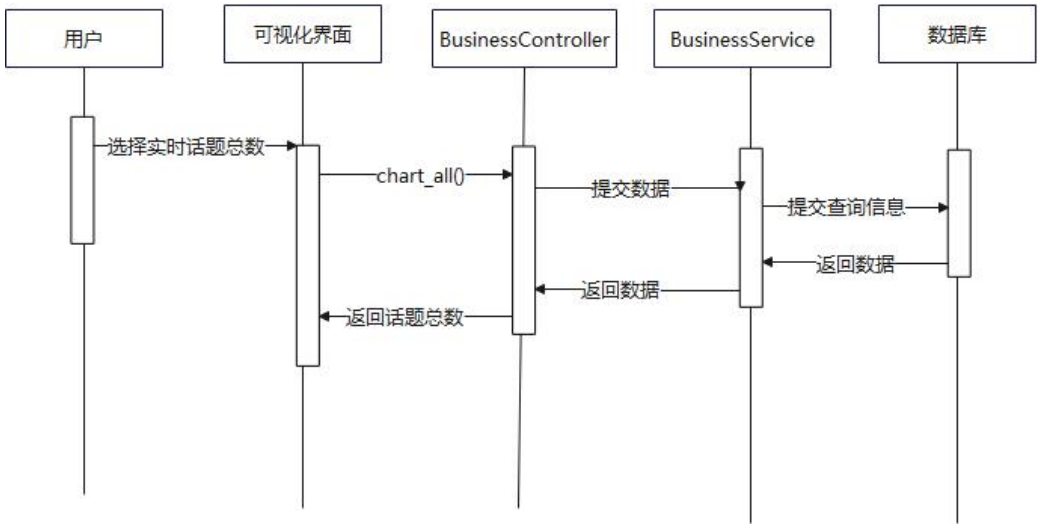

图 6-23 新闻话题统计时序图

Figure 6-23 Timing chart of news topic volume

中国知网 https://www.cnki.net

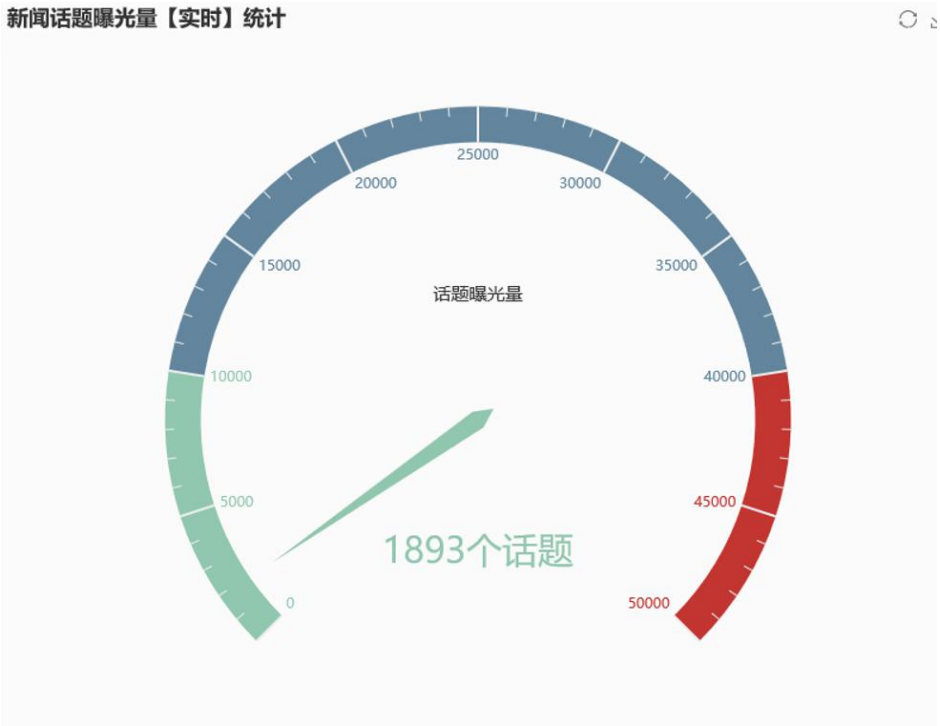

图 6-24 新闻话题统计展示

Figure 6-24 Display of news topics

6.5.4 实时搜索时段流量展示

查看实时话题统计之后业务人员可以自定义查看实时时段流量情况，系统需要调用 chart_partition()方法从数据库中读取实时新闻流量中点击量绘制成玫瑰图进行展示。搜索时段流量的展示功能的时序图如图 6-25，界面在图 6-26。

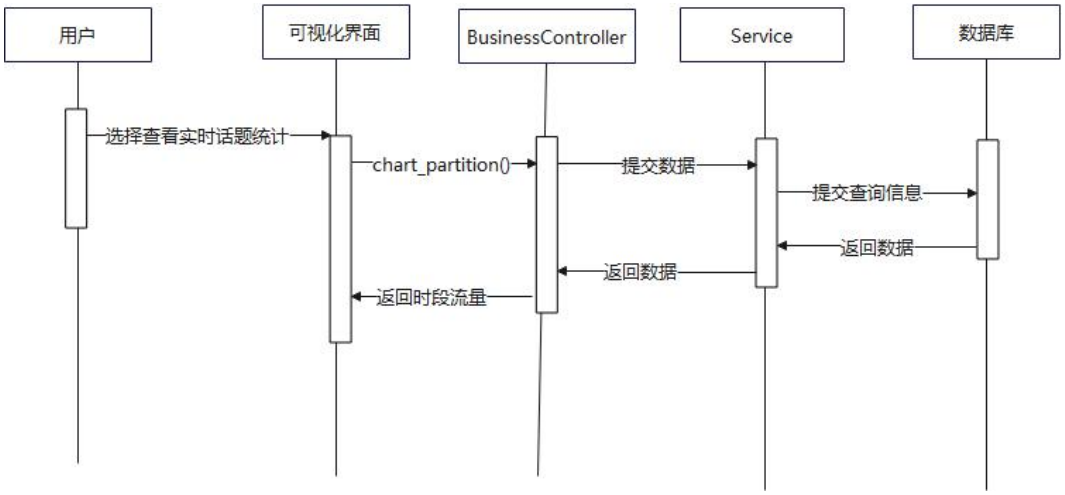

图 6-25 搜索时段流量流程图

Figure 6-25 Search time period traffic flow chart

中国知网 https://www.cnki.net

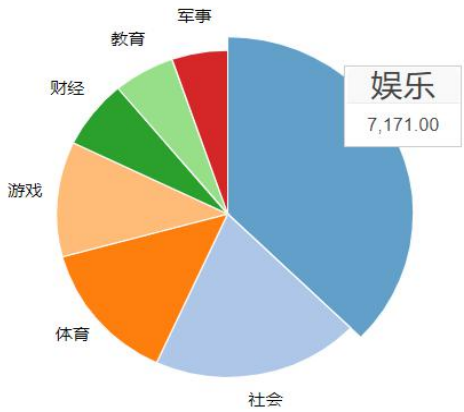

图 6-26 搜索时段流量时序图
Figure 6-26 Flow timing chart in search period

6.5.5 话题点击最优 rank 频率展示

业务点击实时新闻分析之后，可以查看话题点击 rank 频率，即查看该 URL 在返回结果中的排名为 1，且用户点击的顺序号为 1 的条目总数。调用 chart_rank() 方法，这样系统读取实时新闻流量中总话题量绘制成折线图进行展示，是通过调用数据库的方法获取。话题点击最优 rank 频率的展示功能的时序图如图 6-27 所示，界面和话题点击最优 rank 频率展示在图 6-28。

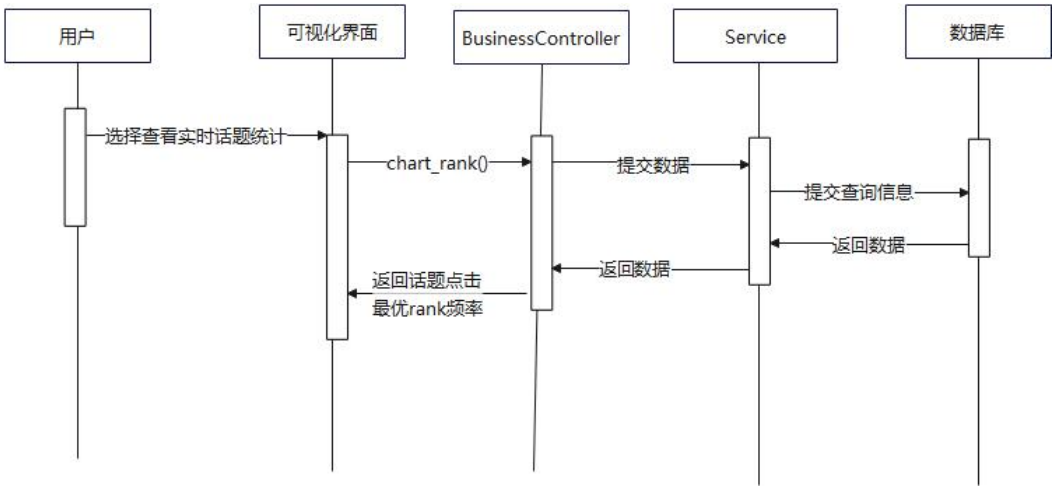

图 6-27 话题点击最优 rank 频率时序图
Figure 6-27 Timing chart of optimal rank frequency of topic Click

中国知网 https://www.cnki.net

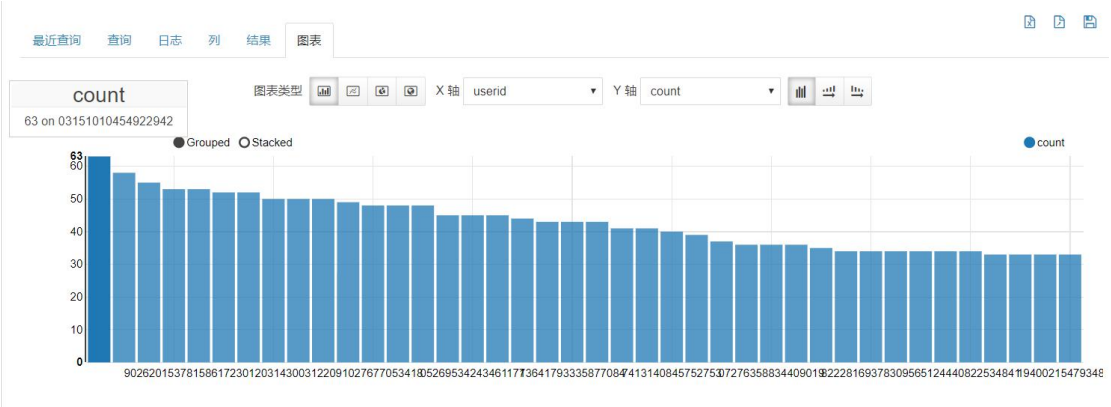

图 6-28 话题点击最优 rank 频率展示

Figure 6-28 Display of optimal rank frequency of topic Click

6.5.6 搜索关键字词模块展示

离线分析板块提供搜索关键字词模块，系统需要调用 chart_wordcloud()方法从数据库中读取离线日志流量中总话题搜索关键字词，利用 python 展示了绘制成词云图，用的是 wordcloud 库。关键字词展示功能的时序图与界面分别如图 6-29 和 6-30 所示。

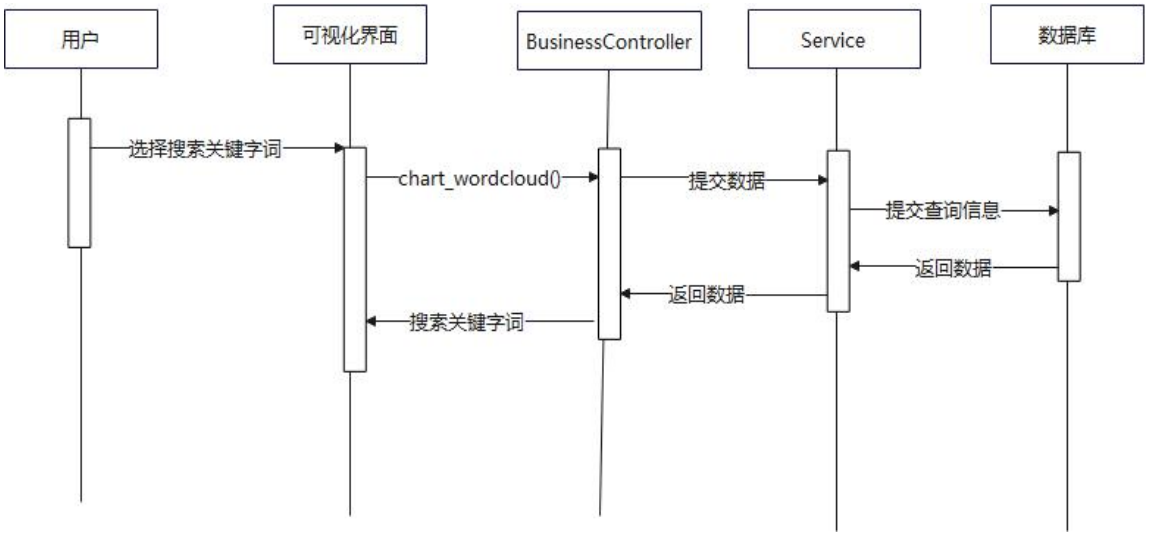

图 6-29 搜索关键字词时序图

Figure 6-29 Sequence diagram of searching key words

中国知网 https://www.cnki.net

图 6-30 搜索关键字词云词图

Figure 6-30 Search keyword cloud

6.5.7 离线搜索时段流量展示

离线分析提供离线时段分析，系统需要调用 chart_olpartition()方法从数据库中读取实时新闻流量中总话题量绘制成折线图进行展示离线搜索时段流量的展示功能的时序图见如图 6-31，离线搜索时段流量展示界面见 6-32 所示。

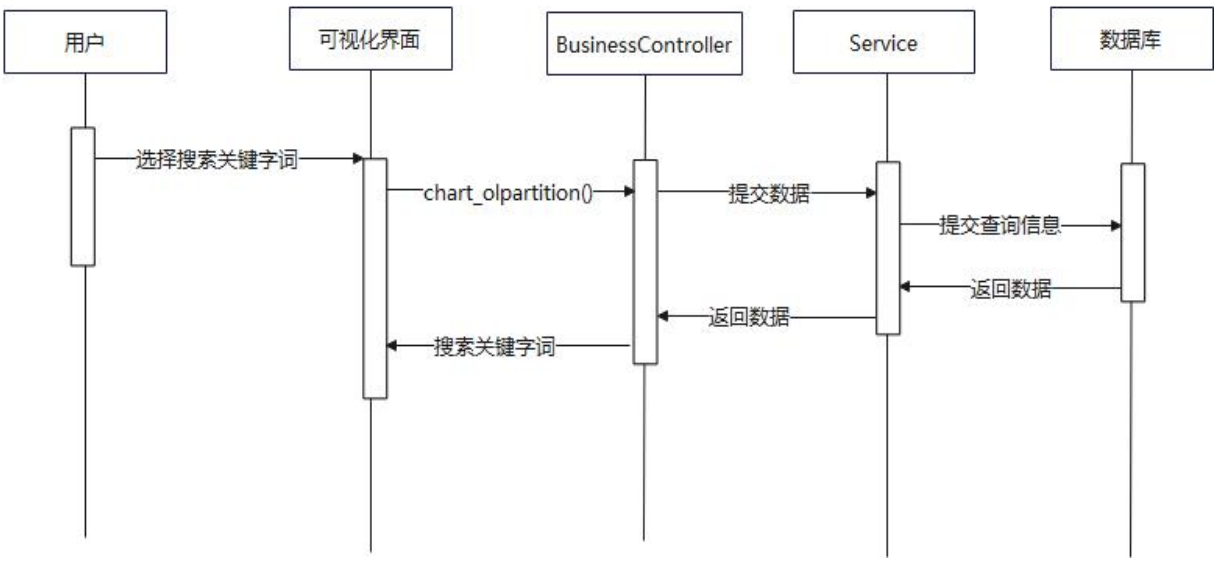

图 6-31 离线搜索时段流量时序图

Figure 6-31 flow sequence diagram during offline search period

中国知网 https://www.cnki.net

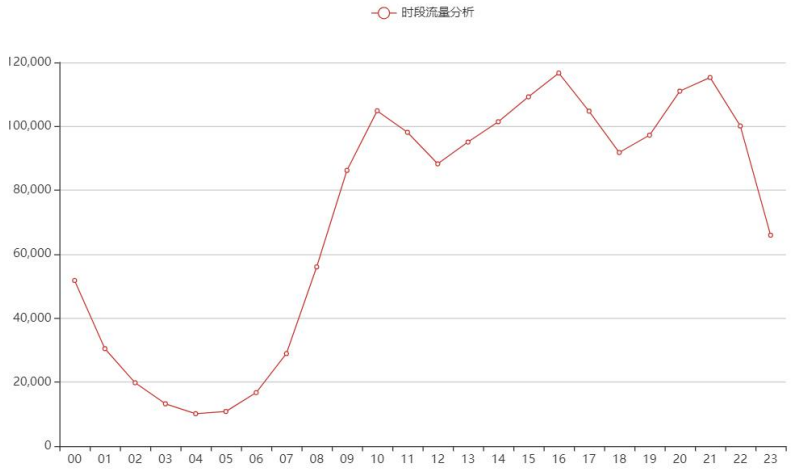

图 6-32 离线搜索时段流量展示

Figure 6-32 traffic display in offline search period

6.5.8 实现效果图

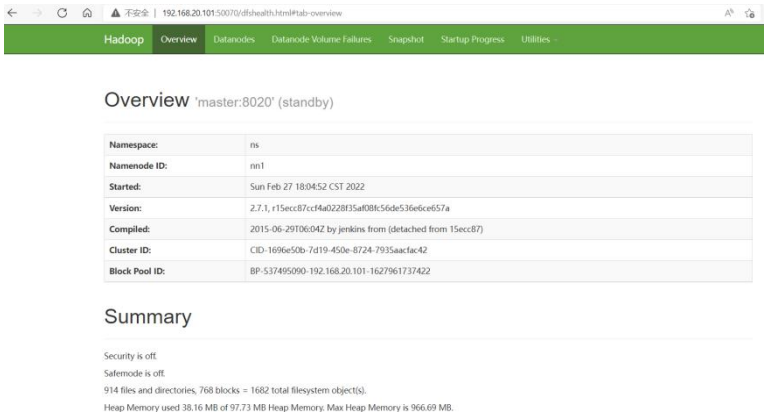

图 6-33 HDFS

Figure 6-33 HDFS

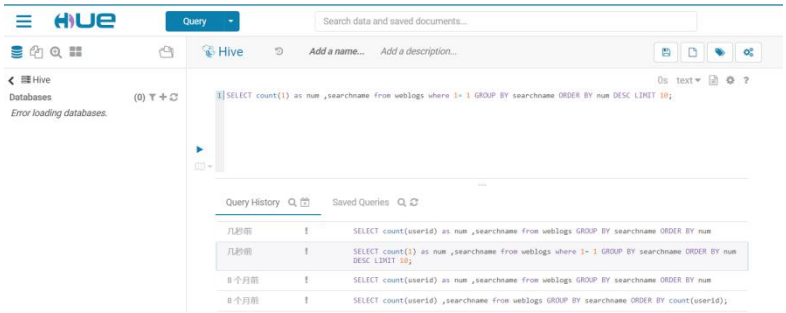

图 6-34 HIVE 可视化面板

Figure 6-34 Hive visualization panel

中国知网 https://www.cnki.net

图 6-35 朴素贝叶斯分类

Figure 6-35 Naive Bayesian classification

6.6 本章小结

本章介绍了日志内容采集系统各主要功能模块的详细实现过程，并着重介绍了功能模组如用户数据管理模块、日志管理系统模块、大数据分析模块、数据挖掘模组以及可视化模型以及一些占比十分重要的技术如 Spark、Flume 和 Kafka 等被这些模块所使用。通过时序图、流程图与类图、实现界面等方式进行描述。本章提供了一个有效的日志整理方法，对解决实际问题有重要帮助。

中国知网 https://www.cnki.net

7 系统测试

本文提出的日志数据分析处理平台不仅能够通过测试用例发现系统开发过程中存在设计、接口或代码上的问题，也能够判断系统是否符合用户需求，从而及时改进以保证系统的高质量。本章将主要从系统的测试环境，功能性测试以及非功能测试三个方面展开介绍。

7.1 开发环境

表 7.1 显示了平台开发中使用的环境名称和硬件配置的版本。已在虚拟机上创建三节点 Spark 群集节点。群集节点包括一个主节点以及两个从节点。确保各个组件版本正确，保证兼容性。

表 7-1 测试环境

Table 7-1 Test environment

环境名称	配置
业务服务器	CentOs7.0，2GB 内存，master CentOs7.0，2GB 内存，slave1 CentOs7.0，2GB 内存，slave2
硬件配置	处理器：英特尔 XeonE5-2680 和 NVIDIAGeForceRTX3080,64GB 内存
ubuntu	16.04
Hadoop	2.7.1
Spark	2.4
Hive	2.1.0
Mysql	5.7
Python	3.7
JDK	1.8
Kafka	2.11
Tomcat	8.5.27
测试结果	与预期结果一致，通过测试

中国知网 https://www.cnki.net

7.2 功能性测试

系统功能性测试对用户管理、日志管理、日志统计、数据挖掘、数据可视化等五个模块进行测试，确保各个功能模块满足需求分析要求。本节通过各种测试用例对模块的黑盒测试过程与结果进行阐述。

表 7-2 为用户管理模块的测试用例，主要测试用户能否成功注册账号与登录账号,,能否检测不合格信息，输入不正确密码的时候能否登录。

7-2 用户管理模块测试用例

Table 7-2 Test cases of user management module

属性	内容
测试用例 ID	TC_01
测试用例名称	用户管理模块测试用例
目的	测试系统注册后能否成功保存，用户是否可以成功登录，忘记密码后是否可以进行修改
测试用例级别	功能性测试
测试流程	1.进入登录界面，点击注册，注册成功后看是否可以登录 2.点击退出登录，查看是否成功退出系统 3.重新登录系统，输入不存在账号密码查看系统是否提示 4.点击忘记密码，查看是否可以通过手机验证码重设密码 5.个人中心板块是否可以修改个人资料
预测结果	1.输入正确注册信息，系统发送手机验证码，输入正确验证码后显示注册成功，并自动进入系统。 2.输入非法注册信息如手机号格式错误、密码不符合要求，系统提示有非法信息，且无法发送手机验证码。 3.点击退出登陆后，退出系统，无法在对系统进行操作 4.登录信息出错，会被系统提示当前信息(账号和密码)错误。 5.点击忘记密码后，系统向注册的手机号发送验证码，输入正确验证码后可以重新设置密码 6.点击修改个人资料，可正常修改
测试结果	与预期结果一致，通过测试

表 7-3 为日志管理模块集群搭建的测试用例，该测试用例测试 Hadoop、Spark 集群搭建是否成功，以及集群生态系统各个组件是否配置成功。

表 7-3 集群搭建测试用例

Table 7-3 Test cases of cluster construction

属性	内容
测试用例 ID	TC_02
测试用例名称	集群搭建测试用例

中国知网 https://www.cnki.net

表 7-3 续表

Table 7-3（continue）

属性	内容
目的	测试 Hadoop 集群搭建、Spark 集群搭建是否成功，测试各种组件配置成功，是否可以进入管理页面。
测试用例级别	功能性测试
测试流程	1.测试 HDFS 集群搭建，zookeeper 集群、是否开启故障转移，是否可以登录 hadoop 管理界面 2.测试三台虚拟机是否联通，使用 scp 互相通信 3.测试 YARN 高可用结群是否搭建成功，测试检查 yarn 的 web 端口、列表名称和对应的主机名等方面 4.测试 HBASE 集群搭建是否成功，存储路径、分布式存储等方面配置正确 5.测试 Spark 集群搭建是否成功，检查工作节点的设置
预测结果	1.用 9000 端口进入 Hadoop 管理页面，查看 datanode、namenode 都是激活状态 2.IP 地址都对应着一台机器。每一个 hadoop 用户都是通过节点创造出来。Master 是主节点，而 Slave1 和 Slave2 以及 Namenode 是从节点。从节点 Namenode 定期按规律通过作为数据节点的 Datanode 接收心跳，以完成它们之间的通信。并且 ping 命令可以将所以节点连通 3.用配置好的端口成功登录 YARN 的管理页面，主从节点显示正确 4.用配置好的端口成功登录 HBASE 的管理界面，存储路径配置正确，HBASE 设置成分布式部署 5.用配置好的端口成功登录 Spark 管理后台，与 JDK\Scala\Hadoop 的配置正确，工作节点配置完成
测试结果	与预期结果一致，通过测试

表 7-4 为日志管理模块的测试用例，主要测试是否可以收集日志文件，以及数据传输、日志文件存储是否正确。

表 7-4 日志管理功能测试用例

Table 7-4 Test cases of log management function

属性	内容
测试用例 ID	TC_03
测试用例名称	日志管理模块测试用例
目的	测试是否可以收集日志文件，以及数据传输、日志文件存储是否正确
测试用例级别	功能性测试

中国知网 https://www.cnki.net

表 7-4 续表

Table 7-4（continue）

属性	内容
测试流程	1.测试 flume 组件配置是否成功，采集日志是否成功 2.查看 kafak 消费者是否抓取到数据。 3.测试新追加的日志是否收集成功 4.测试 flume 缓存中的数据是否写入 HBASE 5.测试新闻日志预处理是否成功
预测结果	1.查看本地日志文件 logs,启动日志采集程序，查看两个从节点，发现 flume 系统轮流采集并打印收集得到的数据信息。主节点和两个自己点连接成功，数据信息完成聚合 2.创建 kafka topic 生产者、消费者，查看到抓取的日志文件 3.测试新数据写入情况，动态跟踪指定文件的写入,发现新追加日志写入成功 4.打开 HBASE 的 shell,输入相关 SQL 语句，查询写入的日志文件 5.查看日志文件格式，确定是否是一下格式 “userid+datatime+searchname+retorder+cliurl+cliorder”
测试结果	与预期结果一致，通过测试

表 7-5 为日志分析模块离线分析功能的测试用例，主要测试是否可以进行离线统计。

7-5 离线日志分析功能测试用例

Table 7-5 Test cases of offline log analysis function

属性	内容
测试用例 ID	TC_04
测试用例名称	离线日志分析测试用例
目的	测试是否可以离线统计分析
测试用例级别	功能性测试
测试流程	1.测试 HBASE 与 Spark SQL 集成，采用 hive on Spark 模式，Hive 既作为存储元数据又负责 SQL 的解析优化，通过创建测试表的方式启动集群进行计算。 2.测试查询搜索引擎查询次数较多的话题，生成关键字词云 3.测试固定时段的时段流量分析，生成小时粒度数据
预测结果	1.Hive 完成测试表的计算，输出查询结果 2.主从节点 scp 命令互相传输文件成功 3.用配置好的端口成功登录 YARN 的管理页面，主从节点显示正确 4.根据查询逻辑，计算热门搜索话题
测试结果	与预期结果一致，通过测试

中国知网 https://www.cnki.net

表7-6 为日志分析模块实时分析功能的测试用例，主要测试在通过对新闻APP总体流量进行监控和分析是否可以进行实时分析以及各个分析维度是否实现计算。

表 7-6 实时分析功能测试用例

Table 7-6 Real time analysis function test cases

属性	内容
测试用例 ID	TC_05
测试用例名称	实时分析模块测试用例
目的	测试是否可以实时统计分析
测试用例级别	功能性测试
测试流程	1.测试了 Kafka 流式数据被 Spark Streaming 的拉下来获取的方式，转化为数据结构 Dstream。结构化流把数据视为无界的、连续追加的表，使用 Update 更新方式进行更新存储。 2.测试实时新闻总体流量的统计分析，使用结构化流数据处理逻辑，设定触发时间和触发位置，开始查询读取数据。 3.测试实时点击率统计，显示点击率最高的 30 个话题 4.测试搜索最优 rank 频率 5.测试时段流量分析
预测结果	1.采用 Direct 方式直接连接 Kafka 分区来获取数据，存储到数据库中。 2.查询实时数据，不断打印查询的数据信息 3.根据查询逻辑，不断更新统计话题点击率 4.根据查询逻辑，不断更新搜索最优 rank 频率 5.根据查询逻辑，不断更新搜索实时时段流量分析
测试结果	与预期结果一致，通过测试

表 7-7 为日志数据挖掘模块的测试用例，主要测试是聚类、分类、协同过滤算法实现。

表 7-7 数据挖掘功能测试用例

Table 7-7 Data mining function test cases

属性	内容
测试用例 ID	TC_07
测试用例名称	数据挖掘模块测试用例
目的	测试日志数据聚类、分类、协同过滤是否正确
测试用例级别	功能性测试
测试流程	1.调用 Kmeans 聚类算法，读取数据，测试数据得到的聚类 2.调用朴素贝叶斯算法，读取数据，测试数据得到的分类 3.调用基于基于时间权重和用户兴趣变化的协同过滤算法模型，读取数据，测试与基于木品协同过滤算法对比效果，实现优化

中国知网 https://www.cnki.net

表 7-7 续表

Table 7-7（continue）

属性	内容
预测结果	1.得到聚类，达到预期效果 2.得到分类，达到预期效果 3.得到推荐算法，达到预期效果
测试结果	与预期结果一致，通过测试

表 7-8 为可视化模块的测试用例，主要测试是可视化模块功能是否实现。

表 7-8 可视化功能测试用例

Table 7-8 Visual function test cases

属性	内容
测试用例 ID	TC_08
测试用例名称	可视化功能测试用例
目的	测试日志文件、离线分析、实时分析是都可以可视化
测试用例级别	功能性测试
测试流程	1.点击日志板块查看日志数 2.点击实时分析，查看实时分析各个维度的图表 3.点击离线分析，查看离线分析各个维度的图表
预测结果	1.正常查看日志数据 2.正常查看实时分析报表，包括时段流量分析、话题统计、搜索最优 rank 频率分析、热门话题分析 3.正常查看离线分析报表，包括小时粒度时段流量分析、关键搜索词云图
测试结果	与预期结果一致，通过测试

7.3 非功能性测试

系统的非功能性测试也是系统测试的重要部分，该过程是对非功能性需求进行测试，验证系统满足功能外的需求。本节将从性能需求、可扩展性和可维护性、可靠性等方面的测试进行阐述。

7.3.1 性能测试

对于评估一个大数据分析系统能力的优劣，其中最为关键的维度就是性能。在本阶段，我们主要验证大数据应用从源数据中提取、加载数据的效率。准备大

中国知网 https://www.cnki.net

数据性能测试脚本，模拟日志量 100 万，全部处理完毕，最小吞吐时间 2.4 秒，最大吞吐时间 4.9 秒。

7.3.2 可靠性

系统中有一个称为故障转移控制器（failover controller）的新实体，管理着将活动 namenode 转移为备用 namenode 的转换过程。有多种故障转移控制器，但默认一种是使用了 Zookeeper 来确保有且仅有一个活动 namenode。每一个 namenode 运行着一个轻量级的故障转移控制器，其工作就是监视宿主 namenode 是否失效（通过一个简单的心跳机制实现）并在 namenode 失效时进行故障转移，这就是 HA 的主备切换机制，主备选举依赖于 Zookeeper。

本文使用分布式 HDFS 文件存储系统。HDFS 用于存储源日志数据。HDFS 是 Hadoop 生态系统的一员，也是底层的存储设备，也将 MySQL 数据库和其共同使用，用于大规模数据存储。文件存储在块中，不仅简化了库存管理，还通过自动备份机制消除了意外数据丢失问题。将所有原始数据导入 HDFS 并保存。

7.3.3 可扩展性和可维护性

可扩展性和可维护性是在一个大数据分析系统开始运行后，需要关注的维度，在本阶段，我们主要验证随着数据规模，数据流量和系统复杂性增长，系统能够保持近似线性的规模增长。准备大数据性能测试脚本，模拟数据规模和流量不断的增加，全部处理完毕，CPU /内存使用率保持在 50%以下，比较稳定，对于系统的响应时间在 2.2 秒。对于系统的可维护性测试，我们提供良好的文档和易于理解的操作模型，测试一个新人上手系统的功能操作时间为 10 分钟，验证了该系统的可操作性和简单性，并且通过良好的后台监控，提供对系统内部状态和运行时行为的可见性。

7.4 本章小结

本章首先对系统的测试环境进行了简单的介绍，然后针对系统的七个功能模块设计了相应的测试用例进行功能性测试，之后从性能、兼容性和易用性三方面进行了非功能性测试，并结合测试结果对系统进行了优化和完善，最终使系统符合用户需求，达到预期目标。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

8 总结与展望

本章是对全文工作成果的总结，从需求分析、概要设计、详细设计和算法实现等方面总结整个项目开发过程与意义，同时结合本系统目前的缺陷，为后续的发展提出改进思路。

8.1 全文总结

随着互联网、大数据的蓬勃发展，人们开始习惯于移动网络时代所提供的各种便利，享受着在线学习、娱乐新闻咨询、网上购物等各种服务。媒体制造商努力推荐给用户一些个性话的新闻消息和文章。新闻服务数据的比较分析在其中是十分重要的，所以服务的改进也是离不开它的。因此，对日志采集与分析系统的研究成为一项有意义的工作。

本文首先从日志分析系统的研究背景和意义出发，介绍了日志分析系统产生的背景和实际意义，并通过研究国内外研究现状指出目前存在的一些问题，接着本文介绍了 Hadoop、Spark 相关技术以及算法相关内容。

之后本文从功能性需求和非功能性需求两个方面对系统做需求分析，功能性需求分析将系统分为日志管理、用户管理、日志分析、数据挖掘、可视化分析等五个模块，非功能性需求分析从性能、可靠性、扩展性等几方面进行分析。

概要设计方面，对逻辑架构、数据流向、集群部署等几方面进行分析，并确定了五个模块的具体功能，同时通过 E-R 图对各张数据表进行了详细设计。详细设计方面，本文通过流程图、类图和时序图对各个功能模块的相关类和处理逻辑顺序进行阐述。算法方面，首先介绍了所使用的推荐算法和模型训练数据，在介绍了算法的训练过程、评价标准和使用结果。

最后本文从系统功能性测试以及非功能性测试两方面对系统进行了测试，并给出详细的测试用例。

8.2 未来展望

综上所述，对于基于 Spark 框架的新闻日志分析系统的设计对新闻日志数据进行了深入的数据分析。详细介绍了整个日志分析系统的开发过程。但是系统还是存在着一些不足，需要进行进一步的改进和研究。

首先，在数据存储方面，采 HDFS 数据存储框架，具有高容错和高吞吐的数

中国知网 https://www.cnki.net

据存储特点。考虑到后期新闻业务线的不断增加，系统的升级，可以尝试一下更为高效的分布式存储文件系统 Elasticsearch。

其次，对于新闻日志数据的实时分析，随着业务不断的深耕，需要进行更为精细化、精准化的大数据分析。对更多的业务线指标数据进行分析,例如如何用户地理分布，利用最优搜索 rank 频率优化推荐算法等。下一步继续借助利用自己的模型以及相关的数据分析平台，扩大和发展数据分析的优势，挖掘出更有用、更合适的信息。

中国知网 https://www.cnki.net

参考文献

[1]中国互联网发展状况统计报告[R].北京:中国互联网信息中心,2019-06.

[2]黎文阳.大数据处理模型 Apache Spark 研究[J].现代计算机(专业版),2015(08):55-60.

[3]傅韧峤.面向移动新闻的日志收集分析系统的设计与实现[D].北京交通大学,2017.

[4]王水德.基于 Spark 平台的推荐系统的研究与实现[D].厦门大学,2017.

[5]Hoffman S.Apache Flume:Distributed Log Collection for Hadoop[M].Packt PublishingLtd,2015.

[6]Long J,Yang C,Wang T,et al.Understanding user behavior in online social networks:a survey[J].Communications Magazine IEEE,2013,51(9):144-150.

[7]Silverstein Craig,Marais Hannes,Henzinger Monika,et al.Analysis of a very large web search engine query log[J].ACM SIGIR FORUM,1999,33(01):6-12.

[8]Lee,Y.H.,Yoo,S.J.The construction of logical, physical network separation by virtualization.Korea Converg.Secur.Assoc.14(2),25-33(2014).

[9]Hu Yunhua,Qian Yanan,Li Hang, et al.Mining query subtopics from search log data[C]//Proceedings of the 35th international ACM SIGIR conference on Research and development in information retrieval. ACM, 2012.

[10]Duan Jianyong, Ji Tianxiao, Wang Hao.Error Correction for Search Engine by Mining Bad Case[J].IEICE TRANSACTIONS on Information and Systems,2018,101(07):1938-1945.

[11]Nguyen Dai Quoc,Nguyen Dat Quoc,Nguyen Tu Dinh,et al.A convolutional neural network-based model for knowledge base completion and its application to search personalization[J].Semantic Web,2019,10(05):947-960.

[12]童国平,孙建军.基于搜索日志的用户行为分析[J].现代图书情报技术,2015(Z1):80-88.

[13]卜晓宁.基于大数据中查询日志的用户行为分析系统的设计与实现[D].北京:北京交通大学,2015.

[14]王继民, 彭波.搜索引擎用户点击行为分析[J].情报学报, 2006,25(02):154-162.

[15]余慧佳,刘奕群,张敏等.基于大规模日志分析的网络搜索引擎用户行为研究[J].中文信息学报,2009,21(01):109-114.

[16]陈志敏,李志强.基于用户特征和项目属性的协同过滤推荐算法[J].计算机应用,2011,31(07):1748-1750.

[17]赵文涛,成亚飞,王春春.基于 Logstic 时间函数和用户特征的协同过滤算法[J].计算机应用与软件,2017,34(2):285-289.

[18]何美慧.基于运营商日志数据的用户行为分析[D].北京:北京交通大学,2019.

[19]启敏,薛锦云,钟林辉.基于 Spring 框架的轻量级 J2EE 架构与应用[J].计算机工程与应用,2008(05):115-118+133.

[20]Sun Y, Guo S, Chen Z.Intelligent Log Analysis System for Massive and Multi-Source Security Logs:MMSLAS Design and Implementation Plan[C]//2019 15th International Conference on Mobile Ad-Hoc and Sensor Networks(MSN).2019.

[21]冀潇,李杨.采用 Echarts 可视化技术实现的数据体系监控系统[J]计算用,2017,26(06):72-76.

[22]赵文涛,王春春,成亚飞等.基于用户多属性与兴趣的协同过滤算法[J].计算机应用研究,2016,33(12):5.

中国知网 https://www.cnki.net

[23]Park Y,Park S,Jung W,et al.Reversed CF:A Fast Collaborative Filtering Algprithm using a k-nearest Neighbor graph[J].Expert Systems with Applications,2015,42(8):4022-4028.

[24]Du C,Guo H,Bigtable:A Distributed Storage System for Structured Data[J].2014.

[25]庄荣.基于 Spark 的流数据分类挖掘算法的研究[D].南京邮电大学,2018.

[26]Harter T,Borthakur D,Dong S,et al. Analysis of HDFS under HBASE:a facebook messages case study[C]//FAST.2014.14:12th.

[27]韩德志,陈旭光,雷雨馨,戴永涛,张肖.基于 Spark Streaming 的实时数据分析系统及其应用[J].计算机应用,2017,37(05):1263-1269.

[28]王水德. 基于 Spark 平台的推荐系统的研究与实现[D]. 厦门大学, 2017.

[29]王艺颖.朴素贝叶斯方法在中文文本分类中的应用[J].中国高新科技, 2019(07): 57-60.

[30]王继成,,高珍.软件需求分析的研究[J]. 计算机工程与设计, 2002, 23(08): 18-21.

[31]董洋溢,李伟华,于会．基于混合余弦相似度的中文文本层次关系挖掘[J]．计算机应用研究,2017(5):132-135.

[32]张煜福.基于 Spark 的查询日志用户行为系统设计与实现[D].山东:曲阜师范大学,2020.

[33]王娜娜.基于时间权重和用户兴趣变化的协同过滤算法[J].皖西学院学报,2020,36(02):40-45.

[]34 何明, 孙望, 肖润,等. 一种融合聚类与用户兴趣偏好的协同过滤推荐算法[J].计算机科学, 2017, 44(B11):6.

[35]HUANG Y X,CUI B, ZHANG W Y,et al.TencentRec: Realtime stream recommendation in practice[C]//Proceedings of ACM SIGMOD International Conference on Management of Data.2015;227-238.

[36]魏慧娟,戴牡红,宁勇余.基于最近邻居聚类的协同过滤推荐算法[J].中国科学技术大学学报,2016,46(09):736-742.

中国知网 https://www.cnki.net

学位论文数据集

表 1.1： 数据集页

关键词*	密级*	中图分类号	UDC	论文资助
新闻日志 离线分析 实时分析 协同过滤	公开			
学位授予单位名称*		学位授予单位代码*	学位类别*	学位级别*
北京交通大学		10004	电子信息硕士专业学位	硕士
论文题名*		并列题名		论文语种*
基于 Spark 框架的新闻日志分析系统的设计与实现				中文
作者姓名*	高志远		学号*	20140533
培养单位名称*		培养单位代码*	培养单位地址	邮编
北京交通大学		10004	北京市海淀区西直门外上园村 3 号	100044
工程领域*		研究方向*	学制*	学位授予年*
软件工程		软件工程	2 年	2022
论文提交日期*	2022 年 11 月			
导师姓名*	包尔固德		职称*	副教授
评阅人	答辩委员会主席*		答辩委员会成员	
	段莉			
电子版论文提交格式 文本（ ） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ） 推荐格式：application/msword；application/pdf				
电子版论文出版（发布）者		电子版论文出版（发布）地		权限声明
论文总页数*	75			
共 33 项，其中带*为必填数据，为 21 项。				

中国知网 https://www.cnki.net