分类号：TQ241　　密　级：公开

西北民族大學

硕 士 学 位 论 文

题目： 基于 Spark 电商平台的用户画像系统的应用研究

姓　　名：申宏章

学　　号：Y221630379

学　　院：电气工程学院

专　　业：人工智能

研究方向：大数据分析

导　　师：杨成慧

二〇二五 年　五月

中国知网　https://www.cnki.net

Research on the Application of User Profile System Based on Spark E-commerce Platform

A Thesis Submitted for the Degree of Master

Candidate：Shen Hongzhang

Supervisor：Prof. Yang Chenghui

May, 2025

Northwest Minzu University

Lanzhou, China

中国知网 https://www.cnki.net

摘 要

我国的移动互联网技术经历了数十年的迅猛发展以及智能手机等移动设备的广泛普及推动了我国的电子商务的跨越式发展，人们足不出户就可以在移动电子商务平台上购买商品。并且我国的电商市场规模十分庞大，用户在电子商务平台上进行电子商务活动也直接催生了海量的用户数据，基于传统的统计模型决策方式越来越难以应对如此庞大的平台数据规模。在此背景下，用户画像技术应运而生，可以显著提升电商平台在大规模数据处理上的速度与效率。主要研究成果如下：

（1）提出了一种基于 Vision Transformer 视觉处理技术的商品分类识别方法，该方法的核心思路是将图像视为一系列的“视觉单词”而不是连续的像素数组，通过将图像分割为固定大小的图像块并为其添加相应的编码信息，并基于多头自注意力机制和前馈神经网络处理更好的捕捉这些嵌入图像块的长距离依赖关系，最后利用分类标记提取商品视觉特征进行图像分类任务。根据实验结果表明，基于 Vision Transformer 的商品分类识别方法在大规模商品分类处理任务中展现出了极强的优越性，商品整体分类识别准确率能够达到 97%以上。

（2）提出了一种基于 RFM 模型的用户画像模型构建方法，根据客户最近购买时间（Recency）、购买频率（Frequency）以及购买金额（Monetary）这三个维度对客户进行画像刻画，并结合了经典的 K-Means 算法对用户群体进行聚类分析，对用户群体进行更为精准的分群预测，构建出一个更加精准的的用户画像平台，从而帮助企业将客户精确地划分为不同的群体，进而提高客户的生命周期价值和企业的整体业绩。

（3）设计了一种基于 Spark 的用户画像平台，通过 Spark 计算框架强大分布式计算能力来高效地处理平台上产生的海量用户数据，构建出高效的海量商品交易数据以及用户行为数据实时处理管道，提升了平台对用户行为数据实时处理和分析的能力，克服了传统数据处理方式在用户画像实时更新上的不足，显著提升了用户画像构建过程中对海量平台用户数据处理的速度和效率。基于 MLlib 算法库还可以对更深层次的用户偏好和行为模式进行更为复杂的特征提取与选择，实现用户兴趣偏好模型的训练与优化，大幅度优化平台用户画像的质量。

综上所述，基于 Spark 和 RFM 模型所构建的用户画像将为大数据时代背景下的电商平台的精细化运营提供了较高的研究探索价值，为其他大数据应用的应用落地提供了较高的参考价值。

关键词：电子商务，用户画像，Spark，Vision Transformer，K-Means

中国知网 https://www.cnki.net

Abstract

The mobile internet technology in China has undergone rapid development over several decades, and the widespread adoption of mobile devices such as smartphones has greatly propelled the leap-forward development of e-commerce in the country. People can now purchase goods on mobile e-commerce platforms without leaving their homes. Additionally, China's e-commerce market is vast, and the e-commerce activities of users on these platforms have directly generated massive amounts of user data. The traditional statistical model-based decision-making approach has increasingly struggled to handle such large-scale platform data. Against this backdrop, user profiling technology has emerged, significantly enhancing the speed and efficiency of large-scale data processing on e-commerce platforms. The main research contributions are as follows:

(1) A product classification recognition method based on Vision Transformer (ViT) visual processing technology is proposed. The core idea of this method is to treat images as a series of "visual words" rather than continuous pixel arrays. The image is divided into fixed-size patches, and corresponding encoding information is added to capture the long-range dependencies embedded in these image patches. The method then uses multi-head self-attention mechanisms and feed-forward neural networks to capture these dependencies more effectively. Finally, the classification labels are used to extract visual features of products for image classification tasks. Experimental results show that this method demonstrates strong superiority in large-scale product classification tasks, with an overall classification accuracy of more than 97%.

(2) A user profiling model construction method based on the RFM model is proposed. This method profiles customers based on three dimensions: Recency, Frequency, and Monetary. It also combines the classic K-Means algorithm to perform cluster analysis on the user group, enabling more accurate user segmentation predictions. This method helps create a more precise user profiling platform, allowing businesses to categorize customers into different groups, thereby improving customer lifetime value and the overall performance of the business.

(3) A user profiling platform based on Spark is designed. By leveraging the powerful distributed computing capabilities of the Spark computing framework, the

中国知网 https://www.cnki.net

platform efficiently processes massive amounts of user data generated on platform. It builds an efficient real-time data processing pipeline for massive product transaction data and user behavior data, enhancing the platform's ability to process and analyze user behavior data in real-time. This overcomes the limitations of traditional data processing methods in real-time updates of user profiles and significantly improves the speed and efficiency of processing large-scale platform user data during the user profile construction process. Moreover, using the MLib algorithm library, the platform can perform more complex feature extraction and selection for deeper user preferences and behavior patterns, enabling the training and optimization of user interest preference models and greatly improving the quality of user profiling on the platform.

In summary, the user profiling system based on Spark and the RFM model provides substantial research value for enhancing the precision operations of e-commerce platforms in the era of big data. It also serves as a valuable reference for the practical implementation of other big data applications.

Key words: E-commerce, User profile, Spark, Vision Transformer, K-Means

中国知网 https://www.cnki.net

目 录

第 1 章 绪论.....1
1.1 研究背景.....1
1.2 研究目的和意义.....2
1.2.1 研究目的.....2
1.2.2 研究意义.....3
1.3 国内外研究现状.....4
1.3.1 用户画像的国外研究现状.....4
1.3.2 用户画像的国内研究现状.....6
1.4 主要研究内容及组织架构.....8
1.4.1 主要研究内容.....8
1.4.2 论文的组织架构.....8
第 2 章 用户画像技术架构.....10
2.1 用户画像.....10
2.1.1 用户画像概述.....10
2.1.2 用户画像的应用.....11
2.1.3 用户画像构建流程.....12
2.2 用户画像相关技术.....13
2.2.1 Hadoop.....13
2.2.2 Spark.....14
2.3 本章小结.....15
第 3 章 基于 RFM 模型的用户画像模型的应用实现.....16
3.1 数据存储的设计与优化.....16
3.1.1 数据仓库的设计.....16
3.1.2 数据存储优化.....19
3.2 用户画像模型的构建.....21
3.2.1 数据集制备.....21
3.2.2 评价指标.....22
3.2.3 实验环境.....23
3.2.4 基于 Vision Transformer 的分类预测算法.....23
3.2.5 基于 RFM 模型结合 K-Means 算法的用户画像模型构建.....27
3.3 本章小结.....31
第 4 章 用户画像系统的设计与实现.....33
4.1 系统分析.....33

中国知网 https://www.cnki.net

4.2 环境搭建.....34
4.2.1 开发环境.....34
4.2.2 分布式环境构建.....35
4.2.3 Spark 分布式集群搭建.....37
4.3 用户画像系统逻辑设计.....38
4.3.1 数据库设计.....38
4.4 用户画像系统的实现.....41
4.4.1 系统部署.....42
4.4.2 系统管理模块.....42
4.4.3 数据管理模块.....44
4.5 本章小结.....48
第 5 章 系统测试与分析.....49
5.1 测试环境.....49
5.2 功能测试.....49
5.3 性能测试.....52
5.4 稳定性测试.....54
5.5 测试结果分析.....55
5.6 本章小结.....55
第 6 章 总结与展望.....56
6.1 总结.....56
6.2 展望.....57
参考文献.....58

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景

随着互联网技术的不断发展进步和广泛普及特别是移动互联网技术的广泛应用，世界各行各业都纷纷主动拥抱数字化转型的黄金时代。智能手机的广泛普及也助推了数字化时代的到来，极大的方便了人们的网络购物需求，人们在电子商务平台的购物活动也越来越频繁，网络购物也迅速成为人们的一种生活潮流，在年轻人中尤甚，并且我国电子商务交易量发展较快[1]，据《中国新电商发展报告 2024》显示，2023 年全国网上零售总额达到 15.42 万亿元，同比增长 11%，中国连续 11 年稳居全球网络零售市场领先地位。其中，网上实物商品零售额占比攀升至社会消费品零售总额的 27.6%。直播电商为新电商的中坚力量，其在电子商务领域中的具有举足轻重的地位，2023 年我国的直播电商市场规模达到 4.9 万亿元，同比增速 35.2%。

数字化时代的到来在丰富人们精神生活的同时也给平台带来了海量的数据流，用户在电子商务平台上进行商品搜寻、浏览、添加购物车、支付和评论等活动也直接催生了海量的用户数据。电子商务的迅猛发展涌现了海量用户数据的同时，其数据规模还呈现指数级的增长趋势，这些数据蕴含了丰富的用户行为和偏好信息，可以为商家提供宝贵的决策洞察支持，但也对用户数据的分析和处理工作带来了严峻的挑战。过去基于传统的人工统计的数据分析方式在面对规模如此庞大且维度十分复杂的数据量时也显得心余力绌，无法充分挖掘用户数据中巨大的潜在价值。在网络信息泛滥的背景下用户也面临着信息过载的挑战，对企业来说如何更好地理解和服务平台用户，快速及时地从海量的用户信息中识别出目标用户并根据每个用户的需求和特点提供个性化服务，这也成为企业提高用户满意度和企业竞争力的关键，而用户画像系统的研究初衷正是为了解决信息过载和个性化需求之间的矛盾。它通过对用户在平台产生的多维度数据进行整合和分析，精准地提取出用户的兴趣、偏好以及行为模式等关键特征，从而更加深入分析和精准把握用户需求，提供符合用户需求的个性化推送和内容匹配等服务。在大数据技术和人工智能火热的新时代，用户画像的构建方式也迎来了全面的升级，逐渐从传统的统计方法转变为更为精准和动态的智能建模，这使得用户画像系统能够快速地从海量的数据中提取用户特征信息和持续进行优化调整提供了可能，随着算法地不断完善，用户画像系统可以保证画像随着用户的实际行动和需求动态变化更新，自动对用户画像进行分析、调整和优化。总之，用户画像系统的研究是由技术进步、市场需求和社会变革共同推动前进的，三者相互促进、相辅相成、

中国知网 https://www.cnki.net

缺一不可。它在为企业提供了精准的用户分析工具的同时，也在推动行业向个性化、智能化以及自动化的热门方向发展。随着技术的不断创新、更迭和成熟，用户画像技术将朝着越来越智能化、个性化、精确化方向持续发展，能够在更加广泛的应用场景中提供为广大用户所欢迎的个性化的服务和解决方案。

1.2 研究目的和意义

1.2.1 研究目的

面对用户进行电子商务活动所产生的多维且巨量的用户数据所带来的严峻挑战，基于大数据技术的用户画像系统的应用与研究也应际而生，针对海量用户数据进行高效地处理与分析，让平台即使面对规模庞大且维度十分复杂的数据时也显得游刃有余，帮助企业更为全面和深入地理解用户的行为、兴趣和偏好。用户还行系统在对用户在不同平台上交互留下的各种行为信息，如：浏览记录、购买历史、点击频率等信息进行综合分析，进而为每个用户构建一个十分详细的行为档案，从而实现对用户兴趣偏好的精准识别和捕捉。通过行为档案对用户在平台上留存的行为数据进行历史分析来把准用户的购买周期，识别出用户的兴趣点，精准预测用户在未来几周或者几个月内最有可能需要什么商品或服务，帮助企业提前做好库存和物流上的充分准备。于此同时，用户画像系统还可以帮助企业更加全面深入地理解用户的生命周期阶段，并在相应的阶段为用户提供量身定制的服务。

使用新型的基于数据驱动的用户画像模型来对用户行为进行预测，通过大数据技术来对收集用户数据进行数据挖掘[2]，从而构建全面、动态且精准的用户画像，为电商精准营销提供了科学的决策支持，从而更好地满足用户日益增长的个性化和多样化消费需求。现如今用户画像技术在电商平台的运营中也扮演者越来越重要的角色，如何有效利用和管理收集好的用户偏好信息以及行为信息来构建出精准的用户画像[3]，已逐渐成为了电子商务领域越来越关键的竞争要素。通过用户画像企业可以对用户行为信息进行分析，基于用户的兴趣和需求对界面进行界面布局设计以及交互流程上的针对性优化，根据用户经常访问的页面以及点击频率较高的内容或功能来对应用界面进行针对性的优化调整，确保界面上优先呈现的是用户感兴趣的内容和服务，从而提升用户的平台浏览体验，进一步提升平台与用户的依存度。对企业来说，用户画像系统最为重要的一个作用是可以辅助公司高层决策提供有力的数据支撑以减少人工干预和错误，提升数据分析的精确度和决策的及时性，特别是在产品研发、市场定位以及资源分配等方面。企业基于不同的用户画像可以进一步细分市场，确定不同用户群体的需求特点，从而帮助公司制定更加符合市场需求的产品策略、定价策略以及品牌传播策略，让企业

中国知网 https://www.cnki.net

在竞争中找到最具潜力的市场定位，根据用户的兴趣、需求和消费能力特征的分析结果，精准识别潜在客户，从而制定出针对性的市场营销策略，进一步提高公司投放广告的点击率和转化率，尽可能最大化广告的投放效果，提高公司营销活动的投资回报率，促进企业效益的大幅度提升。

1.2.2 研究意义

在数字化时代的今天，大数据技术[4]的快速发展已经改变了人们的生活方式和商业模式。用户画像系统便是基于大数据技术的重要应用之一，通过大数据技术对用户在电商平台上留存的用户偏好、行为以及兴趣等信息进行深入分析和挖掘，从而构建出精准的用户画像可以帮助企业更好的理解和分析用户的行为模式、消费习惯和需求特征。通过对用户数据进行深度挖掘，往往可以从海量数据中发现隐藏在其背后的规律和趋势，从而优化企业的资源配置，帮助企业决策者在精准的时机、准确地渠道以及针对特定用户群体进行资源优化配置，为电商企业决策提供可靠的数据支撑，进而为企业提供一个宏观且清晰的市场洞察，帮助企业指定长期的、科学的战略规划，推动企业决策更加的科学和高效，显著降低企业的经营风险。用户画像不仅有助于企业精准地了解真实的用户需求，还能帮助其十分精准地洞察市场中的供需关系，通过实时数据反馈帮助企业更为迅速的响应市场变化和用户需求变化，准确地预测市场趋势和识别消费热点方向从而提前调整供应链和营销策略，对市场用户进行更为精细化的划分，快速找到尚未满足的细分市场和潜在的用户群体，尽可能先于竞争对手推出更具竞争力的产品和服务，帮助企业在市场上和其他同行竞争中尽可能快的抢占领足够多的先机，有助于打破传统的市场垂直划分，提高市场运作的灵活性和敏捷性，为企业发展奠定宝贵的先发优势。

在这个日新月异的新时代洪流当中，商机稍纵即逝，竞争愈发白热化。对于任何一家公司而言，客户就是上帝，没有了顾客的支持与信赖，企业的辉煌将如同无根之木、无源之水，最终难逃被淘汰出局的命运。客户是企业赖以生存和发展壮大的根本动力源泉，只有始终把满足客户需求放在首位，才能赢得市场的认可，在激烈的角逐中立于不败之地。因此我们务必认识到，有效保持同客户之间的紧密联系，这既是企业生存发展的根基，也是取得竞争优势的关键所在，更是企业成功的不二法门。在这个日新月异的时代里，市场瞬息万变，企业之间的竞争愈发激烈，乃至一不留神就将会失去市场先机。只有保持同客户的紧密联系，才能实现企业持续的增长和长期繁荣，才能在众多竞争对手指脱颖而出。只有基于用户具体的特征和行为数据构建出的大数据用户画像系统才能很好地帮助电商企业更好的洞悉用户的需求和行为，指导企业对产品与服务的进行进一步创新和优化，使其更加贴近用户的实际生活需求。用户画像技术也为进一步推出更有

中国知网 https://www.cnki.net

针对性、更加差异化和个性化的产品、内容以及服务提供了战略导向，显著提升用户体验和满意度，进一步增强了企业的科技实力和市场竞争力。借助大数据技术的强大的计算能力，用户画像系统通过对用户的特征和行为进行分析便可以给企业提供新的市场需求和潜在需求动态实时导向，实现针对性的市场营销活动，提高广告投放的精准性和效果，为用户提供更加符合其需求的信息。这无疑可以帮助企业更加快速有效地锁定潜在的客户群体，大大提升了用户服务的品质，显著增强了用户的忠诚度，同时也大幅度降低了用户的流失率，进一步增强企业平台的用户粘性[5]。而用户画像技术就是帮助企业提升客户消费过程中的体验感受的一把利刃，通过对用户行为数据分析建模后打造出让用户满意甚至超出预期的商品和服务，有利于企业更好的客户关系管理，进一步推动企业智能化决策，帮助企业持续保持有价值的客户资源，确保公司在未来的道路上行稳致远，再续辉煌。

1.3 国内外研究现状

1.3.1 用户画像的国外研究现状

由于计算机最早诞生于国外，美国计算机科学家约翰.冯.诺依曼[6]奠定了现代计算机体系，助推了计算机相关技术体系的不断发展完善，这为用户画像领域的深入研究打下了坚实的理论基础和实践基础。用户画像这一概念最早可追溯于 1983 年，是由美国软件设计师、交互设计之父 Alan Cooper[7]在这一年首次提出的，并于 1998 年出版的软件设计著作《软件创新之路—冲破高技术营造的牢笼》[8]一书中正式提出的一个概念。在他看来，用户画像就是对目标用户的具体呈现，通过创建虚构的人物来代表不同类型的用户，可以帮助设计师更好的理解用户的需求和动机，这一方法也在日后的 UX 设计中得到了广泛的应用。用户画像这一全新的概念一经面世便立即引起了业内人士的广泛关注，并吸引了众多计算机领域的专家学者纷纷加入到用户画像技术的研究热潮中来。

国外对用户画像相的关研究有着较长的历史，在用户画像研究的早期起步阶段，由于当时互联网还没有得到广泛的普及，网络用户的规模较小，数据的来源也十分单一，网络数据量的样本数量十分有限。此阶段主要采用传统的问卷调研、电话访谈以及电子邮件的方式来统计和分析用户的数据，从而帮助企业更好的了解目标客户的基本特征和需求。在上世纪五十年代，世界上最大的市场信息调查公司—A.C.Nielsen 为了了解电视观众的兴趣偏好情况而对家庭收视率情况开展了调查，并基于数据分析的方法来对消费者作进一步的市场细分，为公司制定个性化的广告策略提供了有力的数据支撑。后来随着互联网的不断普及，用户规模不断上升，用户的数据量的来源也日趋多样化，用户在线行为数据量十分丰富。

中国知网 https://www.cnki.net

在上世纪九十年代 Web 技术所兴起的浪潮为用户在网站上搜集网页链接的内容满意度评分信息扫清了技术上的障碍，加尼福尼亚大学创建的 Syskil & Webert 网站便是通过收集用户对网页的评分信息的方式来逐步学习构建出用户兴趣模型，从而向用户推荐他可能感兴趣的网页链接。由加州管理大学开发的 Web Watcher 和 Personal Web Watcher 网站能将用户在互联网上产生的各种浏览行为及兴趣偏好信息记录到数据采集器中，以此为基础构建出针对性的用户兴趣模型，从而更好的满足用户个性化的网页信息需求。

在大数据和人工智能的新时代出现了更为强大的信息采集和处理方式，可以更为从容地应对规模庞大且维度十分复杂的平台数据，让大规模数据处理和分析变得更加高效。在 2010 年以后用户画像技术发展十分迅猛并日趋走向成熟，越来越多高校学者也加入到这个研究热潮中来。2013 年，伊朗阿扎德大学计算机科学系的学者 Zerkouk 等[9]提出了一种基于 Web 交互的用户画像构建方法，通过聚类和神经网络技术进行自动分类用户的导航模式，通过注册用户的设置以及活跃用户的相似度度量构建出隐式的用户画像，精准预测用户的需求。2018 年，斯坦福大学的学者 Rex Ying 等[10]针对大规模图数据结构中生成用户和物品的嵌入表示时的性能瓶颈问题，提出了一种结合高效随机游走和图卷积算法—PinSage，该算法能够高效处理平台上数亿级平台数据，显著提升了平台数据的处理效率和推荐质量。2020 年，赫尔辛基大学的学者 Timo Ruotsalo 等[11]针对传统的用户画像构建方法由于对用户情感特征因素的忽略从而导致平台的个性化程度不高的弊端，提出了一种新型的将情感特征融入到多模态的推荐系统的方法，通过结合用户的情感信息构建用户画像模型，不仅改善了推荐系统的性能，也增强了系统对用户情感的理解和响应能力，更具有深远意义的是其为多模态推荐方式提供了全新的研究思路。2021 年，伊利诺伊大学香槟分校的学者 Amin Javari[12]针对庞大网络规模下在局部和全局结构的模型构建效率上的限制问题，提出了一种基于图数据的用户画像构建方法，通过结合局部和全局结构对用户的兴趣和行为进行建模，实现了在社交网络中精准用户画像的构建。2022 年，美国卡内基梅隆大学的学者 Liangwei Chen 等[13]充分考虑到传统用户画像冷启动时用户由于缺少交互记录导致的画像学习的效果差、推荐效果不好的难题，提出了一种基于异构图和元学习的跨领域用户画像自适应方法，利用相似度用户迁移辅助冷启动用户建模方式显著提高了冷启动用户的兴趣建模效果，是的模型在新的应用场景能够快速适应。 2024 年，美国亚利桑那大学的学者 Hyunsik Yoo 等[14]在动态推荐系统中充分考虑了不同模型更新对用户群体公平性的影响以及其可能导致的不同群体之间的性能差异问题而提出了 FADE 框架，通过增量微调和可微分的 Hit 指标来确保推荐系统中的用户侧公平性，显著减少了不同用户全体之间的性

中国知网 https://www.cnki.net

能差异，大大保障了平台的推荐性能表现。

现如今用户画像技术研究成果也逐渐在众多世界级科技巨头的日常业务中开花结果，并得到了进一步的持续应用创新。科技巨头 Google 公司通过充分分析其广告平台收集的用户搜索和浏览记录、浏览习惯、位置数据等用户行为数据而生成高度精确和动态的用户画像来时刻展示符合用户兴趣与需求的广告，当用户在 Google 搜索某一词条时，Google 会通过用户画像系统分析其兴趣和行为，进而展示最相关的广告，实现了个性化和差异化的用户广告推送，显著提高了广告的点击率和转换率，充分地将公司的技术优势和流量优势转化成经济优势。Facebook 作为全球最大的社交平台之一，其广告收入主要来自于精准的广告投放，通过使用用户画像系统全面收集用户在平台上的行为数据，如：点赞、评论、分享、浏览等以及社交关系数据来精准地为广告主定向推送广告，例如，汽车厂商可以选择展示广告给那些有汽车购买意向的用户或者是那些过去在汽车相关话题下互通过的用户，这种精确的广告定向投放使得广告的用户转化率大幅度提升，同时也为公司带来了巨大的潜在商业价值。全球最大的电商平台的 Amazon 成功的关键是在其公司业务中根据平台用户的画像构建了精准的个性化推荐系统，通过对用户的购买历史、价格区间、搜索记录等行为数据进行分析构建用户画像，从而在首页、搜索结果页、结账页等位置始终展示与用户兴趣相关的商品推荐，比如，如果用户曾经浏览过某品牌的手机，系统可能会持续推荐与其相关的配件或产品，显著提升了用户的购物体验，大大提高了公司广告的转化效益。

1.3.2 用户画像的国内研究现状

国内对与用户画像的相关研究虽然起步较晚，但近些年来乘着互联网火热发展的强劲东风而发展迅速，其广阔的应用前景和发展潜力也吸引到了众多学者的目光，越来越多的学者也纷纷加入到用户画像的研究热潮中来，同时大数据相关技术的不断发展成熟也为用户画像的研究扫平了技术上的障碍。2016 年，西安电子科学大学的学者王智囊[15]切中传统问诊模式在患者等待挂号、看病、取药等环节的等待时长弊端，在传统协同过滤算法的基础上结合了奇异值分解技术并提出了一种基于奇异值分解技术的用户数据画像原理设计的医疗信息精准化医学画像模型，以实现对于患者病情与问诊医生的精准化推荐，避免了大量的用户问诊的等待时间。2017 年，中国科技大学的学者郭光明[16]对微博等社交媒体数据源的用户画像建模进行了深入的研究，针对对社交媒体大数据长度短、质量差、变化迅速、相关性弱等痛点，提出了高效用片段挖掘算法的多重优化策略，并创造性地设计了 LUBD-CM 的概率主题模型，相比于传统的朴素的 Bayes 算法，该模型在算法的运行速度以及用户标签的预测准确性有了明显的提升。2020 年，青岛大学商学的学者吴剑云等[17]采用了新颖的时间指数衰减的个性化推荐模型

中国知网 https://www.cnki.net

来构建用户视频兴趣标签，并结合 K-Means 聚类算法和 LDA 模型来提取标签主题，从而捕捉到用户的兴趣与时间的变化关系，以此来提高系统对用户兴趣随时间变化的感知能力。2021 年，河北大学管理学院学者吴树芳等[18]考虑到用户兴趣动态变化的特性，针对传统的静态用户画像方法难以捕捉用户兴趣演化过程的缺陷，提出了一种融合深度学习的用户兴趣演化建模方法，利用长短记忆网络（LSTM）建模用户兴趣的时间序列特征，并结合自注意机制（Self-Attention）捕捉用户兴趣的长期依赖关系，从而动态捕捉用户兴趣的演化过程，提高了平台系统的服务推荐的个性化和准确性。2022 年，中国海洋大学学者袁苗苗等[19]为解决传统单一模态用户画像方法难以全面反映用户兴趣和需求的痛点，提出了一种多模态信息融合的用户画像构建方法，利用全局神经网络提取图像特征，并利用循环神经网络（RNN）处理文本信息，再利用多模态融合网络将不同模态的信息进行融合，从而构建出能够全面放映用户兴趣和需求的用户画像模型，提高平台系统服务推荐的准确性和用户满意度。2023 年，东南大学学者杨钰[20]充分剖析了传统用户画像模型缺乏对用户背景知识的理解，导致了用户画像在深度和广度上的严重不足，针对这一问题而提出了一种基于知识图谱的用户画像构建方法，充分利用知识图谱中的实体和关系信息并结合图卷积神经网络对用户的兴趣进行建模，进一步构建能够深入理解用户行为数据和背景知识的用户画像，显著提高了平台系统的准确性和可解释性。2024 年，南昌大学学者周峰[21]则在用户画像在政企人才选拔效率方面的应用领域提出了自己的独到见解，针对在随机选择初始簇所带来的算法收敛问题以及划分簇计算耗时过长的问题对 Bisecting K-Means 算法做了改进，提升了人才数据聚类的质量，推动了政企在人员管理以及人才招聘的效率。

在未来我们对用户画像的研究也将持续深入、更加广泛，届时用户画像技术可能应用到生活的方方面面，成为我们日常生活中不可或缺的一部分。用户画像的研究同样也离不开众多企业的参与，面对平台日益增长的巨量且维度复杂的用户数据，如何基于海量的用户消费数据中洞察用户的行为特征和喜好特征逐渐成为了企业关注的焦点。我国用户画像的相关研究就是在这样的大背景下乘势而起，这也为用户画像技术的广泛应用和迅速发展提供了良好的市场契机。国内对于用户画像的研究主要集中在以数据驱动的用户画像应用[22]和以社交网络分析的用户画像应用[23]两个领域为主，腾讯、阿里巴巴和字节跳动等国内互联网巨头便是其中的佼佼者。国内社交领域内的巨头企业腾讯热衷于在社交网络分析用户画像领域内持续深耕，从用户的社交关系、信息传播、兴趣爱好等方面着手，基于用户的社交角色、社交关系强度和社交行为着手进行深入研究，充分结合用户在社交平台的行为习惯为用户建立精准的画像，并依据用户的喜好匹配度在 QQ 和微

中国知网 https://www.cnki.net

信这两款国民级社交平台上进行精准化推送。国内电商巨头阿里巴巴则依托旗下的淘宝和天猫电商平台来对商品数据、购买者特征、热词榜等进行分析，从用户的消费行为、兴趣偏好、价格偏好、购物习惯、浏览记录、搜索记录等方面进行多维数据分析来深入了解不同群体的需求特点，从而为用户建立精准的用户画像，为公司决策提供及时的市场变化洞察以及有力的数据支撑。字节跳动是我国互联网行业的一颗耀眼的明星，是目前中国盈利能力最强的互联网公司，其成立距今也不过十二年时间便成为比肩腾讯、阿里巴巴等老牌互联网巨头明星企业。其成功的秘诀就是从用户出发，精准抓住用户的喜好需求，通过其强大的数据分析能力对抖音短视频以及西瓜视频平台上用户的基本信息、兴趣偏好、社交关系、活跃时段、消费能力、消费行为、内容创作与互动情况、用户反馈等多维度的数据进行全面的分析，构建了高度精细的用户画像模型来帮助平台更充分、更深入、更全面的理解用户的需求，不断提高平台视频内容推送的精准度来牢牢抓住用户的心，这也成为抖音短视频平台最为独特的竞争优势。字节跳动旗下的短视频平台抖音一经推出便风靡全国，受到了广大年轻人的青睐。

1.4 主要研究内容及组织架构

1.4.1 主要研究内容

本文研究主要完成了用户画像模型的构建以及系统应用的实现，在 RFM 客户关系模型的基础上做了相应的优化和设计，构建出了较为高质量的电商平台用户画像，并对数据仓库的存储效率上的进行了优化工作，为用户画像模型构建提供了有力的数据服务支撑。然后提出了一种基于 Vision Transformer 的商品特征分类的预测算法，用户提升电商用户画像平台系统对商品数据的处理效率和准确性。最后，设计了基于 Spark 的用户画像平台，用于处理电商平台上产生的海量用户数据。主要研究内容如下：

（1）基于 RFM 模型改进优化后的用户画像模型构建方法

（2）基于 Vision Transformer 的商品分类识别方法

（3）基于 Spark 的电商用户画像平台的应用设计与实现

1.4.2 论文的组织架构

本论文研究内容由六个主要章节构成，各个章节的内容概况如下所示：

第 1 章为绪论部分，在绪论开篇处首先介绍了论文的相关研究背景和研究意义，由此展开进一步概述了用户画像在国内外的研究现状，对用户画像的研究前沿现状有一个较为全面清晰的认识，最后介绍了本文的主要研究内容和组织架构。

第 2 章为用户画像相关技术基础，此章节主要介绍用户画像研究所应用的大

中国知网 https://www.cnki.net

数据处理相关技术架构，为后续的相关研究工作开展提供了充分的技术理论依据。

第 3 章为用户画像模型的构建，本章主要对电商数仓存储效率进行进行优化处理，提高用户行为数据和业务数据的存储效率，充分保障数据存储的安全性，为用户还行提供了高质量的数据保障。并提出了基于 Vision Transformer 的商品分类预测方法并对其进行了相应的优化，对大规模商品数据进行快速精准的分类，提高商品分类的速度以及精准度，为后续的用户标签的精确分类扫平了技术上的障碍。同时基于 RFM 模型上做了相应的设计和改进，并结合 K-Means 聚类算法相结合的方式完成了用户画像模型的构建，提高了用户画像的科学性和准确性。

第 4 章为基于 Spark 的电商平台用户画像系统的应用。本章节首先介绍了用户画像平台的整体架构和设计流程，接着对 Spark 电商用户画像平台的应用开发进行了较为详细的介绍，最后对实现的平台系统进行了界面展示，使得用户画像平台系统的具象化、成果化。

第 5 章是本文的系统测试与分析部分，这部分主要对本论文的电商用户画像系统进行了全面的测试，充分保证了整个用户画像系统功能的正常、稳定和可靠。

第 6 章是本文最后的总结与展望部分，这部分主要对本论文的电商用户画像的研究工作进行总结并对今后的学习研究做了进一步展望。

中国知网 https://www.cnki.net

第 2 章 用户画像技术架构

2.1 用户画像

2.1.1 用户画像概述

用户画像是通过数据驱动[24]的方法来对用户行为数据进行深入的分析后所生成的用户详细特征的数字化描述，它不仅仅包含用户的年龄、婚配、性别、地址、学历等基本信息，还包括了用户的价值观、浏览习惯、购买记录、兴趣爱好、消费习惯、购物频率、教育背景等更为深层次的行为特征，是一种十分有效的刻画目标用户的工具。用户画像的基本元素如图 2-1 用户画像基本要素图所示。

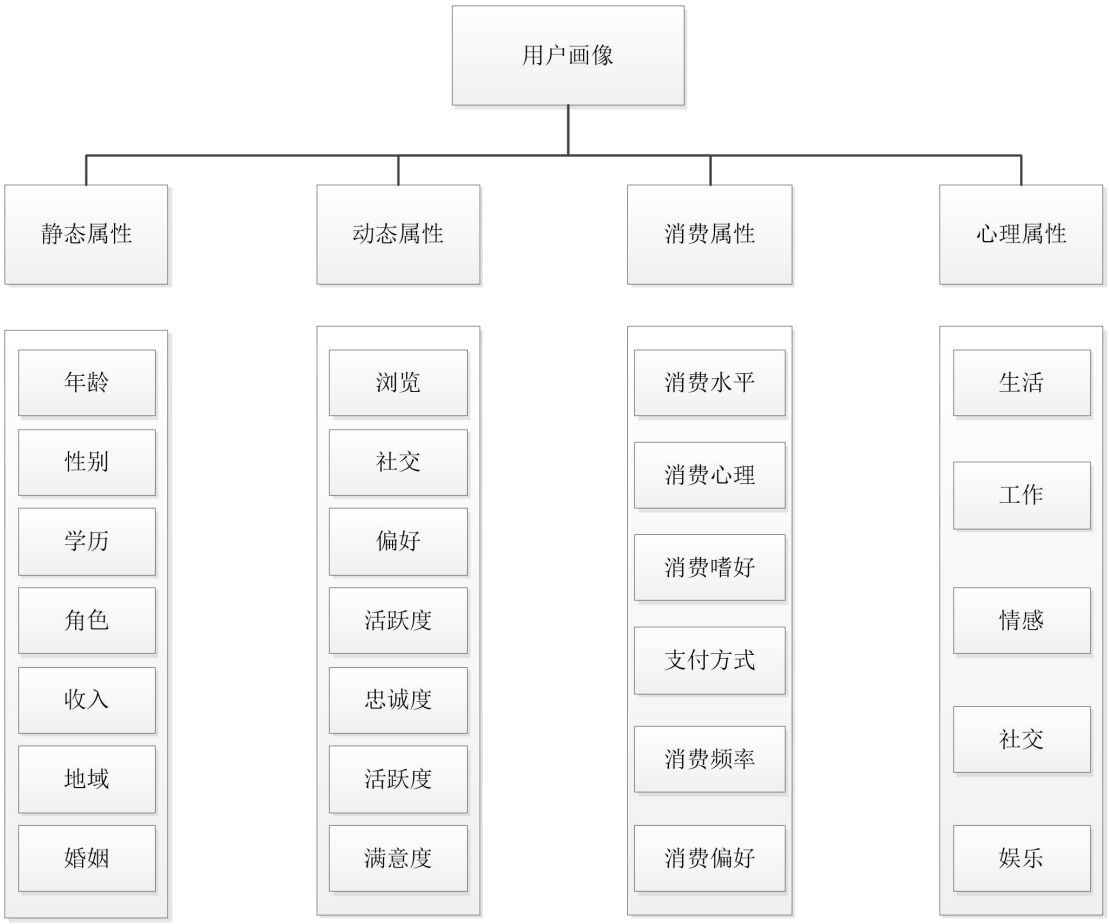

图 2-1 用户画像的基本要素图

用户画像所生成的用户角色并不指某一个具体的用户，它是基于真实的某一类用户的抽象化，是真实用户的虚拟代表。用户画像根据目标的行为观点的差异来划分不同的类型，然后再将其组织在一起提炼出具有群体代表性的用户特征，从而形成对一个群体类型的用户画像。它通常是和市场与产品紧密联系在一起，具有普遍性和代表性，可以恰如其分地代表产品的目标群体和主要受众。

中国知网 https://www.cnki.net

通过对每个具体信息进行标签抽象化后再让这些抽象化的标签将用户全体形象具体化，可以让为不同用户群体提供完美契合的个性化、差异化服务。创建用户画像就是用来帮助企业深入和精准的理解目标用户，进而在产品设计和推广过程中制定更加精准的市场营销策略和产品开发计划，从而推动公司市场业务的增长。一个精良的用户画像能够帮助企业形成清晰的市场定位，及时准确地响应市场变化，显著提升公司决策的科学性和效率性。

2.1.2 用户画像的应用

用户画像是帮助企业更深入、更全面理解用户行为特征的一把绝世好剑，有了这一柄利器，企业可以更加科学地对市场用户群体进行更为细致化、精确化的划分，从而让公司的产品和服务受到人民大众的喜爱，推动公司的产品走进千家万户、惠及千家万户。出色的用户画像能够帮助企业在激烈的市场竞争中大放异彩，一枝独秀。在经历了数十年的不断发展完善和市场洗礼，用户画像技术的应用主要有如下的几个主流的研究方向：

（1）多维度用户画像：与传统单一维度的用户画像有所不同，多维度用户画像[25]的侧重点不仅仅在于用户的基本信息和行为数据，还会充分考虑到用户基本信息以外的用户的情感、价值、态度、价值观等多维度的行为特征，通过分析用户的心理和情感状态，更好的洞察用户的需求和行为意图。

（2）跨平台用户画像：随着移动互联网的广泛发展普及，手机等移动设备已经成为人们日常生活中不可或缺的一部分，用户在互联网上的活动不再局限于传统的电脑设备上，用户往往会在手机、平板以及电脑等多个平台和设备上进行网络活动，活动也日趋丰富多样。因此，充分整合和分析不同设备平台上的用户行为数据，建立跨平台的全渠道的用户画像十分有必要，这样才能更加全面和准确的了解用户的需求[26]。

（3）动态用户画像：随着科技的不断发展，人们的物质文化需求日趋丰富多样，用户的兴趣和偏好也不是一成不变的，可能会随着时间的推移而动态变化的。此时传统基于静态用户数据构建的用户画像就无法恰如其分地反应出用户的最近的兴趣和偏好情况，建立动态画像[27]可以实时的跟踪和更新用户行为，及时更新和调整用户画像，以更好的适应用户的兴趣和偏好的动态变化。

（4）增强和学习化：近些年来我国人工智能技术的发展达到了一个空前未有的状态和高度，基于机器学习和深度学习技术构建用户画像也成为了一个重要的研究热点方向。通过增强学习[28]可以从海量维度复杂的用户数据中自动学习和发现用户的特征和模式，帮助企业更好得理解和预测用户行为，进一步提高用户画像的效果和准确性。

（5）隐私保护和伦理考量：随着国家保护隐私相关的法律法规的相继出台

中国知网 https://www.cnki.net

充分展现了国家对于用户隐私保护的高度重视，因此企业在进行用户画像构建时需要充分遵守法律法规以及用户的自主选择权，应采用匿名化和加密技术等更加隐私友好的数据采集和处理方法，确保用户个人信息的安全性和机密性[29]。

2.1.3 用户画像构建流程

用户画像的构建是一个持续迭代、动态变化的复杂过程，通常包括基础数据的收集、数据清洗预处理、用户行为建模和画像构建等四个主要流程，构建流程如图 2-2 用户画像构建流程图所示。

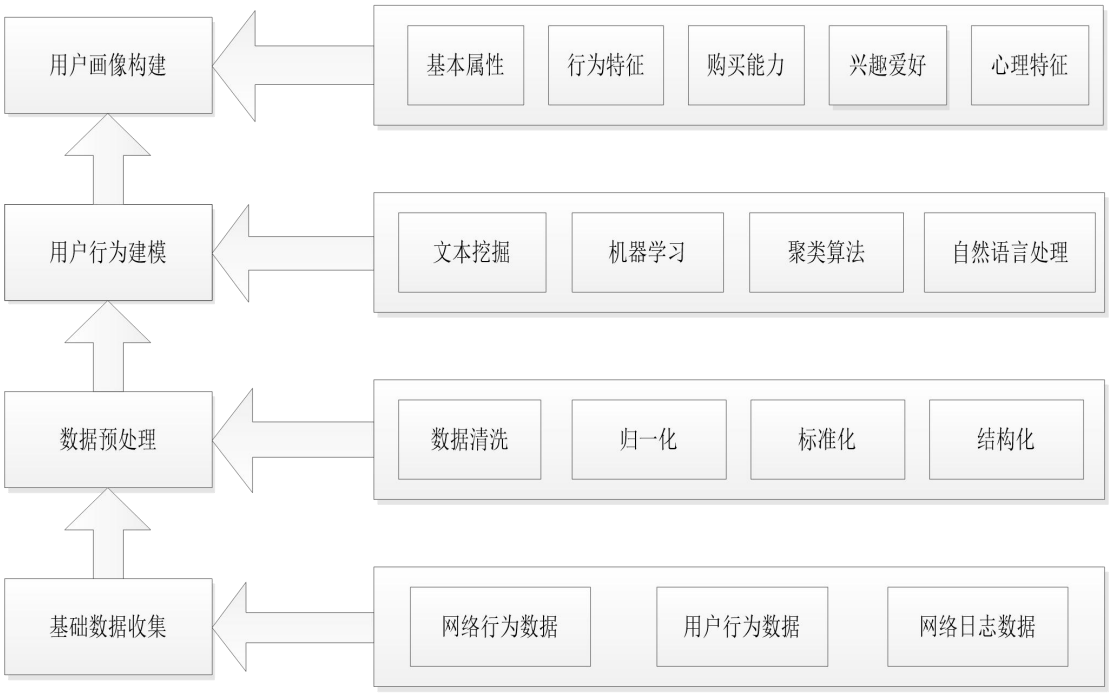

图 2-2 用户画像构建流程图

（1）基础数据采集：在用户画像的构建过程中数据往往是最为核心和关键的资源，高质量的数据往往是构建优秀的用户画像的基础。通过网站采集用户注册时所留存的姓名、年龄、性别、地址、职业、学历等基本信息，以及通过分析用户日志，采集用户在网站上进行商品搜索、商品预览、添加购物车、在线支付、商品评论等网络购物活动时所产生的用户行为数据，为用户画像的精准刻画迈出坚实的第一步。

（2）数据预处理：通常采集到的用户数据规模庞大复杂，数据质量良莠不齐，数据规格也天差地别。为了充分提高实验数据的质量，需要对这些数据进行去重、缺失值处理、数据格式转换等预处理操作。在数据预处理过程中对数据进行标准化和归一化，让来源不同的数据保持一致性，为后续进一步研究分析提供了高质量的数据支撑。

（3）用户行为建模：通过聚类算法和分类算法对采集的用户数据分别进行

中国知网 https://www.cnki.net

聚类分析和分类分析，根据用户特征精确地将用户划分为不同的群体以及不同的用户类型，以便更好的理解用户的习惯、偏好和动机，为进一步精准化构建用户画像打下坚实的技术基础。

（4）用户画像构建：根据用户行为建模环节的聚类和分类结果，再创造性地运用机器学习和文本挖掘等技术，对用户群体的特征进行标签抽象化，用户画像由此便完成了最终的构建工作。

2.2 用户画像相关技术

2.2.1 Hadoop

Hadoop[30]诞生至今也经历了二十多年的发展历史，这一概念在诞生之初时还仅仅是指 Apache 基金会旗下的一款开源的分布式基础系统架构。通过构建 Hadoop 大数据集群可以充分提高大规模数据存储和处理的潜力，充分发挥出集群在对大规模数据高速运算和存储的威力。大数据技术体系在经历了数十年的不断发展迭代以及逐渐成熟，Hadoop 所指代的概念也变得越来越宽泛化，逐渐形成了以 Hadoop 为基石的大数据生态圈[31]。为了应对 Hadoop 特定数据处理和存储应用场景的不足，可以充分组合生态圈中在各个应用场景中最合适的技术架构来提高大规模数据计算处理的效能。

经历持续不断地版本迭代和市场化推广，如今 Hadoop 已经演变到了 Hadoop3.x 版本了。Hadoop 对大规模数据的强大处理能力离不开 HDFS[32]、MapReduce[33]和 YARN[34]这三大核心组件相互协作支持，Hadoop 组件架构如图 2-3 Hadoop 组件架构图所示。

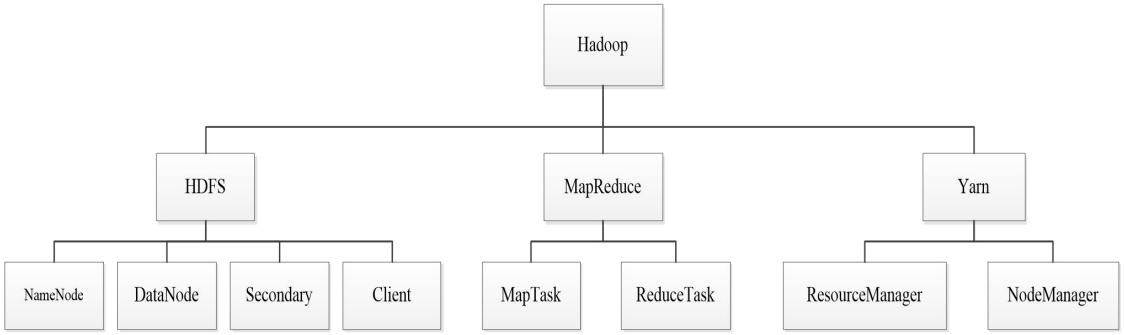

图 2-3 Hadoop 组件架构图

其中 HDFS 是负责海量数据存储和管理的分布式文件系统[35]，通过将数据分别存储在集群中的多个节点中来保证数据存储的高容错性。NameNode[36]是 HDFS 用于管理名称空间、副本配置策略以及数据映射信息的主节点，而 DataNode 是用来存储实际的数据块并执行数据块的读写操作的从节点，Secondary 则用于定期保存元数据的快照，用于在紧急情况下辅助恢复 NameNode，Client 则是用于与 NameNode 和 DataNode 进行交互操作的一把利器，界面化的

中国知网 https://www.cnki.net

操作方式为用户提供了操作上的便捷。MapReduce 常用于对大规模数据进行并行处理，其核心原理是将复杂的计算任务拆成可以执行的小任务，并利用集群中的多个节点通过 Map 和 Reduce 两大阶段来对大规模数据进行并行处理，充分地利用集群资源和提高数据处理效率。YARN 主要负责对集群的资源进行调度[37]，为多个应用程序有序分配和调度集群中的计算资源，通过动态监控和管理系统任务的执行来确保任务高效可靠地完成。

2.2.2 Spark

Spark[38]是一款快速、通用的分布式大数据集群分析引擎，旨在通过大规模数据处理和分析为用户提供高效、易用的解决方案。它最早源自加州大学伯克利分校的 Matei、Zaharia 等[39]发表的一篇关于弹性分布式数据集的学术论文，后由加州伯克利分校的 AMP 实验室所开发实现并开源的大数据并行处理技术架构，现如今已经成为 Apache 基金会旗下的最受市场追捧和广泛应用的顶级开源项目之一。Spark 完美承袭了 MapReduce 在分布式并行计算场景下的全部优点，并针对 MapReduce 在迭代计算和交互式查询等应用场景下的效率问题而做了大量的优化，提供了更为灵活的内存计算和更加强大的数据处理能力。Spark 的体系架构直观展示如图 2-4 Spark 系统架构图所示。

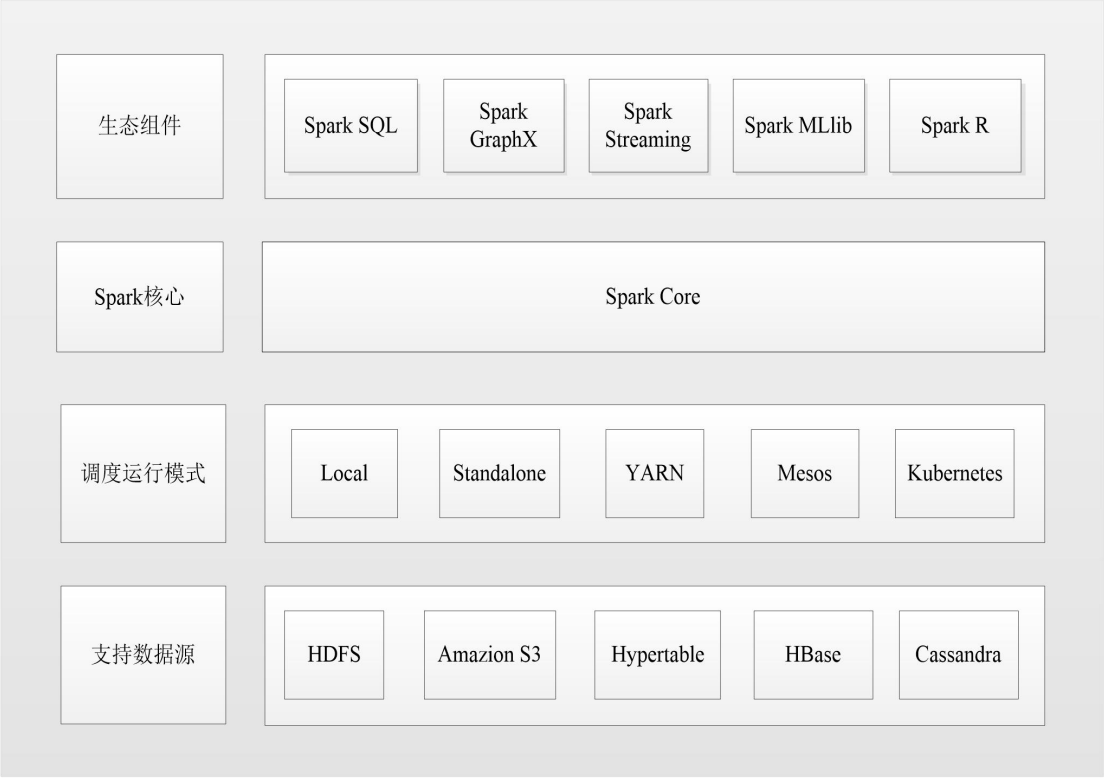

图 2-4 Spark 系统架构图

Spark 由多个负责不同数据处理任务的子组件组成，Spark Core[40]作为 Spark 的基础计算引擎为其他组件提供了基本的任务调度、内存管理、容错处理和存储

中国知网 https://www.cnki.net

系统的交互等底层服务，并且包含了用户并且处理数据的 API 来对数据进行创建、转换和操作。Spark SQL[41]则是用于进行结构化数据处理的核心组件，通过熟悉的 SQL 命令的方式来更加方便地处理结构化数据。Spark SQL 还能够与 Hive 完美的结合，直接使用兼容 Hive 的 SQL 查询方式来数据查询，并且以此为基础还可以进一步分析复杂的数据。Spark Streaming[42]是一个支持高吞吐量、可容错处理的实时流式数据处理框架，能够处理包括文件、Socket[43]、Kafka[44]以及 Kinesis[45]在内的多种数据源的实时数据流，其核心工作原理是将复杂的实时数据分解成一系列微小的作业进行分批次处理，以实现高效的实时数据处理操作。Spark MLlib 则是 Spark 内置的一个常用机器学习库，其囊括了分类、回归、聚类、推荐算法在内的常用的机器学习算法[46]，经过一些算法优化措施处理后，可以充分发挥出 Spark 的分布式计算的巨大潜能，进而进行高效的大规模数据训练。Spark GraphX[47]则是一个十分强大的分布式图计算库，提供了十分高效的图计算和图挖掘算法 API 以及丰富且功能强大操作算子，极大地方便了用户对海量且复杂的分布式图片进行高效化处理。Spark R[48]则是为 R 语言开发人员所量身定做的一个编程接口，适用于大规模数据集场景下的统计分析工作。

Spark 以其出类拔萃的大规模数据分析和处理能力、卓越的处理速度以及广泛的通用性而在众多的大数据技术中脱颖而出，现如今已逐渐成为全球范围内最受国内外众多企业所广泛青睐的大数据处理方案，像 Amazon、Facebook 和 Google 等具有全球影响力的国外高科技巨头们已经广泛采用 Spark 技术来分析和处理公司平台服务过程中所产生的海量用户行为数据。国内电商巨头阿里巴巴则是在电商领域中应用 Spark 技术架构而大放异彩，其利用 Spark 强大的数据处理能力开发了符合自身业务发展的大数据生态—MaxCompute[49]。显著优化了用户的使用体验，还基于 Spark，并且在此基础上实现了规模化的分布式计算和数据仓库管理。腾讯在国内社交领域中可谓一枝独秀，依托旗下的国民级社交平台—微信和 QQ 所产生的包括点赞、评论、分享、动态、聊天记录在内的海量用户行为数据来构建和分析社交网络图谱，借助 Spark 强大的分布式计算能力来帮助公司分析用户之间的关系强度、影响力和网络结构，以此为基础来识别用户的关系网和社交圈层，进一步推动公司产品更加精准的满足用户需求。

2.3 本章小结

本章节主要对用户画像的概念、应用场景以及构建流程做了一个较为细致的梳理和阐述，并且着对用户画像所应用的大数据技术以及其基本工作原理做了详细的剖析，为本文研究内容的技术架构的选用提供了有力的理论论据支撑，束上起下，为后续进一步的研究开展迈出了最为坚实的关键一步。

中国知网 https://www.cnki.net

第 3 章 基于 RFM 模型的用户画像模型的应用实现

3.1 数据存储的设计与优化

3.1.1 数据仓库的设计

数据仓库[50]在用户画像模型的构建中扮演着必不可少的角色，而对大量的用户数据的收集则是用户画像模型构建成功与否的关键一步。用户们在电商平台上购物时会产生数不胜数的用户数据，并且形形色色的用户数据通常还来源于多个不同的渠道和系统，不但包含电商平台本身因电商活动而产生的用户的浏览历史、购物记录、搜索行为、购物车行为等用户行为数据，还包括了用户注册信息、会员等级、优惠卷使用情况等客户关系数据，并且伴随着用户通过社交媒体分享商品时会产生用户评论、分享和讨论等用户社交数据，在最终的商品结算环节还会产生用户交易记录、支付方式、支付频率、支付金额区间等用户支付数据。面对分散在多个系统中的海量用户数据，电商数据仓库可以很完美地将这些异构数据源集中整合到一个统一的存储系统中并进行统一的分析和管理，为用户画像模型的构建提供了强有力的数据支持。

面对日趋庞杂且来源多样化的用户数据，为了更加高效的对数据集进行管理，本次数据仓库采用了一种十分高效、科学的分层架构设计方法，让每一层次都有着清晰明确且独立的职责和目标，让数仓系统架构设计更加的模块化、科学化，让企业可以充分根据自身实际业务需求和数据规模的变化而灵活调整和扩展各个层次的数据存储和处理能力，进一步方便企业对数据仓库的管理和扩展。与此同时，在对数仓的各个层级进行逐级优化后充分保障了数据的可靠性、准确性、一致性和完整性，为用户画像的构建提供较为高质量的数据支撑。对数据仓库进行分层设计也更有助于每一层次的问题能够被单独定位和修复，并且数据在不同层次的分布设计也让系统的扩展性有了突飞猛进的飞跃，可以在不会影响系统整体的功能的情况下在某一层次中单独实现新增业务需求，这显著增强了系统的可维护性和扩展性，降低了后续数仓系统的维护难度和维护成本。各个层级之间的紧密联系，不同层次的明确分工也使得不同层次能够各司其职地承担不同的计算任务，并结合分区存储、索引优化和缓存等技术可以大大提高数据仓库的整体查询性能，有效避免了单一层次的性能瓶颈。层级清晰的分层架构设计还有利于企业实施科学高效地数据治理策略，企业在进行数据权限管理、数据质量审查以及合规性审计工作时也水到渠成，确保数据的安全和合规，推动企业从“数据孤岛”向“数据驱动”的飞越，从而为企业带来更高的业务价值。基于上述分析，本次

中国知网 https://www.cnki.net

数仓选用了市面上主流的四层分层架构设计，将整个数仓系统分为 ODS 原始数据层、DWD 数据明细层、DWS 数据服务层和 ADS 数据应用层这四个层次，数据仓库分层架构如图 3-1 数据仓库分层架构图所示。

图 3-1 数据仓库分层架构图

数据仓库的四层架构（ODS、DWD、DWS、ADS）是更为灵活，可扩展和可维护的架构设计，每层各司其职可以使得不同的层级为不同的业务需求提供服务，从原始数据采集再到高级分析应用环节之间形成了一个完整的数据处理闭环，通过这种分层架构可以更加高效地管理平台产生大规模的用户数据，为企业决策提供全面、实时和准确的高质量数据支持。接下来是对数据仓库的四层架构做一个系统的介绍：

（1）ODS 原始数据层（Operational Data Store）

ODS 层是数据仓库架构中用于接收和存储来自各个业务系统中提取的原始数据的入口层，负责对操作数据进行实时采集和初步整合，是用来存储来自多个不同业务系统中的一些未经过复杂数据转化处理的较为原始的业务数据。这一层

中国知网 https://www.cnki.net

级通常是一个集成的、实时的存储区域，更加注重数据的实时性，更新频繁的事务性数据是支持当前业务状态的快速查询的坚实基础，为后续的数据分析和决策提供了一个集中化、可实时访问的基础数据源。

（2）DWD 数据明细层（Data Warehouse Detail）

DWD 层是数据仓库架构中的第二层级，是负责对从 ODS 层所提取的的数据进行数据清洗、整合、转换和规范化处理后将其中的脏数据、垃圾数据和不规范的数据过滤掉，以确保数据的准确性、一致性和完整性，同时也解决了不同系统间数据的不兼容问题，使得转换后的业务数据更加满足业务需求和分析。DWD 层通过将来自 ODS 层的原始数据转换成结构化和符合业务逻辑的业务数据，为更高层级提供干净、完整、细粒度的高质量业务明细数据，能够为后续的决策支持和数据分析提供更详细、更精准以及更符合报表和分析需求的数据支撑。

（3）DWS 数据服务层（Data Warehouse Service）

DWS 层通常是指数据仓库的存储层，这是数据仓库架构中第三层的核心层，由于其覆盖的应用场景十分广泛，因此又被称为数据集市或宽表。这一层也是数据仓库的公共汇总层，在这一层将会进行轻度汇总工作，是可以用来集中存储所有历史数据的区域，能够显著提高复杂查询和多维分析的效率和性能。与 DWD 层有所不同，DWS 层的数据通常不需要频繁更新的长期历史记录，它根据 DWD 层上提取的基础数据整合汇总来分析某一个主题域的服务数据，为业务人员提供一个数据仓库的历史视图，为业务人员内更加科学高效地对历史数据进行深度分析和决策支持。

（4）ADS 数据应用层（Application Data Store）

ADS 层通是数据仓库体系中极具战略意义的最顶层，它通常是用于存储那些直接面向业务分析、数据挖掘和高级分析需求这些经过聚合、精细化和定制化等高级分析处理后的结果数据集，为企业业务系统和应用提供服务接口和数据访问服务。ADS 层面向的对象是业务应用和最终用户，为用户提供了便捷的数据访问接口和服务，通过将数据仓库的数据集成到业务应用中来的高度定制化方式来为特定的业务问题提供精准的解决方案和实时支持，为企业科学的业务决策指导，加快了企业业务应用的开发和部署效率。通过报表、仪表板等可视化技术还可以将 ADS 层的数据生成一个直观的、易于用户理解的可视化报告，以直观的方式帮助用户更好地理解和解释数据的分析结果。

（5）DIM 维表层（Dimension）

DIM 层是数据仓库中用于存储和管理业务分析相关的维度信息的管理层，这一层的数据以维度为核心进行组织并以结构化的表形式存储，提供了包含包括事实表和维度表在内的与业务相关的维度模型，用来描述和解释事实表中的业务

中国知网 https://www.cnki.net

指标，如销售额、订单数量、成交量等。精心合理的维度表设计可以构建灵活、易用的数据模型，为企业决策提供关键的市场洞察和多维度分析能力。

3.1.2 数据存储优化

数据存储的性能往往会受到数据处理、存储和查询等多方面因素的影响，在数据量爆炸式增长的大数据时代下对数据存储性能优化和调优也逐渐成为一个首当其冲的痛点问题。联系到本文研究工作的实际情况并结合相关实验结果分析，本次对于数据存储的优化工作主要集中在对数据存储格式的选择、数据处理和分区优化这三方面着手。

（1）数据存储格式甄选

数据的存储格式往往会和数据仓库的性能、存储效率以及查询效率表现呈现正相关，不同的存储格式在数据存储的效率、查询速度、压缩比以及 IO 性能等方面有着各自的优势以及不足之处，不同的数据存储格式在同一应用场景下的性能表现往往会天差地别，因此选择合适的数据存储格式对于数据仓库性能的提升显得至关重要，在不同的应用场景下选择与之契合的数据存储格式往往能让数据仓库的性能达到事半功倍的奇效，从而推动数据仓库的性能表现实现一个跨越式的飞跃。本文经过对 14.18GB 的实验数据分别采用四种常用的数据存储格式下的存储空间、存储耗时以及查询速度三方面表现做了权衡对比后果断选择了各方面表现俱佳的 ORC 存储格式来存储数据，实验结果对比相关详情如表 3-1 存储格式性能测试表所示。

表 3-1 存储格式性能测试表

数据格式	Avro	Parquet	ORC	RCFile
存储空间	9.46GB	1.56GB	0.26GB	9.45GB
存储耗时	75.26s	74.28s	74.16s	75.06s
查询耗时	40.36s	4.43s	1.56s	15.07s

（1）数据倾斜优化

数据倾斜[51]是指在分布式计算环境下进行大规模数据处理时，数据负载在不同节点之间分布不均衡，某些节点由于需要处理的数据量过大导致数据处理任务过重，而其他节点数据处理任务情况则截然相反，从而导致了整个集群内的资源分配严重失衡，从而会显著影响了整个数仓系统处理数据的性能和效率。数据倾斜是数据仓库中的一个最为常见的性能问题，它会导致部分节点的任务处理时间过长进而较大幅度延长了整体作业的完成时间，降低了整个数据仓库的处理性能。并且部分节点过度负载而其他节点较多的空闲也将会导致系统资源利用率低下，造成集群内计算和存储资源的严重浪费。在极端情况下，某些节点可能因为处理过多数据而导致内存溢出或磁盘空间不足等问题，最终会导致任务失败并且系统

中国知网 https://www.cnki.net

崩溃的风险也显著提高，这对集群的稳定性和作业的可靠性构成了严重的威胁。

为了充分保障数据仓库在进行数据处理任务时的稳定性和作业的可靠性，采取强有力的优化措施来规避数据倾斜所带来的严重后果也刻不容缓。结合自身研究所拥有的系统资源实际情况，本人做了如下针对性的优化措施：首先，在进行数据处理前对数据进行抽样分析、数据标准化等数据预处理操作，尽早识别并处理可能导致倾斜的热点数据，降低数据倾斜的风险。其次，通过重新分配数据来避免数据在少数几个节点中集中，实现每个节点处理的数据量更加的均衡化。另外还可以通过分布式缓存技术可以通过将热点数据分别缓存到多个节点中来分散数据的访问压力，以此来减轻数据倾斜所带来的不利影响。使用专业的监控工具也是检测数据倾斜出现的又一柄利器，通过负载均衡[52]机制实时地监控各节点的负载情况，根据负载均衡策略动态调整数据分配，有效避免单一节点过载。

（2）分区优化

数据仓库分区是指对数据进行物理上的划分，通过将大规模的数据集按照特定的逻辑规则划分若干个更小的、更易于管理的物理块来实现高效地数据管理。每个分区分别对应一个逻辑数据单元，分区的存在使得查询仅需要扫描与之相关的分区上更小的数据集，避免了全表扫描所造成的性能瓶颈以及资源消耗，从而极大地减少了扫描和处理的数据量，显著减少了 I/O 操作和查询时间。分区使得查询可以在多个分区上并行执行，这样可以充分利用系统资源，大幅度提升查询效率和系统吞吐量。同时不同分区的数据可以进行独立的管理和维护，如分区级别的备份、恢复、归档和清理工作，如果某个分区的数据损坏，只需要恢复该分区的数据，而不会影响到其他分区的数据，减少了对整个数据集的影响，提高了数据的可靠性和系统容错性。同时分区也提供了数据隔离的效果，不同分区的数据不会相互影响，这减少了数据之间相互干扰和冲突的风险。分区的存在也可以使得数据加载并行进行，不同分区的数据可以同时得到加载，大幅度提升了数据仓库整体数据加载速度。分区的划分还可以显著提高数据的存储效率，通过对每个分区进行单独压缩处理，并结合不同的数据压缩策略来优化存储效率，大大节省了数据仓库的存储空间，而在删除过期或无用数据时，也只需要裁剪相关的分区即可而不必操作整个表，数据的管理效率也得到了进一步的提升。

一个大型的电商平台的数据规模往往十分巨大并且其规模还会随着时间的推移而累积剧增，其日均产生的订单数量往往会达数百万之巨。面对规模巨大的平台数据所带来的查询性能压力，时间分区的方法简直是为大规模电商数据等时间敏感性数据应用场景所量身定制的最佳解决方案。根据时间戳来将数据划分成多个时间范围区间，如按照日期、季度或者年度进行分区划分，这使得对数据生命周期的管理变得更加方便，通过对过期数据进行定期归档和删除处理来保持数

中国知网 https://www.cnki.net

据仓库的持续高效运行，定期添加新分区和移动旧分区的滚动窗口数据管理策略也确保了数据仓库数据的实时性和有效性。通过时间分区可以快速定位到特定时间的数据让查询只需要在相关的时间范围内进行而不会影响到整个数据仓库数据，显著提升了对于特定时间范围内商品数据的查询效率，大大方便了电商平台对商品历史数据的管理，显著提升了数据仓库的整体性能表现。本文所采用的数据仓库时间分区策略如图 3-2 数仓库分区策略流程图所示。

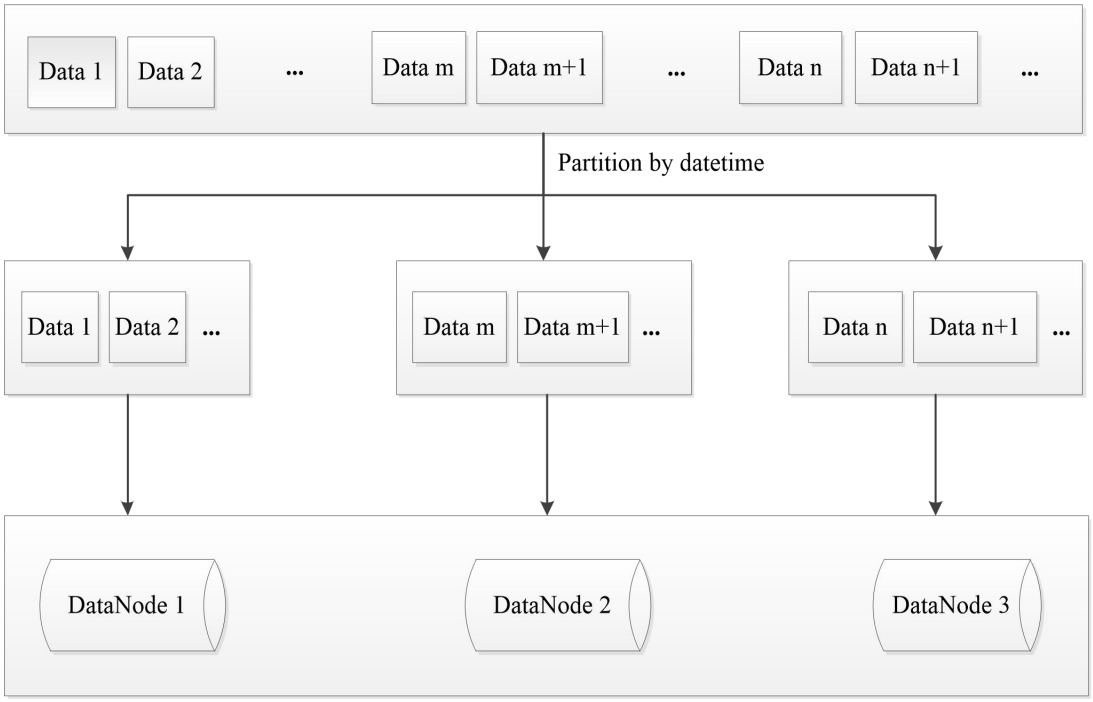

图 3-2 数据仓库分区策略流程图

3.2 用户画像模型的构建

3.2.1 数据集制备

数据集的质量往往对实验的成功与否具有决定性的影响，高质量的数据集能够确保实验的可靠性、模型的泛化能力以及应用的实际价值，为应用研究提供可靠的结论和有价值的洞察。为了让构建的用户画像模型更加的贴近实际的平台购物体验，本次实验选择的数据集数据均为真实的电商商品数据。本次实验所选用的数据集式国内最具代表性的电商巨头平台京东平台所提供的一个公开的商品图片数据集—Products-10K，其提供的数据均为真实的电商平台产生的商品数据。由于京东在国内电商领域的独特地位，其提供的公开数据集也十分具有代表性，其商品数据量十分齐全、数据量也十分庞大，包含衣服、裤子、鞋子、手表、雨伞、玩具等常见日用品在内的众多商品数据。该数据集中数据的格式均为 tsv 格式，总共包含了 140000 多条训练数据以及 50000 多条测试数据，商品数据的数

中国知网 https://www.cnki.net

据量和丰富程度可以充分保障用户画像生成的最终效果。

为了让生成的用户画像模型尽可能达到理想的效果，本次实验前对数据集进行了统一的预处理。首先本人对所有的实验选用的数据图像规格大小统一调整为 224×224，并且本次实验还对数据集中的训练数据和测试数据按照 10:2 的比例划分来进行实验。为了进一步提高实验数据的质量、多样性和代表性，事先将从原始数据集中选取的 12000 多条商品数据进行了随机裁剪、翻转、旋转和颜色调整等数据增强处理，充分保证了实验数据的质量以及丰富度，让模型得到了更为充分多远的训练，以此来提高模型的泛化能力。同时还对实验数据进行了采样、欠样等方法对实验数据进行了清洗操作，也对实验数据中缺失值、异常值、重复值以及数据格式进行了修正和处理，也避免了商品数据分布不平衡对实验效果的不利影响。商品数据集部分图片如图 3-3 商品数据集样例展示图所示。

图 3-3 商品数据集样例展示图

3.2.2 评价指标

在衡量一个模型的性能效果表现时往往需要通过一些特定的评估指标来展现，而了解这些评估的指标为我们提供了在各种应用场景下相对客观的模型性能表现评估，这对于我们更好地了解模型的泛化能力、不同模型之间的对比以及模型的优化工作具有重要的指导意义。对于本模型的整体效果表现，我们通过精确率（Precision, P）、召回率（Recall, R）以及 F1 值（F1-Score, F1）这三个常见的评价指标来评估。其中关于如上的三个评估指标的具体计算方式分别如公式 3-1、3-2、3-3 所示。

中国知网 https://www.cnki.net

$$\mathrm{P}=\frac{TP}{TP+FP} \tag{3-1}$$

$$\mathrm{R}=\frac{TP}{\mathrm{TP}+FN} \tag{3-2}$$

$$\mathrm{F1}=2\times\frac{P\times R}{P+R} \tag{3-3}$$

其中 TP（True Positive）是指真正例，即被正确分类为正例的样本数，TN（True Negative）是指真反例，即被正确分类为负类的样本数，FP（False Positive）是指假正例，即被错误分类为正例的样本数量，而 FN（False Negative）是指假反例，即被错误分类为负数的样本数。样本识别的精确率表示被预测为正类的样本中实际为正类所占的比例，而召回率则表示实际为正类的样本中预测为正类所占的比例，F1 值则是综合了精准度和召回率二者的调和平均值，是用于不平衡的数据集处理效果常用衡量指标。

3.2.3 实验环境

本次实验环境相关配置情况如表 3-2 实验相关参数配置详情表所示。

表 3-2 实验相关参数配置详情表

CPU	11th Gen Intel(R) Core(TM) i7-11800H
内存	16GB 2.50GH
操作系统	Window11
开发工具	PyCharm 2020.1
硬盘	512GB
Pytorch 版本	1.12.1
开发语言版本	Python 3.8.5

3.2.4 基于 Vision Transformer 的分类预测算法

Vision Transformer[53]是一种由 Google 公司的 Research 科研团队于 2020 年首次提出的一种基于 Transformer[54]架构的全新的图像处理模型，通过将图像识别问题创造性地转化为类似于自然语言处理的序列建模任务，从根本上改变了传统的计算机视觉方法。它的出现首次将 Transformer 架构从自然语言处理引入到了计算机视觉领域，并且基于 Transformer 架构自身的自注意力机制[55]可以更好的捕捉全局特征，成功克服了传统图像处理模型在局部特征依赖较强的局限。ViT 在大规模图像分类任务中优势尤为显著，特别是在使用预训练模型进行微调的情况下能取得比传统图像处理模型更好的性能表现，现如今已迅速成为了图像分类任务重的热门领先的技术。尽管严临着这来自计算复杂度和数据需求的严峻挑战，但是随着计算机资源的不断提升和数据集的扩展，ViT 在大规模图像识别领域的

中国知网 https://www.cnki.net

优势也会越来越显著，应用前景也会变得十分广阔。

Patch Embeddings（图像分块）、Position Embeddings（位置编码）、Classification Token（分类标记）、Linear Projection（线性投影） 和 Transformer Encoder（Transformer 编码器）这五大部分构成了 ViT 模型的核心组件，通过五大核心组件之间的相互分工协同工作，ViT 能够十分高效地处理和理解图像数据，实现高效的图像分类和识别任务。ViT 的模型架构如图 3-4 ViT 模型架构图所示。

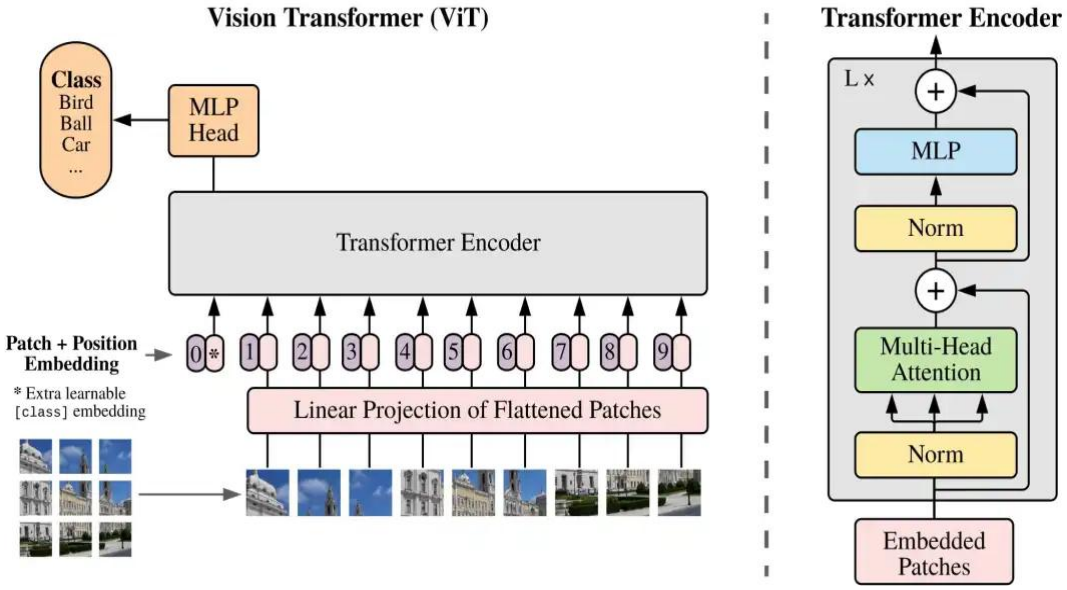

图 3-4 ViT 模型架构图

如图 3-4 ViT 模型架构图所示，ViT 的核心工作原理就是先通过 Pathch Embeddings 组件将输入的图像分割为固定大小的图像块（patch），如将一个 224×224 的图像分割成多个 16×16 的图像块，这样整个图像被分割成 14×14=196 个图像块后二维图像数据的每个图像块将被展平为一个一维向量后作为模型的输入转化为类似序列的结构。在对图像进行分割工作后为了更好地理解图像的结构，Position Embeddings 组将会给图像添加上位置编码信息，这些位置编码信息能够让模型识别到每个图像块在原图中的位置，确保 Transformer 能够捕获图像块之间的空间关系。Linear Projection 组件负责对每个展平后的图像块向量应用一个线性变换，即通过一个可学习的权重矩阵将其映射到一个高维空间中，从而将图像块的像素信息转换成高维的嵌入特征向量，使其包含语义信息以便于后续的 Transformer 编码器做进一步处理。假设展平后的图像块向量长为 P，投影后的向量长度为 D，通过线性变换后将每个长度为 P 的向量投影到长度为 D 的向量空间。这个过程可以转化为如公式 3-4 所示。

$$X' = W \cdot Y + b \tag{3-4}$$

其中 W 是权重矩阵，X 是展平后得到的图像块向量，而 b 则表示偏置向量。再对图像进行线性变换处理后基于 Transformer Encoder 组件的多头注意力机制

中国知网 https://www.cnki.net

[62]来捕捉图像块之间的关系，通过并行计算多个不同的注意力头来关注不同的图像特征，对每个图像块与其他图像块之间的相似性分数进行计算后生成自注意力分布，从而实现全面的图像理解。对于每一个嵌入的向量需要进过一个自注意力层的计算，计算公式如公式 3-5 所示。

$$Attention(Q,K,V) = Soft\max(\frac{QK^T}{\sqrt{d_k}}) \tag{3-5}$$

其中 Q 是来自输入嵌入向量的查询矩阵，K 是来自输入嵌入的键矩阵，V 是来自输入嵌入向量的值矩阵，而 d_k 则是用于缩放处理键的维度。经自注意力机制处理后的输出结果将杯传递到全连接的前馈神经网络[56]中进行进一步处理。经过每个自注意力层之后的应用两层线性变换和激活函数来对注意力输出进行非线性变换来增强特征表示能力，并在对每个子层之间引入残差连接和层归一化来稳定训练过程，从提高模型的整体性能表现。最后根据 Transformer 编码器中输出到 Classification Token 组件中的分类标记来表示整个图像的全局特征，将分类标记的最终表示通过全连接对图像特征进行提取和分类等任务，并输出图像最终的类别预测。

为了验证上文所述模型的显著优越性，本次算法实验总共对包包、衣服、鞋子、灯泡、风扇、手表、行李箱、玩具、衣服、裤子、雨伞等十种常见商品在内的总计 12000 多条测试数据进行了类别预测准确度验证，本次商品类别预测效果分别从识别准确率、召回率和 F1 值这三方面指标来综合评估。本次实验的商品类别预测的效果如表 3-3 ViT 模型商品类别预测效果指标表所示。

表 3-3 ViT 模型商品类别预测效果指标表

商品类别	准确率/%	召回率/%	F1 值/%
包包	97.12	96.19	96.65
衣服	90.99	97.12	93.95
灯泡	96.26	99.04	97.63
风扇	100.00	91.67	95.65
裤子	97.00	94.14	95.57
玩具	99.01	96.15	97.56
鞋子	100.00	98.11	99.05
雨伞	94.44	98.08	96.23
手表	99.05	99.05	99.05
行李箱	99.01	98.04	98.52

从表 3-3 ViT 模型商品类别预测效果指标表中可以很容易看出，基于 Vision Transformer 的分类预测算法准确性十分之高，甚至部分商品的识别准确率还能达到 100%，其最低的准确率类别也有 90.99%。并且结合此次实验的商品分类识别结果中的召回率以及 F1 值情况来看，该分类预测算法的实验数据正例的识别能力很强，并且其在分类预测的准确性和召回率之间也保持了一个较好的平衡。为了进一步凸显本文所用模型的性能优越性，本次还将 Vision Tranformer（ViT）

中国知网 https://www.cnki.net

模型和经典的CNN模型以及ResNet模型基于同一实验环境配置并在同一数据集上进行了对比实验，三个模型对商品识别准确率对比如图 3-5 模型识别准确率对比柱状图所示。

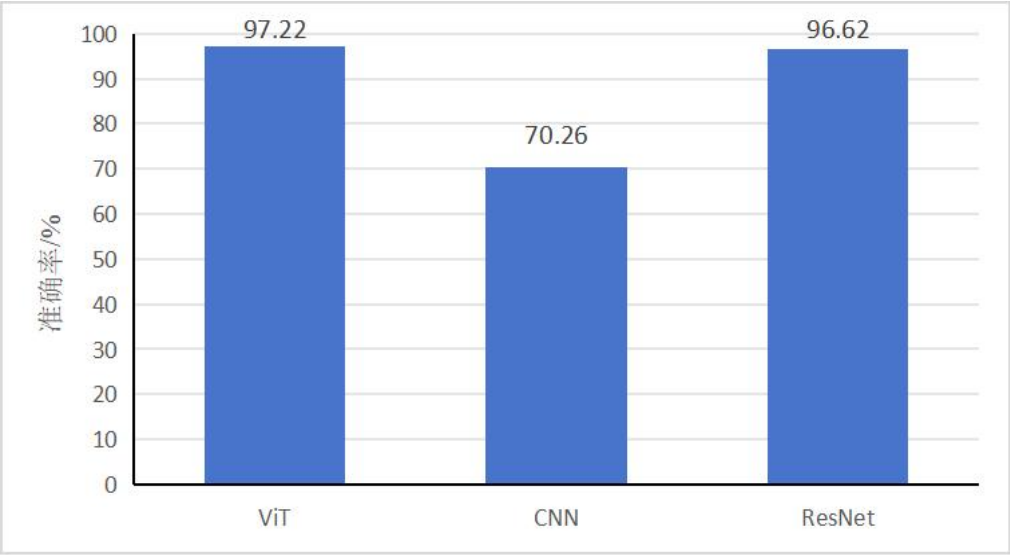

图 3-5 不同模型识别准确率对比柱状图

从图 3-5 不同模型识别准确率对比柱状图可以很明显地看出，基于 Vision Transformer 的分类预测算法准确性十分之高，远远超过传统的 CNN 模型，又略好与 ResNet 模型的识别效果。本次实验除了以不同模型之间的识别准确率比较外，还比较了不同模型之间的召回率和 F1 值，这三个模型评估指标的实验结果如表 3-4 不同模型识别总体效果指标表所示。

表 3-4 不同模型识别总体效果指标表

训练模型	准确率/%	召回率/%	F1 值/%
CNN	70.26	69.09	68.89
ResNet	96.62	93.37	96.42
ViT	97.22	97.14	97.15

从表 3-4 不同模型识别总体效果指标表中可以很明显看出 ViT 模型的识别准确性不但好于其他两个模型，并且根据本次实验所得到的召回率和 F1 值可以判断出 ViT 模型整体效果高于其他两个模型，在面对不平衡的数据集中显示出了更为强大的处理能力。

虽然本次实验中 ViT 模型的具有效果十分优异，但是不同实验参数设置也有可能直接影响到模型的实际表现效果，因此还可以对模型作进一步优化，基于多次实验结果权衡考量，在实验的时将参数 lr 设置为 0.001，epoch 参数设置为 10，bath_size 选取 20 时模型可以在此设备环境配置下达到最为理想的效果，其总体准确率达到 98%以上，从而验证了本文所提模型优化方法的可行性和优越性。

中国知网 https://www.cnki.net

3.2.5 基于 RFM 模型结合 K-Means 算法的用户画像模型构建

RFM[57]模型是一种广泛应用于市场营销、客户关系管理（CRM）和电子商务领域的客户价值评估和行为分析的经典方法，它通过量化客户的活跃度和价值来帮助企业实现客户分群和精准营销，是一种简单且十分实用的客户分析工具。在实际应用的场景中企业还可以根据自身业务特点来灵活调模型参数，进一步提升分析的效果。RFM 分别是 Recency、Frequency 和 Monetary 三个单词的首字母缩写组合而成，其中 R（Recency）代表消费者在电子商务平台最近一次消费的时间，F（Frequency）则代表消费者在最近的一定时间范围内的消费频率，M（Monetary）则表示消费者在这个时间范围内的消费金额消费金额。企业从客户的最近一次消费时间、消费频率和消费金额这三个维度出发来分析客户的价值状况，这将更加深入地了解客户的行为特征和价值，进而制定更为精准高效的营销路径。在用户画像平台系统合理应用 RFM 模型可以显著提升客户管理和营销效果，为企业带来更多的业务增长和客户满意度。

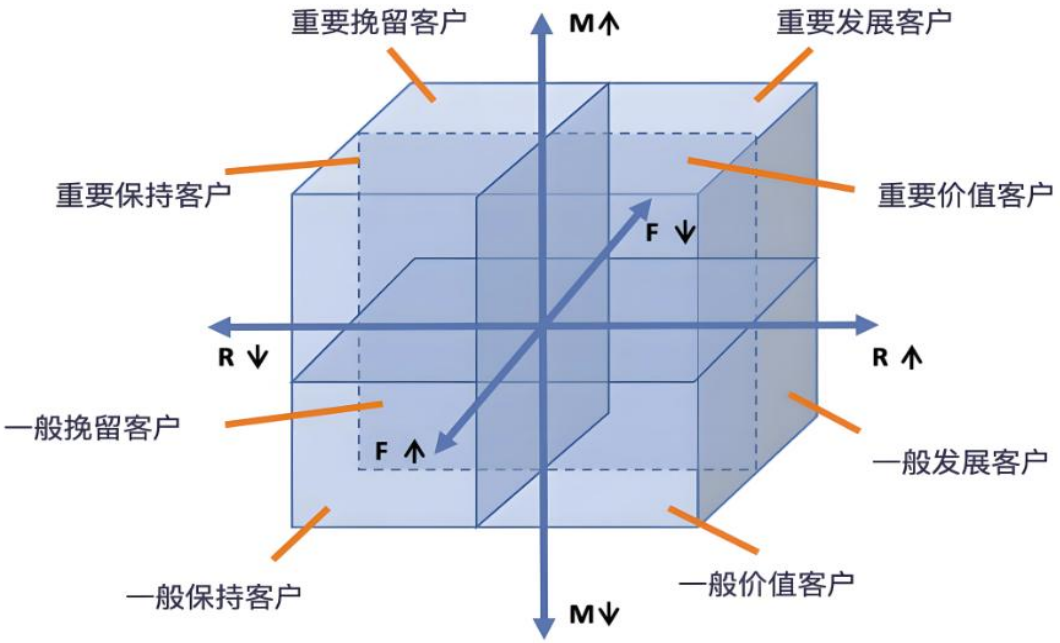

图 3-6 RFM 模型示意图

RFM 模型是用来帮助企业分析客户价值并针对不同的客户群体制定个性化营销策略的强大的工具，RFM 模型示意图如图 3-6 RFM 模型示意图所示，通常在 F 值和 M 值相同的情况下 R 值越小往往意味着客户的价值越高，1 天前在本店消费国的客户价值肯定要大于 1 年前在本地那消费过的客户。而在 R 值和 M 值相同时，F 值越大客户的价值往往越高，因为 F 值体现了用户的活跃程度，一般来说经常购物的客户绝对比偶尔购物的用户价值要高。而在 R 值和 F 值相同时，M 值越大通常客户的价值越高，因为 M 值体现的是客户的购买能力，客户的购买能力越高其价值自然也越高。

中国知网 https://www.cnki.net

RFM 模型通过对每个客户的 R、F 和 M 这三个维度进行评分，通常采用 1 到 5 的评分系统，其中 1 表示最低而 5 表示最高，客户价值对应的评分 1 到 5 依次递增，并且每个维度的评分均可以根据特定的分组标准或数据分布进行划分。若是按照客户最近一次消费时间间隔进行分组，这意味着客户消费的时间间隔越短则客户评分越高。若是按照客户消费频率进行分组后，客户消费的次数越多客户的评分也就越高。若是将客户按消费金额进行分组，则客户消费的金额越高其评分也将越高。

除了分别按照上述的 R、F 和 M 这三个维度对客户进行评分外，还可以将 R、F 和 M 三个维度的评分组合在一起形成一个三位数的 RFM 客户综合评分，如：555 表示最高价值客户，111 则表示最低价值客户。根据 RFM 的客户综合评分情况，企业可以对客户进行进一步的细分为不同的客户群体，每个群体则代表了不同的客户特征和价值，如高价值客户（555）为最近消费频繁且消费金额很大的客户，这也是企业的最为核心的客户群体。潜在流失客户（155）则代表最近没有消费但过去消费频率高且金额较大的客户，这部分的客户需要进行重点的维护。而新客户（511）则是最近刚消费但是消费频率和金额均较低的客户，对于这部分客户企业需要进行培养和激励。如下步骤为本次 RFM 模型应用的实现方式：

（1）计算出 RFM 模型评分，评分如表 3-5 客户 RFM 值计算详情表所示。

表 3-5 客户 RFM 值计算详情表

客户编号	R 最近消费日期	F 消费频率	M 消费金额
10001	2024-12-17	5	1000
10002	2024-12-18	28	500
10003	2024-12-19	50	800

（2）制定 RFM 打分细则，打分细则如表 3-6 客户 RFM 打分细则表所示。

表 3-6 客户 RFM 打分细则表

R	1-5 天=5 分	6-10 天=4 分	11-15 天=3 分	16-20 天=2 分	>20 天=1 分
F	≥200=5 分	150-199=4 分	100-149=3 分	50-99=2 分	1-49=1 分
M	≥16W=5 分	12-15W=4 分	8-12W=3 分	3-7W=2 分	<3W=1 分

（3）计算 FRM 模型值，计算结果如表 3-7 客户 RFM 计算结果详情表所示。

表 3-7 客户 RFM 计算结果详情表

客户编号	R	F	M
10001	3	1	2
10002	4	3	1
10003	5	2	3

（4）采用 K-Means 聚类算法进行分组

中国知网 https://www.cnki.net

K-Means[58]算法是一种十分经典且应用十分广泛的聚类算法，用于将数据集划分为 k 个不同的簇（Cluster），使得同一簇中的数据点之间的相似度最大，不同簇之间的数据点相似度最小。K-Means 算法的基本思想是通过迭代优化使得簇内数据点的总距离的差平方和最小，在 K-Means 算法中簇的个数 K 是一个需要认为输入确定的超参数。其距离计算方法如公式 3-6 所示，其中 x_i 和 y_i 分别表示数据点 x 和数据点 y 的第 i 个特征值，通过计算两个数据点之间的欧氏距离可以衡量两个数据点之间的相似程度。

$$\mathrm{d}(x,y)=\sqrt{\sum_{i=1}^{n}(x_i-y_i)^2} \tag{3-6}$$

K-Means 的核心任务就是根据设定好的 K 来找出 K 个最优的质心，并将离这些质心最近的数据分别分配到这些质心代表中的簇中去，从而达到最小化簇内数据点与中心点之间的总距离的目的[59]。最小化距离计算公式如公式 3-7 所示。

$$\mathrm{J}=\sum_{j=1}^{k}\sum_{\mathrm{x}_i\in C_j}\left\|x_i-\mu_j\right\|^2 \tag{3-7}$$

其中，k 代表簇的数量，C_j 是指第 j 个簇，x_i 是簇 C_j 中的一个数据点，而 μ_j 则表示 C_j 的中心点。由于不同特征的量纲不同，因此对数据进行标准化处理也十分有必要，这样会避免因未标准化的数据导致距离计算会被某些特征的影响被放大以至于影响算法效果。我们使用经典的 z-score 标准化方法来对数据进行标准化处理，标准化计算方法如公式 3-8 所示，其中 x 表示原始数据，μ 表示数据的平均值，而 σ 则是数据的标准差。

$$\mathrm{z}=\frac{x-\mu}{\sigma} \tag{3-8}$$

K-Means 算法具体实现步骤如下所示：

a. 首先随机选取样本中的 K 个点作为聚类中心。

b. 分别计算出样本中其他样本距离这个 K 个聚类中心的距离，并将这些样本作为自己最近的那个聚类中心的类别。

c. 对上述分类完的样本再次计算每个类别平均值，并求解出新的聚类质心。

d. 与上一次计算得到的 K 个聚类质心相比较，不断重复分配数据点和更新质心的过程，如果聚类质心发生变化就转至过程 b，否则就转至过程 e。

e. 当质心不再发生变化或者达到预定的迭代次数时算法立即终止，停止并输出聚类结果。

中国知网 https://www.cnki.net

上述 K-Means 算法的实现步骤分解如图 3-7 K-Means 实现步骤分解图所示。

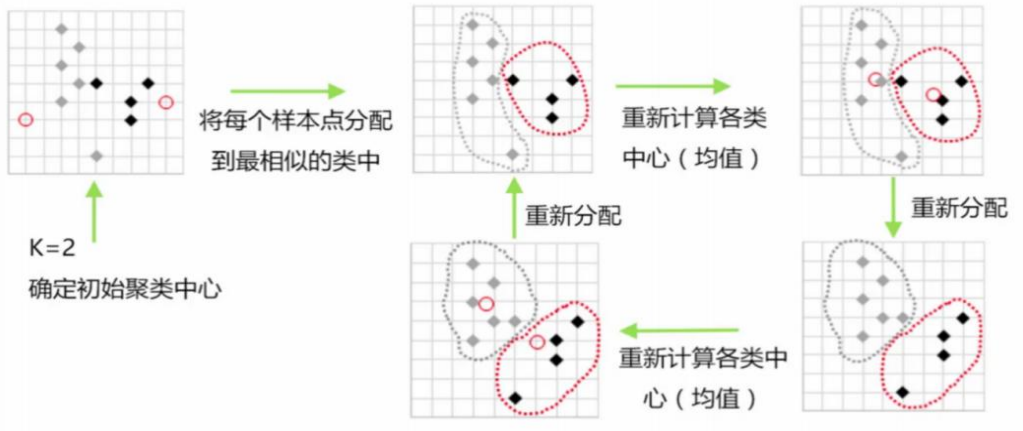

图 3-7 K-Means 算法实现步骤分解图

基于 Spark 的分布式计算框架可以加速聚类的过程，可以做到数据预处理、管道构建工具的无缝衔接。本次对用户进行聚类分群训练的核心代码实现如下代码块所示。

```
import org.apache.spark.{SparkConf, SparkContext}
import org.apache.spark.ml.clustering.{KMeans, KMeansModel}
import org.apache.spark.sql.{DataFrame, SparkSession}
import org.apache.spark.rdd.RDD
object KMeans_Exam {
  def main(args: Array[String]): Unit = {
    //建立与 Spark 框架的连接
    val sparkConf = new SparkConf().setMaster("local")
      .setAppName(this.getClass.getSimpleName.stripSuffix("$"))
      .setMaster("local[2]")
      .config("spark.sql.shuffle.partitions", "2")
      .getOrCreate()
    val sc = new SparkContext(sparkConf)
    import org.apache.spark.sql.functions._
    import org.apache.spark.implicits._
    val irisDF: DataFrame = spark.read
        .format("customer")
        .load("datas/customer_kmeans.txt")
    irisDF.printSchema()
    irisDF.show(10, truncate = false)
    //构建 K-Means 算法模型学习器实例对象
```


中国知网 https://www.cnki.net

```
        val kmeans: KMeans = new KMeans()
            //设置输入特征列名称和输出列的名称
            .setFeaturesCol("features")
            .setPredictionCol("prediction")
            //设置 K 值为 3
            .setK(3)
            //设置最大的迭代次数
            .setMaxIter(20)
        //应用数据集训练模型，获取转换器
        val kMeansModel: KMeansModel = kmeans.fit(irisDF)
        //获取聚类的簇中心点
        kMeansModel.clusterCenters.foreach(println)
        //模型评估
        val wssse: Double = kMeansModel.computeCost(irisDF)
        println(s"WSSSE = ${wsssse}")
        //使用模型预测
        val predictionDF: DataFrame = kMeansModel.transformer(irisDF)
        predictionDF.show(150, truncate = false)
        predictionDF.groupBy($"label", $"prediction")
            .count()
            .show(150, truncate = false)
        //应用结束并关闭连接
        sc.stop()
    }
}
```

3.3 本章小结

本章节主要对用户画像模型的构建流程进行了较为细致的阐述，在章节的第一部分主要对数据仓库采用了分层的架构设计，各层各司其职、相互配合，从而让用户画像数据的管理更加的科学、高效。同时也对数据仓库进行了相应的优化措施，显著提高了数据仓库的数据查询效率和整体性能表现，为用户画像的构建提供了高质量的数据支撑。在本章节第二部分主要提出了一种基于 Vision Transformer 的商品类别预测算法，将 Transformer 架构从计算机视觉领域引入到图像分类领域，并对其进行了相应的优化，显著提高了商品分类的准确率和效率

中国知网 https://www.cnki.net

表现。最后本文又选用常用的 RFM 经典模型并结合经典的 K-Means 算法成功地构建出用户画像的价值模型，为后续章节研究的开展打下了坚实的基础。

中国知网 https://www.cnki.net

第 4 章 用户画像系统的设计与实现

4.1 系统分析

传统的信息管理系统单体式的系统设计对数据的处理能力十分有限，无法高效地应对大规模、多数据源的应用场景。传统的信息管理系统也无法应对实时数据的分析需求，无法根据市场环境的变化做出快速而又针对性的策略调整，响应速度十分滞后，并且集中式的架构设计也使得其扩展性不足，缺乏动态性和灵活性，通用性也较差。通过大数据和人工智能技术构建用户画像系统能够很好的解决传统管理系统在大规模、多数据源以及实时性要求高的应用场景下的致命缺陷。并充分结合前文所介绍的商品分类算对商品进行分类以及使用聚类算法来对用户标签数分群处理，从而对用户画像数据据进行更加科学有效的管理。

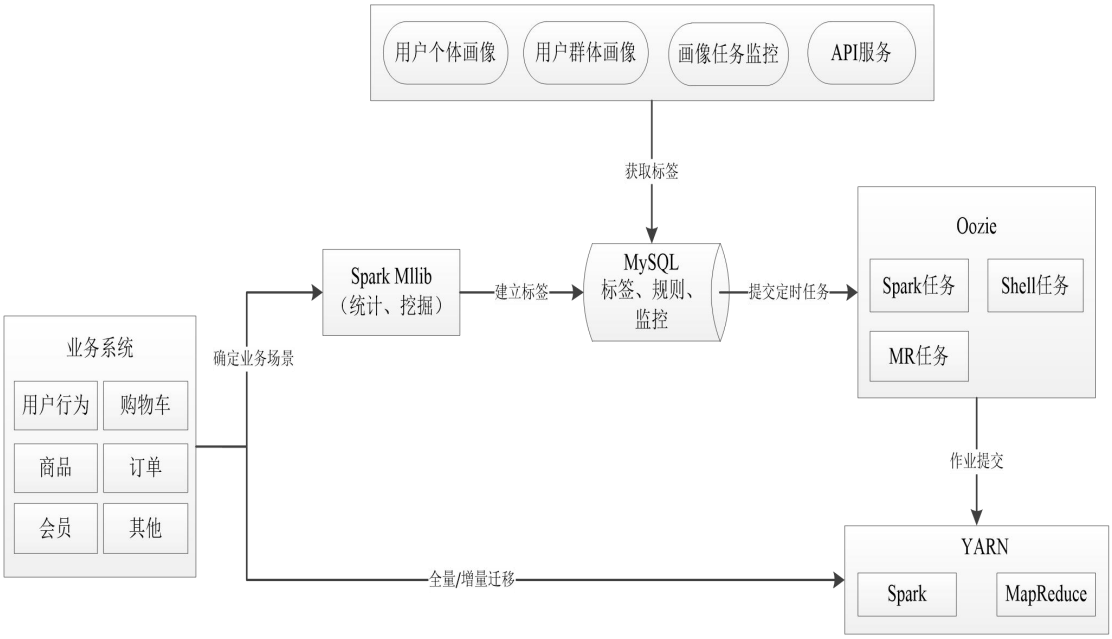

图 4-1 系统功能架构图

用户画像系统的功能架构如图 4-1 功能架构图所示，用户画像系统通过业务系统采集包括购物车、商品信息、订单信息、会员信息以及其他相关信息在内的用户行为信息，然后通过 Spark Mllib 算法库来对特定业务场景下的用户行为信息进行统计和挖掘，提取用户的多维度特征，包括用户基本信息，如：年龄、性别、家庭地址等，也包括用户活跃度、购买偏好等用户行为特征，还包括用户网络、共同兴趣等用户关系特征，并以此为基础建立用户标签，通过用户画像系统获取用户标签信息后将用户标签信息存储到 MySQL 数据库后提交定时任务给 Oozie 来进行调度和管理，然后把作业提交给 YARN 来进行资源调度，并结合

中国知网 https://www.cnki.net

Spark 和 MapReduce 强大的数据处理能力来处理 Oozie 提交过来的作业。基于 Spark 的用户画像系统采用了性能卓越的分布式架构和先进的数据处理技术，充分保证了系统的高性能和高可用性，通过高效地数据采集、预处理、存储、分析功能，构建出全面且精准的用户画像，为企业的精准化营销和科学决策提供了强有力的数据支撑。

系统采集的数据来源十分广泛，数据主要来自于 ERP 系统、CRM 系统、其他系统、日志文件和其他文件所存储的用户行为数据以及系统业务数据。采用 Spark 计算引擎来对存储的数据进行去重、格式标准化、错误纠正等数据清洗操作，并对结构化与非结构化数据进行标准化处理，同时进一步整合多数据源来打通数据孤岛，并生成用户的统一标识。本次项目是基于 SpingBoot 来进行项目的开发构建，其简洁性和强大性大大简化了项目开发的流程和配置步骤，充分保障软开开发的质量和效率。

4.2 环境搭建

4.2.1 开发环境

开发环境的配置是软件开发中的前置条件，也是至关重要的环节，开发环境配置的好坏往往会直接影响到软件开发的效率、代码质量和项目的成功率，一个高效的开发环境不仅能减轻开发者的负担，还能提升整个团队的生产力和项目的成功率。采用一致、规范和安全的开发环境配置和管理往往能达到事半功倍的奇效，不但可以显著提高项目开发效率和代码质量，还能促进团队成员之间的紧密协作，充分保障了软件产品最终的交付质量。本次用户画像系统的开发环境配置情况如表 4-1 开发环境配置详情表所示。

表 4-1 开发环境配置详情表

CPU	11th Gen Intel(R) Core(TM) i7-11800H
内存	16GB 2.50GH
操作系统	Windows11
开发工具	IDEA2020.1.1
服务器	阿里云轻量应用服务器 1 核 2G
服务器系统	CentOS7.6
开发语言	Java8.0
服务器	Apache-tomcat-8.0.53
Spark	spark-2.4.3-bin-hadoop2.7.tgz
硬盘	512GB

中国知网 https://www.cnki.net

4.2.2 分布式环境构建

考虑到大数据平台的数据处理任务量十分巨大，对于计算机的性能、安全性以及可靠性方面要求十分高，本地机器部署分布式环境可能无法满足大数据平台对于数据处理任务在性能、可靠性、运营成本以及安全性上的需要，基于以上因素的权衡考量后本次的分布式集群是基于阿里云环境下搭建的完全分布式集群，集群中有包含一台主服务器和三台从服务器共四台服务器，四台服务器采用相同的配置，均为阿里云云翼计划学生专享服务器。首先需要在阿里云上注册并用学生优惠购买阿里云服务器，之后登录阿里云账号点击控制台后进入云服务器 ECS，然后再点击创建 4 个实例，选择固定区域以保证各个节点之间的相互通信。为了方便四台服务器之间的联动通信，此项目所选用的一台主服务器和三台从服务器的 IP 都在处于同一个局域网之内。本次集群搭建选用的四个服务器节点如下所示。

master 192.168.174.130

slave01 192.168.174.131

slave02 192.168.174.132

slave03 192.168.174.132

由于四个节点的配置步骤是相同的，本次仅展示一个节点的配置过程，详细的配置步骤如下所示。

（1）基础环境配置

首先通过 vi /etc/sysconfig/network-scripts/ifcfg-ens33 命令进入到 ifcfg-ens33 文件的编辑界面，然后将文件中的 BOOTPROTO 的属性设置为 static。然后通过 hostname master 命令将主机名设置为 master，并通过 vi /etc/hosts 对 hosts 文件进行编辑，在文件中配置 ip 和主机名的映射关系，即将内容：192.168.174.130 master 追加到该文件中。配置好静态 ip 后再配置 ip 和主机的映射关系，使用 systemctl stop firewalld 命令关闭电脑的防火墙。关闭防火墙后通过 ssh master 指令进行免密登录，这样我们只需要在一台机器上便可以启动整个集群，这样就大大方便了集群内节点的启动操作。

接下来需要配置 Java 开发环境，首先通过 mkdir -p /data/soft 指令创建一个名为 soft 的文件目录，用于存放软件的安装包。从官网下载好 JDK 安装包后将目录切换至 soft 目录下，然后通过 tar -zxvf jdk-8u202-linux-x64.tar.gz 指令将 JDK 安装包解压至 soft 目录下，并通过 mv jdk1.8.0_202 jdk1.8 指令将 JDK 安装路径重命名。最后再配置环境变量 JAVA_HOME，通过指令 vi /etc/profile 命令进入 profile 文件的编辑界面，然后将文件中的末尾位置的添加如下的两行内容：export JAVA_HOME=/data/soft/jdk1.8 和 export PATH=.:$JAVA_HOME/bin:$PATH。为了

中国知网 https://www.cnki.net

确认基础环境是否配置成功，可以先试用 source /etc/profile 让编辑的文件生效，然后输入 java -version 指令后若出现相应的 java 版本信息则意味着基础环境已经配置成功。

（2）安装 Hadoop

为了节省时间，本次部署将只在 master 主节点上安装 Hadoop，然后通过节点拷贝的方式实现其他从节点的安装 Hadoop。首先需要将 hadoop-3.2.0.tar.gz 安装包上传至 linux 服务器的/data/soft 目录下，然后通过 tar -zxvf hadoop-3.2.0.tar.gz 命令对安装包进行解压。解压后再对 Hadoop 的相关配置文件进行配置，使用 cd hadoop-3.2.0/etc/hadoop/命令切换至配置文件所在的目录，然后使用如下的：vi hadoop-env.sh 命令在文件末尾中添加：export JAVA_HOME=/data/soft/jdk1.8 和 export HADOOP_LOG_DIR=/data/hadoop_repo/logs/hadoop 两行内容。接着就可以使用 vi core-site.xml 指令修改 core-site.xml 文件中的内容，使其主机名和主节点的主机名保持一致。下一步再使用 vi hdfs-site.xml 指令将 hdfs-site.xml 文件中的文件副本数量设置为 2，分别对应集群中的两个从节点。接着我们需要修改 mapred-site.xml 文件，使用 vi mapred-site.xml 指令将 mapreduce 使用的资源调度框架设置为 yarn。设置好资源调度框架后再修改 yarn-site.xml 文件，并设置好 yarn 上支持运行的服务和环境变量白名单。最后修改 workers 文件，使用 vi works 指令进入文件的编辑界面，给文件的末尾添加所有从节点的主机名，即添加 slave01、slave02 和 slave03 两行内容。

完成上述配置步骤后，紧接着就需要修改 start-dfs.sh 和 stop-dfs.sh 两个脚本文件，分别使用 vi start-dfs.sh 和 vi stop-dfs.sh 指令进入两个文件的编辑界面，然后将如下四行内容依次添加到两个文件的最前面的位置，即：

HDFS_DATANODE_USER=root
HDFS_DATANODE_SECURE_USER=hdfs
HDFS_NAMENODE_USER=root
HDFS_SECONDARYNAMENODE_USER=root

（3）将 master 节点上将修改好配置的安装包拷贝到其他两个从节点

首先使用 cd /data/soft/将当前目录切换至安装目录，然后使用如下的两个命令：scp -rq hadoop-3.2.0 slave01:/data/soft/、scp -rq hadoop-3.2.0 slave02:/data/soft/将 master 节点上将修改好配置的安装包拷贝到 slave01、slave02 和 slave03 三个从节点上。拷贝完成之后，再使用 cd /data/soft/hadoop-3.2.0 将当前目录切换至 hadoop 安装目录后使用 bin/hdfs namenode -format 将 master 节点 HDFS 格式化。

（4）启动、验证和关闭集群

集群环境配置完成后，通过 sbin/start-all.sh 启动集群。集群激动之后分别在

中国知网 https://www.cnki.net

master、slave01、slave02 和 slave03 四台机器上执行 jps 命令。若执行 master 节点后出现 NameNode、ResourceManager 和 SecondaryNameNode 则意味着 master 主节点启动成功。若执行 salve01、slave02 和 slave03 节点后出现 NodeManager 和 DataNode 则意味着两个从节点也启动成功了。集群启动完毕后通过 sbin/stop-all.sh 指令来关闭集群，至此基于完全分布式集群环境群搭建完成。

4.2.3 Spark 分布式集群搭建

Spark 集群有多种部署方式，基于集群资源共享的角度以及维护成本和运维压力方面的多方面权衡考量，此次优先选择系统资源消耗更少的 ON YARN 模式来部署 Spark 分布式集群环境。将 Spark 运行在 YARN 上也就意味着 Spark 可以共享上一个小章节在阿里云中所搭建的 Hadoop 集群内的所有资源，无需单独为 Spark 单独搭建集群，因此也可以直接复用 Hadoop 中配置的基础环境，无需再次进行相关基础环境的配置工作了，省去了一大堆重复的繁琐配置步骤，这就大大较少了集群的运维成本和运维压力，显著提高了集群内的资源利用率。Spark 集群的详细部署步骤如下所示。

（1）下载安装 Spark

选择与安装的 Hadoop 想匹配的 Spark 版本，经过各方面的权衡考量，此次选择下载安装这个版本：spark-2.4.3-bin-hadoop2.7.tgz。下载好安装包后，将其上传到 slave04 的/data/soft 目录中，使用 tar -zxvf spark-2.4.3-bin-hadoop2.7.tgz 指令将其解压至 soft 目录中。

（2）修改配置文件

然后使用 cd spark-2.4.3-bin-hadoop3.2/conf/命令将当前目录切换至 conf 目录下，再使用 mv spark-env.sh.template spark-env.sh 指令将 spark-env.sh.template 重命名为 spark-env.sh。接下来需要修改 spark-env.sh 文件中的内容，然后使用 vi spark-env.sh 指令来进入 spark-env.sh 文件的编辑界面，接下来在文件的末尾添加如下两行内容来分别指定 JAVA_HOME 和 Hadoop 的配置文件目录，即：

```
export JAVA_HOME=/data/soft/jdk1.8
export HADOOP_CONF_DIR=/data/soft/hadoop-3.2.0/etc/hadoop
```

（3）提交 Spark 任务

最后我们可以通过 bin/spark-submit --class org.apache.spark.examples.SparkPi --master yarn --deploy-mode cluster examples/jars/spark-examples_2.11-2.4.3.jar 2 命令来通过 Spark 的客户节点来向 Hadoop 集群上提交 Spark 任务，然后可以通过 YARN 的 8088 界面上可以直观地查看到 Spark 客户节点提交的任务。到这里基于 ON YARN 模式部署的 Spark 集群到此就搭建完毕，在此模式下的 Spark 任务执行也将变得更加的方便。

中国知网 https://www.cnki.net

4.3 用户画像系统逻辑设计

数据库的逻辑设计在整个用户画像系统的实现和运行中起着关键性作用，良好的逻辑设计可以充分整合多个不同的数据，消除数据孤岛。通过规范的数据模型和约束条件，可以确保各个子系统中数据的一致性，避免各个子系统中出现数据冗余和冲突。与此同时，合理的数据库表结构设计，如对表进行规范化和索引的创建来提高数据存储和访问的效率，从而减少了数据查询的时间，提升了系统的整体相应速度。优秀的数据库逻辑设计师用户画像系统成功的基础，通过合理设计数据整合与一致性、高效查询、多维度分析、可扩展性、可维护性和数据安全等方面，可以显著提升系统的整体性能和可靠性，为企业提高强有力的数据支撑和分析能力。

4.3.1 数据库设计

MySQL 是在软件项目开发中广泛使用的一款开源的关系型数据库管理系统，其简单易用、高性能、灵活性和扩展性等众多优点使得其成为中大型企业项目的首要选择。本次用户画像系统所产生的所有业务数据都是真实电商数据，用户画像系统设计了 t_customer、t_behavior、t_user、t_order、t_good 和 t_log 总共六张表来分别存储用户信息、用户行为信息、客户基本信息、订单数据信息、订单商品信息和用户行为日志信息，其表结构和字段设计分别如表 4-2 用户字段详情表、表 4-3 用户行为字段详情表、4-4 客户基本信息表、表 4-5 订单数据表、表 4-6 商品信息表和表 4-7 用户行为信息表所示。

表 4-2 用户字段详情表

字段名	数据类型	备注	约束条件
Uid	Bigint(50)	用户编号	主键、自增
Name	String	用户名字	非空
Sex	Int(2)	性别	默认值为 0
Totalpay	Bigint(30)	总支付订单	非空
Totalorder	Bigint(30)	总订单数	非空
Totalamt	Bigint(30)	总消费金额	非空
Birth	String	生日日期	非空
Age	Int(3)	用户年龄	非空
Province	String	用户所在省份	非空
County	String	用户所在县城	非空
Telephone	String	电子邮箱	非空
Finallogin	Timestamp	最后一次登录时间	非空

中国知网 https://www.cnki.net

续表 4-2 用户字段详情表

字段名	数据类型	备注	约束条件
Lip	String	用户登录 Ip	非空
Firstlogin	Timestamp	首次登录时间	非空
Joindate	Timestamp	加入日期	非空
City	String	用户所在城市	非空
Address	String	家庭住址	非空
Tel	String	电话号码	非空
Telsystem	String	手机系统	非空
Telmodel	String	手机型号	非空
Staytimeofweek	Bigint(30)	最近七天停留次数	非空
Onlinetimeofweek	Bigint(30)	最近七天在线时长	非空
Collectcountofweek	Bigint(30)	最近七天收藏次数	非空
Opentimesofweek	Bigint(30)	最近七天打开次数	非空
Clicktimesofweek	Bigint(30)	最近七天点击次数	非空
Firstordertime	Timestamp	首次下单时间	非空

表 4-3 用户行为字段详情表

字段名	数据类型	备注	约束条件
Uid	Bigint(50)	用户编号	非空
Sid	Bigint(50)	会话编号	非空
Provice	String	登录地省份	非空
City	String	登录地城市	非空
Logintime	Timestamp	登录时间	非空
Client	String	访问客户端	非空
Lid	Bigint(50)	登录用户的 Id	主键、自增
SearchTime	Timestamp	商品搜索时间	非空
Lip	String	登录用户的 Ip	非空
Nameofgoods	String	被点击的商品名称	非空
Tagname	String	商品标签名称	非空
Gstatus	Int(2)	商品状态	非空
Ustatus	Int(2)	用户状态	默认值为 100001
Utype	Int(2)	用户类型	默认值为 1
Messcode	String	手机短信验证码	非空
SearchId	Bigint(50)	搜索的商品编号	非空

中国知网 https://www.cnki.net

表 4-4 客户基本信息表

字段名	数据类型	备注信息	约束条件
Cid	Int(10)	用户编号	主键、自增
AvatarFileId	Varchar(255)	头像编号	默认为空
Email	Varchar(120)	电子邮箱	默认为空
UserName	Varchar(60)	用户名	非空
Password	Varchar(60)	账号密码	默认为空
RegisterTime	Int(20)	注册时间	非空
FinalLoginTime	Int(20)	最后登录时间	默认为空
FinalLoginIp	Varchar(20)	最后登录 Ip	默认为空
MemberId	Int(10)	特殊会员等级编号	默认为空
LastAddress	Int(10)	上次使用的收货地址	默认为空
LastPayment	Varchar(20)	上次使用的支付方式	默认为空
Gender	Tinyint(3)	性别	默认为空 值 0、1
Birthday	Date	生日日期	默认为空
Mobile	Varchar(15)	手机号码	默认为空

表 4-5 订单数据表

字段名	数据类型	备注信息	约束条件
Oid	Int(10)	订单编号	主键、自增
HasSync	Tinyint(1)	是否已经同步	非空、默认为 0
IsBackend	Tinyint(1)	是否为后台添加订单	非空、默认为 0
PackageId	Int(10)	套装编号	非空
RelationOrderSn	Varchar(60)	关联订单编号	非空
MemberId	Int(20)	会员编号	非空
MemberEmail	Varchar(120)	会员邮箱	非空
AddTime	Int(10)	订单添加时间	非空
SyncTime	Int(10)	同步到此表中的时间	非空
OrderStatus	Smallint(5)	订单状态	非空
PayTime	Int(10)	在线付款时间	非空
PaymentStatus	Smallint(5)	付款状态	非空 值为 0、1
GoodsAmount	Decimal(10,2)	商品金额	非空
TotalAmount	Decimal(10,2)	订单总金额	非空
Paymentway	Varchar(60)	支付方式	非空
Consignee	Varchar(60)	收货人	非空

中国知网 https://www.cnki.net

表 4-6 商品信息表

字段名	数据类型	备注信息	约束条件
Gid	Int(10)	商品编号	主键、自增
HasRead	Tinyint(1)	是否已读	非空、默认为 0
IsBook	Tinyint(1)	是否为预定网单	非空、默认为 0
ProductType	Varchar(60)	商品类型	非空
ProductId	Int(10)	抽象商品编号	非空
Productname	Varchar(100)	商品名称	非空
Price	Decimal(10,2)	商品价格	非空
Sku	Varchar(60)	商品货号	非空
Number	SmallInt(5)	商品数量	非空
CateId	Int(11)	商品分类编号	非空
BrandId	Int(11)	商品品牌编号	非空
ActivityId	Int(11)	促销活动编号	非空
InvoiceNumber	Varchar(60)	运单号	非空

表 4-7 用户行为信息表

字段名	数据类型	备注信息	约束条件
Lid	Varchar(50)	日志编号	主键、自增
RemoteIp	Varchar(60)	远程 Ip 地址	默认为空
SiteGlobalTicket	Varchar(250)	全局优惠券	默认为空
SiteGlobalSession	Varchar(250)	全局会话	默认为空
CookieText	Mediumtext	通知文本	默认为空
GlobalUserId	Varchar(50)	全局客户编号	默认为空
UserAgent	Varchar(250)	客户代理人	默认为空
RefUrl	Varchar(250)	先前的 Url 地址	默认为空
LocUrl	Varchar(250)	日志的 Url 地址	默认为空
LogTime	Varchar(50)	日志生成时间	默认为空
Uid	BigInt(20)	客户编号	非空

4.4 用户画像系统的实现

本章节承接前一章节用户画像系统的设计工作的基础上进一步展开介绍用户画像系统各模块的具体实现，前一章节的工作是本章节实现的必要准备，以下便是本章节的详细内容。

中国知网 https://www.cnki.net

4.4.1 系统部署

结合本章的需求分析以及功能分析，此次用户画像系统的开发工作需多台服务器的相互配合协调才能达完成要求。立足于当前资源的实际情况考量，本次实验的服务器集群的配置情况如表 4-8 服务器集群节点分配详情表所示。

表 4-8 服务器集群节点分配详情表

部署模块	服务器功能说明	主机名	端口	备注
MySQL	存储用户标签	MySQL-01	5806	用户标签数据存储
	用户行为数据	MySQL-01	5807	用户行为数据存储
Spark	用户画像数据	Spark-01	8206	离线类业务
	处理	Spark-02	8207	实时类业务
		Spark-03	8208	
		Spark-04	8209	
Flume	日志数据收集	Log-Flume	8106	日志收集节点

如表 4-8 服务器集群节点分配详情表所示所示，MySQL 数据库负责存储用户标签相关数据，而 Hive 数据仓库负责将 MySQL 数据库中的非结构化数据转换成结构化的表格形式，让数据更加易于管理和查询大规模用户数据。Spark 计算引擎则负责处理离线类业务和实时类业务中的数据处理任务，Kafka 的三个节点用于将不同的用户数据进行分类转发，而 Flume 服务器则用于获取企业业务操作所产生的实时日志数据。各个部署模块相互协作，各司其职，为用户画像系统的数据高效存储和处理提供了可能。

4.4.2 系统管理模块

（1）系统登录

系统登录模块式是用户进入系统的访问入口，在用户画像系统中扮演者极其重要的角色，是用于确保整个系统安全和验证用户身份的关键功能。作为用户画像系统中不可或缺的一部分，系统登录模块不仅负责用户身份验证和权限管理，并通过多种安全措施保障保障系统的安全性。在用户想服务器发送登录请求时，服务器在接收到登录请求后会自动跳转至登录界面进行密码校验，校验成功后才会正确相应登录请求。用户登录成功后会将通过的用户验证信息发送至系统控制层，然后再调用数据服务层向数据库请求用户信息，并将最终的用户数据返回。登录模块时序图如图 4-2 用户登录时序图所示。

中国知网 https://www.cnki.net

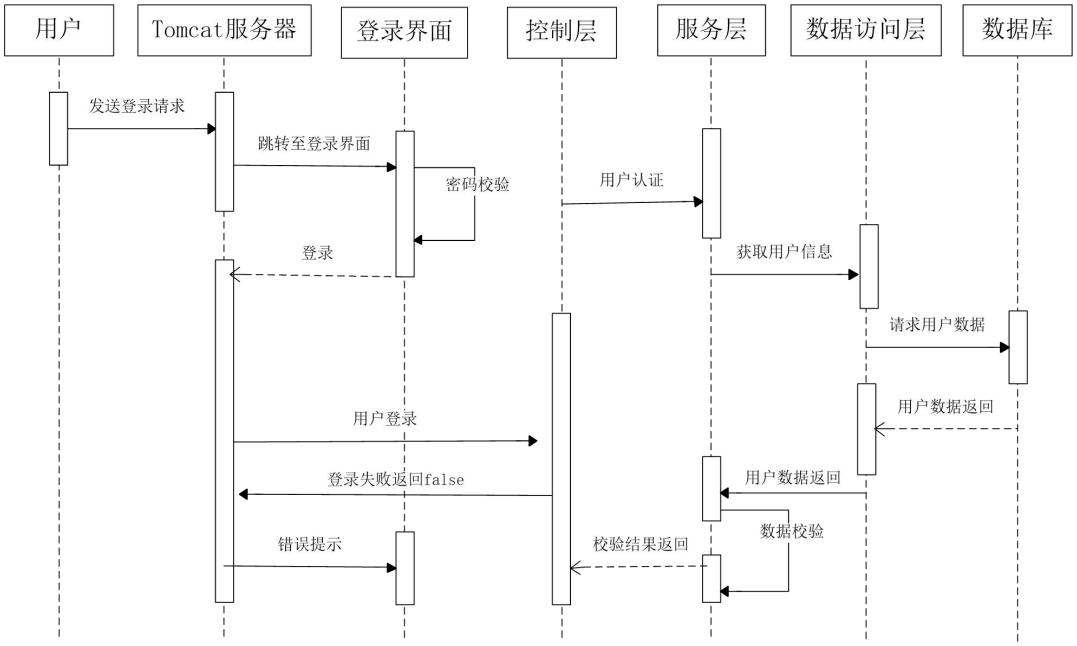

图 4-2 用户登录时序图

通过优化系统登录模块的设计与实现可以显著提高系统的安全性和稳定性，更重要的是用户的使用体验也会大大得到提升，为用户提供编辑、安全的访问途径，只有当用户输入的账号和密码和注册时的保持一致才可以成功登录进入系统，否则就会被拒之门外，并会给与用户相应的提示信息。系统登录模块界面直观展示如图 4-3 用户登录界面图所示。

图 4-3 用户登录界面图

（2）角色权限管理

角色权限管理模块通过有效地管理和控制用户对系统资源和功能的访问权限的核心功能模块，其通过角色分配和权限控制确保用户只能发给我与其角色相

中国知网 https://www.cnki.net

关的资源和功能，从而提高了整个用户画像系统的安全性、灵活性和可维护性。角色权限管理的时序图如图 4-4 角色权限管理时序图所示。

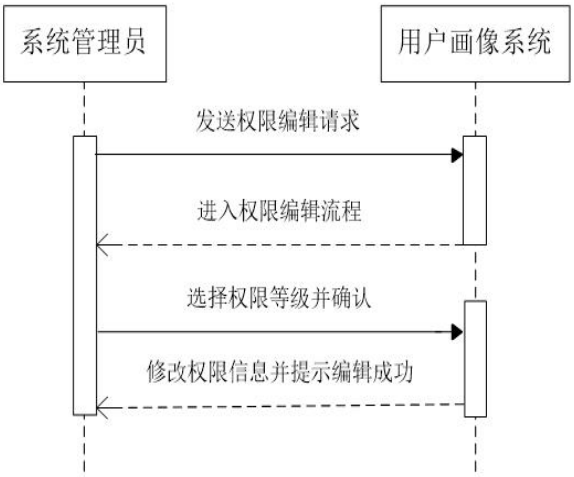

图 4-4 角色权限管理时序图

角色权限管理模块通过定义不同的用户角色，如：超级管理员、普通管理员、普通用户、游客等，并为每个角色分配与之对应的权限，每个角色代表一组特定的权限集合而不是直接分配给用户，实现了用户与权限的解耦。一个角色可以对应多个用户，而多个角色也可以被一个用户拥有，将用户分配到特定角色，进而继承该角色的权限。这样就建立了更加清晰的权限层次结构，简化了权限管理的流程，从而避免了逐个设置用户权限的繁琐，大大提高了系统管理员的工作效率。角色权限管理界面直观展示如图 4-5 角色权限管理界面图所示。

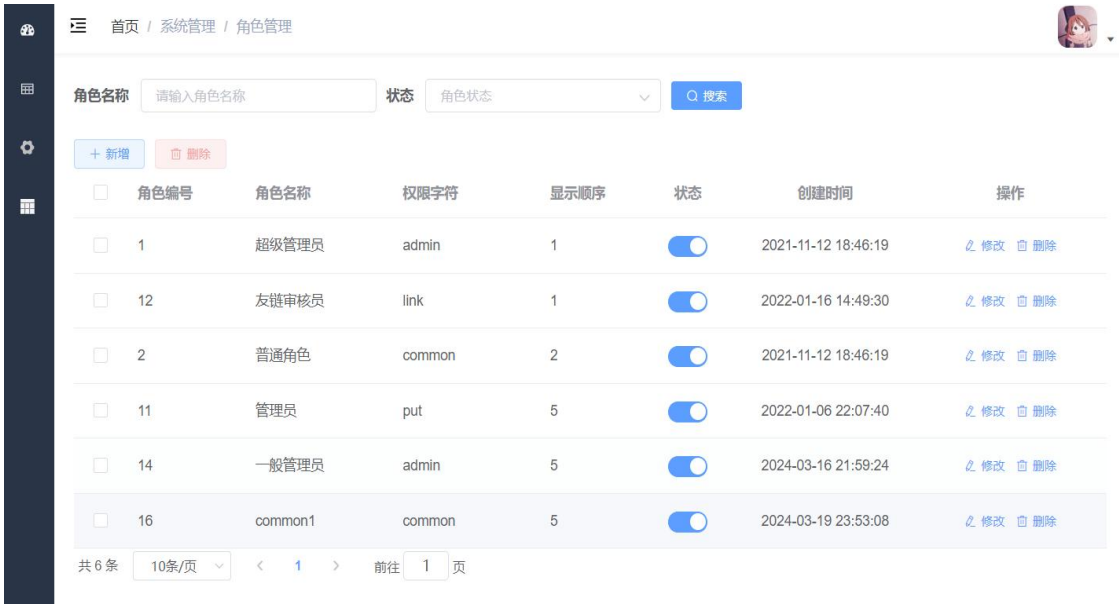

图 4-5 角色权限管理界面图

4.4.3 数据管理模块

（1）用户数据管理

中国知网 https://www.cnki.net

用户数据管理模块在用户画像系统的中扮演着十分关键的角色，它确保了用户数据的有效获取、处理、存储和更新，是构建精准用户画像的基础。用户数据管理的时序图如图 4-6 用户数据管理模块时序图所示。

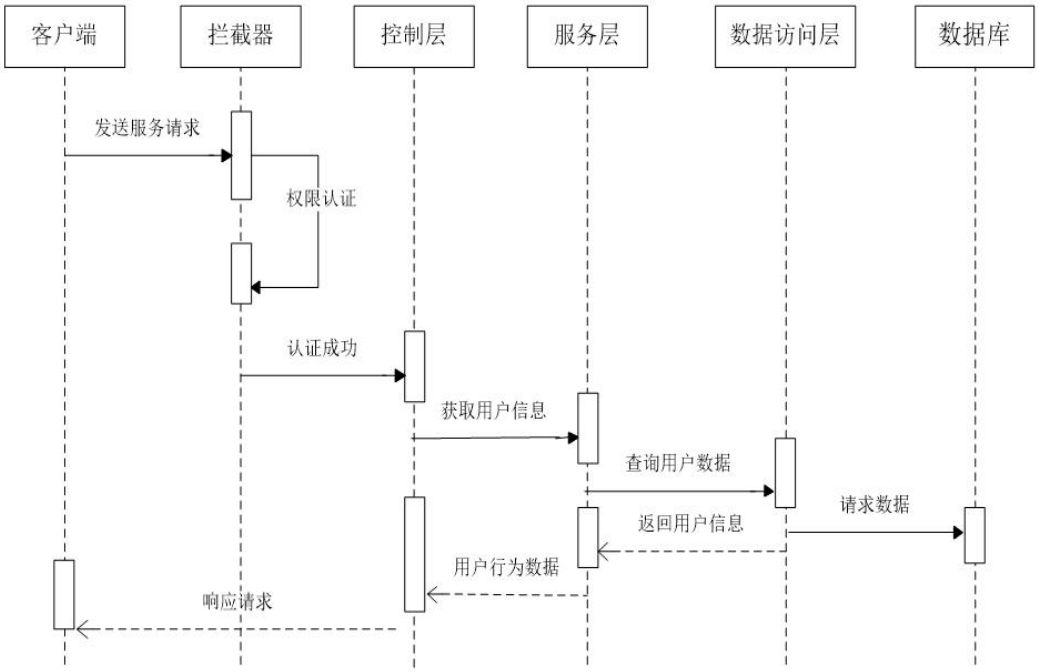

图 4-6 用户数据管理时序图

用户数据管理界面如图4-7用户数据管理界面图所示，通过高效的数据收集、存储、处理、分析和安全管理，充分保障了用户数据的完整性和安全性，提升了真个用户画像系统的性能和用户体验。一个完善的用户数据管理模块是用户画像系统运行和持续优化的基础，它通过确保数据的质量、完整性和安全性，为用户画像系统提供了强大的数据支撑。

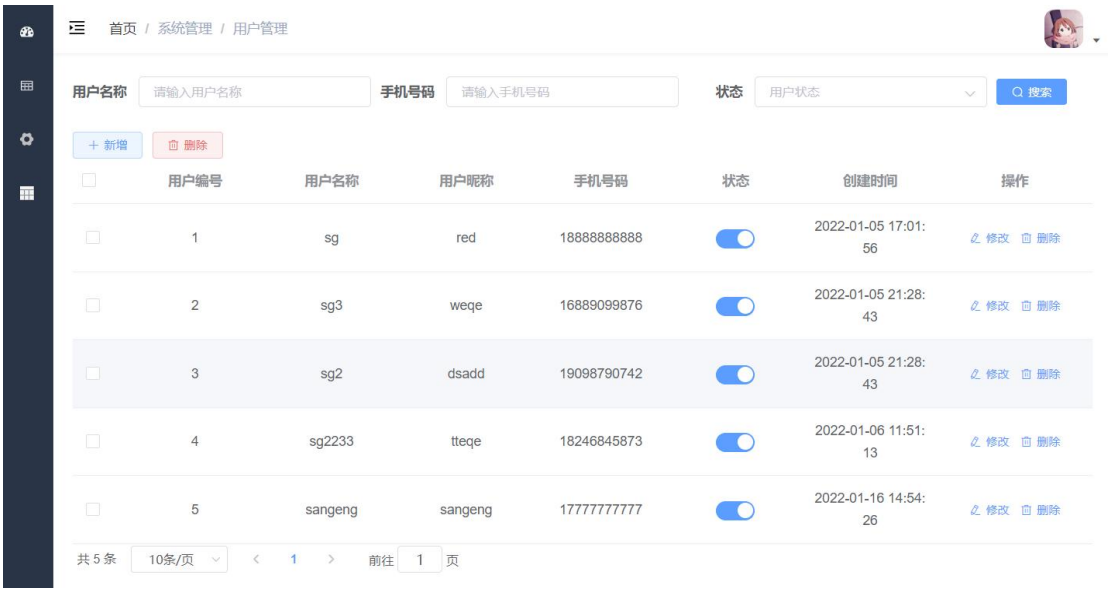

图 4-7 用户数据管理界面图

中国知网 https://www.cnki.net

（2）标签任务管理

用户标签任务管理是构建用户画像系统的核心基础，是确保用户画像系统能够高效精准运作的核心组成部分。用户标签是对用户进行分类和表述的一种方式，而标签任务管理则是确保这些标签准确、实时和有效地更新和应用的机制通过精细化的用户标签管理，系统不仅可以为用户提供个性化的服务体验，还可以帮助企业作出更加智能化和数据驱动的企业营销决策。用户标签任务管理的时序图如图 4-8 标签任务管理时序图所示。

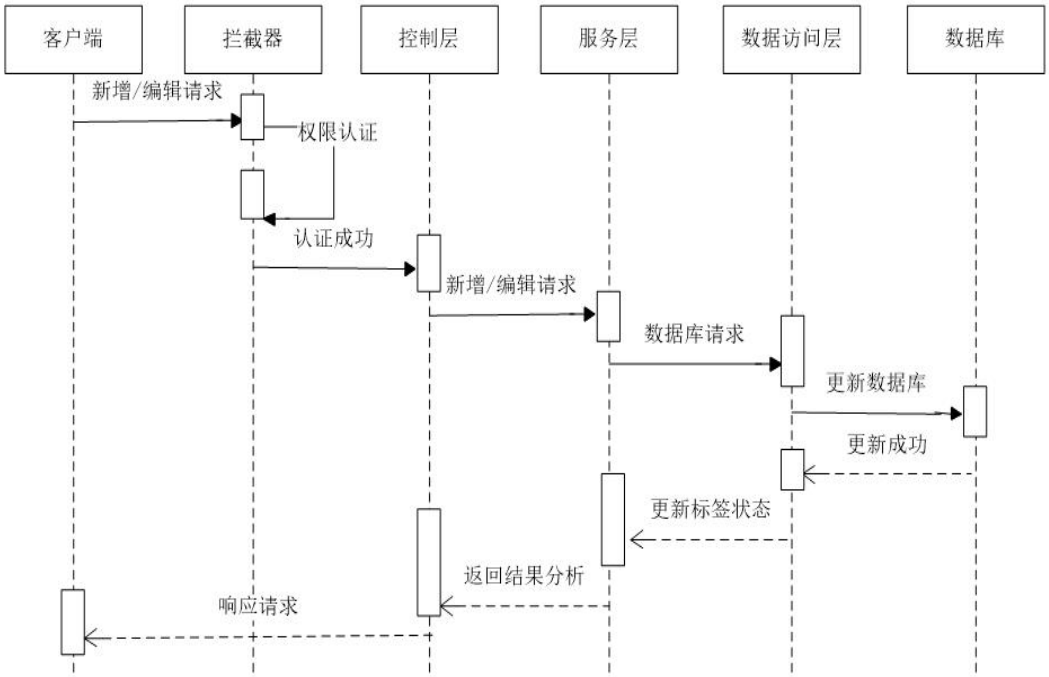

图 4-8 标签任务管理时序图

用户标签任务管理是构建用户画像的关键步骤，通过对用户的购买记录、浏览历史、点击行为等用户行为数据进行细致的分类和标记的标签化处理可以更加精准描述用户的特征和兴趣爱好，帮助构建精细化、可操作的用户画像。一个完善的标签数据任务管理模块是用户画像系统成功实施的关键，能够显著提升用户的使用体验和业务效果。标签任务的新建任务界面和编辑任务界面展示效果如图 4-9 标签任务新建界面图和图 4-10 标签任务编辑界面图所示。

中国知网 https://www.cnki.net

图 4-9 标签任务新建界面图

图 4-10 标签任务编辑界面图

中国知网 https://www.cnki.net

4.5 本章小结

本章节主要分为四部分，其中第一部分主要对整个用户画像系统进行了系统分析，并对整个系统的功能以及所使用技术架构有了一个清晰和全面的梳理。第二部分则是介绍了用户画像系统的开发环境以及大数据集群框架的搭建情况，为后续的设计与实现工作打下了坚实的基础。第三部分则是进行关键的数据库逻辑设计，根据系统自身需求情况以及实验硬件条件而精心设计数据库字段。而本章节的最后一部分则是关于电商用户画像系统的具体实现情况，介绍了本系统的实现架构，并附上了最终的 Web 界面效果截图。自此，本章节关于用户画像系统应用的设计与实现工作也就此完成。

中国知网 https://www.cnki.net

第 5 章 系统测试与分析

系统测试环节在软件的开发生命周期中起着至关重要的作用，尤其是在电商平台用户画像系统这类大规模软件系统中显得尤为重要。对系统进行充分的测试不仅能够验证整个系统功能和性能的正确性，还是系统稳定性、安全性和用户的使用体验的必要保障，更有利于提前发现系统中存在的潜在问题。为了充分保障电商平台用户画像平台系统能够高效、稳定、准确地运行，在本章节中对用户画像系统进行了充分的功能测试、性能测试以及用户体验测试这三方面的综合测试，确保基于 Spark 的电商平台用户画像系统能够提供高质量的用户服务。

5.1 测试环境

测试环境的配置是系统测试的基础，也是确保测试结果准确性和系统质量的必要前提。测试环境的好坏也将会直接影响到最终测试结果的准确性和系统质量。合适的测试环境配置将会提高测试的效率，达到事半功倍的奇效，可以更为全面地验证系统的各功能、性能和稳定性，显著降低系统风险，为电商平台用户画像系统提供高质量的技术保障。本研究所采用的测试环境配置情况如表 5-1 测试环境配置详情表所示。

表 5-1 测试环境配置详情表

CPU	11th Gen Intel(R) Core(TM) i7-11800H
内存	16GB 2.50GH
操作系统	CentOS7.6
硬盘	512GB 固态+1T 机械
Spark 版本	spark2.4.3
JDK 版本	Java8.0
Jmeter 版本	Jmeter5.6
TestComplete 版本	TestComplete11.2
服务器	Apache-tomcat-8.0.53
数据库	MySQL8.0

5.2 功能测试

功能测试主要验证系统的各个模块是否能够按照需求和设计正确的执行功能以及系统各业务之间的流程是否可以顺利运行，这是系统测试中最基础且最重要的一部分，也是保证软件质量的重要环节。在功能测试阶段可以充分验证系统

中国知网 https://www.cnki.net

所有的功能模块都能够按预期工作并及时发现和修复系统中的缺陷，减少系统后期的维护成本。功能测试除了关注系统是否能够按照需求正常工作外，还注重用户的使用体验，从用户的角度出发验证功能是否满足用户的使用期望，充分保障系统的质量。

在进入电商平台用户画像系统中之前，系统会对用户的登录信息进行认证校验，只有当用户输入的登录信息和用户的注册时填写的信息保持一致时才能登入系统才能跳转到相关功能界面，从而享受相对应的用户服务。用户登录认证校验测试用例如表 5-2 用户登录认证校验测试用例表所示。

表 5-2 用户登录认证校验测试用例表

用例编号	测试步骤	预期结果	是否一致
1	进入登录界面	1.系统提示用户登录成功，并且成功跳转到系统首页中	是
2	输入正确的用户名和密码		是
3	勾选“记住我”选项	2.再次进入登录界面是无序再次输入用户名和密码即可登录系统	是
4	点击“登录”按钮		是
5	关闭浏览器后重新访问登录界面		是

数据清洗是电商用户画像平台处理数据流程中的一个极为重要的环节，旨在消除测试数据中的错误、不一致、不完整和冗余部分来提高测试数据的质量。在面对日趋庞大且来源复杂的用户数据时，对数据进行清洗工作显得尤为重要，只有高质量的用户数据才能支撑系统准确地生成精准的用户画像并给用户提供个性化的服务推荐。该功能测试用例如表 5-3 数据清洗功能测试用例表所示。

表 5-3 数据清洗功能测试用例表

用例编号	测试步骤	预期结果	是否一致
1	输入包含重复值、缺失值和异常值的原始数据集	1.输出的数据集中无重复值	是
2	运行数据清洗模块	2.缺失值的数据已经被处理	是
3	检查输出数据集是否已经去除重复值、填充缺失值并过滤异常数据	3.异常的数据已经被过滤处理	是

在电商平台用户画像系统中，特征提取是从海量的用户行为数据中提取出有意义的、可供进一步分析和建模的特征，帮助平台从庞大的用户行为数据中提取出有用的信息据，通过特征提取可以提高模型的性能和准确性、简化数据和降低数据维度、增强模型的可解释性，从而提高模型的准确性和计算效率，优化用户

中国知网 https://www.cnki.net

画像的生成，并提升数据的质量和可靠性，为平台提供更加精确的用户洞察。用户数据清洗功能测试用例如表 5-4 特征提取功能测试用例表所示。

表 5-4 特征提取功能测试用例表

用例编号	测试步骤	预期结果	是否一致
1	输入用户行为数据集	输出的特征集中包含浏览记录、购买记录、点击率等预定义的关键特征	是
2	运行特征提取模块		是
3	检查输出特征集是否包含购买频率、浏览时长、点击率等关键特征		是

用户标签生成功能是电商平台用户画像系统中的核心功能之一，生成精准的用户标签对于个性化推荐、精准营销和提高用户体验至关重要。用户标签是从用户的行为数据中提取的有意义的、简洁的描述，用于标识用户的特征、偏好以及兴趣等，这些标签可以帮助系统更加准确地了解每个用户的真是需求，从而进一步优化用户服务，并提高平台的运营效率。用户标签生成功能测试用例如表 5-5 用户标签生成功能测试用例表所示。

表 5-5 用户标签生成功能测试用例表

用例编号	测试步骤	预期结果	是否一致
1	输入用户行为数据集	生成的用户标签能准确反映用户的行为特征，如“高价值用户”、“潜在流失用户”	是
2	运行标签生成模块		是
3	检查生成的用户标签是否符合预期		是

用户画像的存储是电商平台用户画像系统中的一个重要环节，它负责将生成的用户画像数据进行有效、可靠地存储和管理。这一功能能够确保电商平台能够随时访问、更新和使用用户画像数据，以支持用户个性化服务的业务需求，从而优化用户体验、提高平台运营效率，并最终提升商业价值。用户画像存储功能测试用例如表 5-6 用户画像存储功能测试用例表所示。

表 5-6 用户画像存储功能测试用例表

用例编号	测试步骤	预期结果	是否一致
1	生成用户画像数据	用户画像数据成功存储到数据库中，并且数据十分完整	是
2	运行画像存储模块		是
3	检查用户画像数据是否已存储到数据库中		是

用户分群功能是电商平台用户画像系统中的一个关键功能，是指通过对用户

中国知网 https://www.cnki.net

行为、特征等数据的分析来将不同的用户群体划分成具有相似特征或行为模式的小组，通过用户分群可以更加精准地识别和理解不同用户的需求、兴趣和偏好，从而提供更加人性化的服务。用户分群功能测试用例如表 5-7 用户分群存储功能测试用例表所示。

表 5-7 用户分群功能测试用例表

用例编号	测试步骤	预期结果	是否一致
1	输入用户画像数据集	用户被正确分群，并且分群结果合理，如“高活跃用户”、“低活跃用户”	是
2	运行用户分群模块		是
3	检查分群结果是否符合预期		是

5.3 性能测试

性能测试是系统测试中十分重要的一部分，尤其是在大规模的电商平台中性能测试的作用尤为突出。性能测试是利用相关测试工具来模拟系统在多样的负载场景下的性能表现，以确保系统在各种实际运行场景中能够稳定、高效地服务于用户。性能测试不仅仅是为了检查系统是否能够承受大量用户的访问，还包括了对系统的相应时间、资源消耗、扩展性等多方面的评估，确保系统系统能够在高并发、高负载等极端情况下仍然保持优异表现。在性能测试中可以提前发现并解决系统的性能瓶颈，不仅能避免潜在的故障和崩溃，还能帮助平台优化资源配置，大幅度降低电商平台的运营成本。

本次选用了功能十分强大的 Jmeter 测试工具来进行性能测试，这一工具因其免费开源、功能强大、配置灵活以及丰富的扩展性等众多优点而成为一个非常流行的性能测试工具选择。系统响应时间是评价系统处理用户请求时的响应速度情况，它是一个衡量系统性能和用户体验的重要指标，对系统响应时间进行测试可以为平台的稳定健康的运行提供重要的数据支持。该测试用例如表 5-8 系统响应时间测试用例表所示。Jmeter 本次测试总共对 20 组线程循环执行 200 次完成后对接口的响应结果进行测试，测试结果如图 5-1 性能测试结果图所示。

表 5-8 系统响应时间测试用例表

用例编号	测试步骤	预期结果	是否一致
1	进入 Jmeter 工具	系统的响应时间无明显的延迟现象，延迟时间在豪秒级	是
2	模拟 1000 个并发用户访问系统		是
3	记录系统响应时间		是

中国知网 https://www.cnki.net

执行顺序	执行时间	线程名称	平均响应时间(ms)	请求状态	字节大小	发送字节大小	请求延迟	请求连接时间(ms)
1	11:25:15	Thread-1	1250	成功	24425	117	1233	1228
2	11:25:16	Thread-2	282	成功	24432	117	243	216
3	11:25:17	Thread-3	765	成功	24415	117	745	728
4	11:25:18	Thread-4	44	成功	24459	117	38	0
5	11:25:19	Thread-5	45	成功	24450	117	39	0
6	11:25:20	Thread-6	37	成功	24457	117	46	0
7	11:25:21	Thread-7	42	成功	24451	117	44	0
8	11:25:22	Thread-8	41	成功	24435	117	38	0
9	11:25:23	Thread-9	40	成功	24456	117	168	0
10	11:25:24	Thread-10	46	成功	24431	117	35	0
11	11:25:25	Thread-11	38	成功	24451	117	38	0
12	11:25:26	Thread-12	39	成功	24467	117	39	0
13	11:25:27	Thread-13	45	成功	24465	117	198	147
14	11:25:28	Thread-14	214	成功	24468	117	202	156
15	11:25:29	Thread-15	39	成功	24457	117	54	0
16	11:25:30	Thread-16	41	成功	24458	117	38	0
17	11:25:31	Thread-17	42	成功	24450	117	41	0
18	11:25:32	Thread-18	243	成功	24452	117	35	0
19	11:25:33	Thread-19	54	成功	24449	117	43	0
20	11:25:34	Thread-20	33	成功	24466	117	42	0

图 5-1 性能测试结果图

如图 5-2 用户画像数据实时分析折线图所示，蓝线表示画像系统的响应时间，从图中可以得出用户画像数据分析的平均响应时间为 2 秒左右，进一步验证系统的响应时间在豪秒级，无明显的延迟现象，性能表现较为优异。

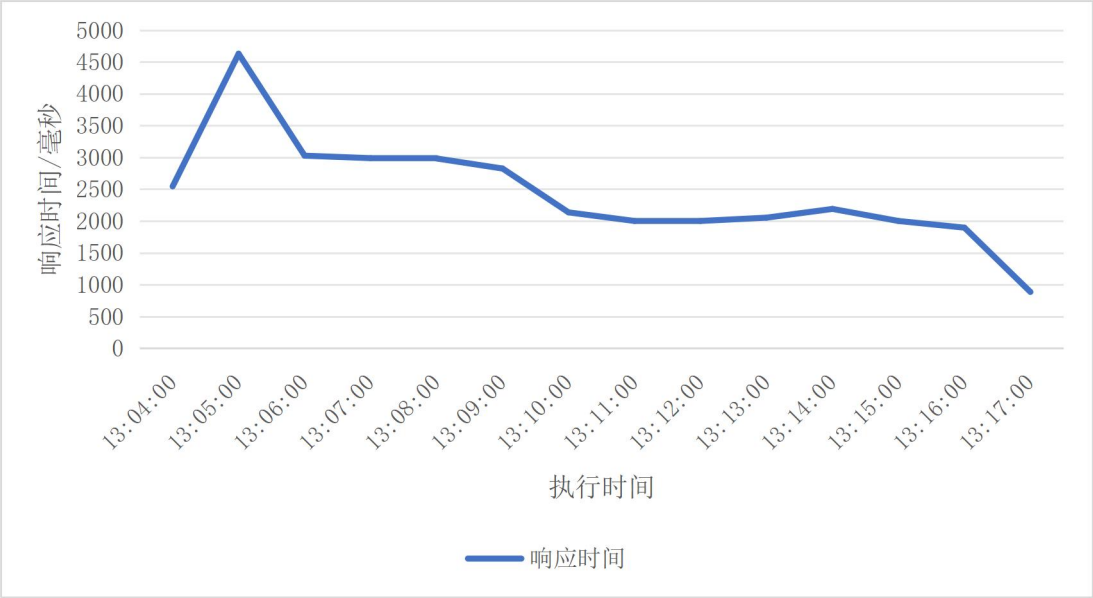

图 5-2 用户画像数据实时分析折线图

如图 5-3 用户画像数据查询性能分析折线图所示，图中的橙色折线表示系统离线分析用户画像数据时的平均执行时间，其平均执行时间为 0.7 秒左右，执行画像分析任务时性能表现较为优异。而图中的灰色折线则表示执行用户画像数据查询任务时的耗时情况，是用户画像查询性能的直观化，从表中可以得出系统在执行用户画像查询任务时的平均查询时间为 0.6 秒左右，这进一步充分说明用户画像系统在用户画像的相关任务执行效率较高，性能较为卓越，可以充分保障画像系统在大规模数据涌入时的高效数据处理能力以及快速的系统相应速度。

中国知网 https://www.cnki.net

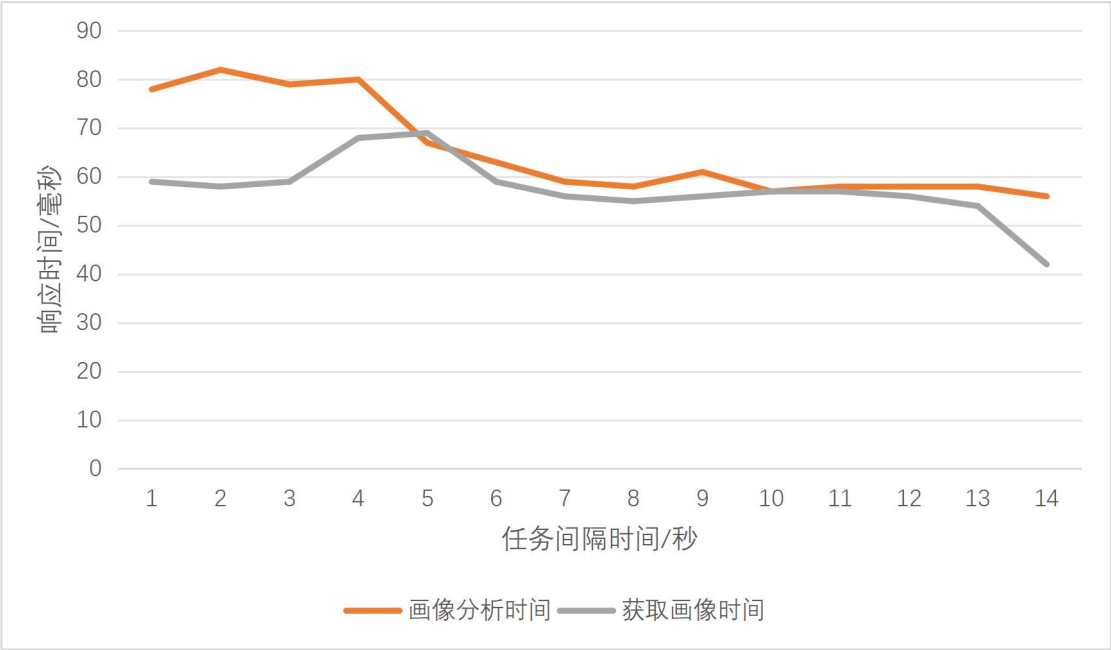

图 5-3 用户画像数据查询性能分析折线图

资源利用率测试也是性能测试中的必要环节，它旨在评估和监控系统在运行过程中各项硬件和软件资源的使用情况，如 CPU、内存、磁盘 I/O 等。通过对资源利用率的测试可以确保系统在不同负载下高效地使用资源，避免资源浪费或资源不足的情况，从而提升系统的整体性和稳定性。资源利用率测试用例如表 5-9 资源利用率测试用例表所示。

表 5-9 资源利用率测试用例表

用例编号	测试步骤	预期结果	是否一致
1	运行用户画像构建模块	CPU 的使用率低于 80%，内存使用率低于 70%，均保持在合理范围	是
2	监控 CPU 和内存的使用情况		是

5.4 稳定性测试

在大数据时代下，大数据平台的稳定性对企业的发展至关重要，稳定性指标是评估大数据平台运行和性能的关键指标。稳定性测试是通过给系统加载一定的业务压力来检测系统是否能够长时间稳定运行，这是确保系统长期稳定运行的关键步骤。通过稳定性测试可以确保系统能够持续提供高可用性服务，及时发现和修复内存泄漏、性能瓶颈以及资源过度消耗等重大缺陷，充分验证系统在长时间运行过程中的稳定性。充分保障平台的可靠性、扩展性以及在关键时刻的表现。

大数据平台往往需要运行很长时间之后，在平台用户数据积累到一定程度之后，如：内存泄漏、组件崩溃等严重系统问题才会充分暴露出，短时间的运行测

中国知网 https://www.cnki.net

试根本无法充分模拟实际的工作生产环境，也无法充分测试出内存泄漏、组件崩溃等严重系统问题。因此为了更好的测试系统的稳定性，让潜在的严重系统问题充分暴露出来，本次稳定性测试以自动化测试的方式，通过执行自动化测试脚本来持续进行 7 天不间断的运行测试来验证系统在长时间运行下的稳定性。系统稳定性测试用例如表 5-10 稳定性测试用例表所示。

表 5-10 稳定性测试用例表

用例编号	测试步骤	预期结果	是否一致
1	进入 TestComplete 自动化测试工具	系统持续不间断	是
2	编写测试脚本，并设置脚本运行的时间为 7 天	稳定运行 7 天，在运行的 7 天内无	是
3	运行自动化测试脚本	崩溃或者其他重	是
4	开启系统监控工具	大异常情况	是

5.5 测试结果分析

本章节主要从功能性、性能以及稳定性三方面对用户画像系统进行了全面且充分的测试，并根据功能需求针对性地设计了多条测试用例，以上的测试用例全面覆盖了系统的核心功能和指标。以测试用例执行驱动系统测试流程的方式大幅提高了测试的全面性和系统性，充分保障了系统的可靠性和可用性，确保了软件系统在各个阶段都能满足预期的质量要求。经过以上充分的测试可以知道此系统登录验证功能、用户标签生成、用户分群以及画像存储等功能模块在功能性、性能以及稳定性方面均达到了预期的目标，此次测试结果分析情况如表 5-11 系统测试结果分析表所示。

表 5-11 系统测试结果分析表

功能测试	系统各模块功能正常，能够准确处理和分析用户数据
性能测试	系统在大规模数据是表现出色，数据处理速度快，系统响应时间十分迅速，达毫秒级，资源利用率也十分合理，其中 CPU 的使用率低于 80%，内存使用率低于 70%
稳定性测试	系统运行稳定运行 24 小时，无崩溃和重大异常

5.6 本章小结

在本章节主要对基于 Spark 电商平台的用户画像系统的全部核心功能、系统性能以及稳定性在内的多个方面进行了十分全面且充分的测试，充分保障了整个用户画像系统质量的稳定可靠以及用户画像数据处理的响应速度。

中国知网 https://www.cnki.net

第 6 章 总结与展望

6.1 总结

用户画像技术立足于科技发展前沿的实际情况，充分结合当前电商行业在大数据背景下的精准营销与用户洞察需求，针对传统的信息管理系统在超大规模应用场景下处理能力不足的致命弊端，围绕 Spark 的用户画像平台构建进行了深入的研究与实践，探讨了应用 Spark 的分布式计算能力、流处理技术以及机器学习架构来构建和优化高效、精准的用户画像平台，并基于研究所得成果成功设计并实现了一个高效、可扩展的用户画像系统。本文的主要研究内容如下：

（1）针对传统电商管理平台在对大量商品分类检索的效率低下以及准确性不高的问题，本文提出了一种基于 Vision Transformer 模型的多类商品分类识别方法，该方法将图像视为一系列大小固定的图像块并为其添加相应的编码信息，借助多头自注意力机制和前馈神经网络处理能够更好的捕捉嵌入图像块的长距离依赖关系，根据之前的分类标记进行商品视觉特征图像分类任务。实验结果表明，基于 Vision Transformer 模型的多种商品分类识别方法在大规模商品分类处理任务中展现出了极强的优越性，交传统的电商平台在商品识别效率和准确性上有了大幅度的提升，商品整体分类识别准确率能够达到 97%以上。

（2）针对电商平台用户画像的精准刻画的需求，本文提出了一种基于 RFM 模型的用户画像模型构建方法。RFM 模型是从客户最近购买时间、购买评率以及购买金额这三个维度对客户进行画像精准刻画，科学地将用户分为不同价值的客户群体，帮助电商平台更好地进行个性化的精准营销。RFM 画像构建模型结合经典的 K-Means 聚类算法可以对用户群体进行更为精准的分群预测，通过对用户群体进行聚类分析可以构建出一个更加精准的的用户画像平台，从而帮助企业将客户精确地划分为不同的群体，显著提高客户的生命周期价值和企业的整体效益水平。

（3）针对传统电商平台在高并发、高负载环境下系统数据实时响应处理能力严重不足的弊端，本文研究设计了一种基于 Spark 的电商用户画像平台。在 Spark 分布式计算框架强大分布式计算能力的加持下，显著电商平台对海量用户数据的处理和分析能力，并通过 Spark Streaming 构建出高效的海量商品交易数据以及用户行为数据实时处理管道，通过融合用户静态信息与动态行为数据，显著提升了用户模型的完整性和时效性，充分弥补了传统电商平台在数据实时处理和分析上的不足，显著提升了电商平台对海量用户数据处理的效率。MLlib 算法库提供的机器学习算法还可以对用户偏好和行为模式进行更深层次的特征提取

中国知网 https://www.cnki.net

与选择，大幅度提升电商平台用户画像的质量。

虽然基于 Spark 电商平台用户画像系统在大规模数据处理、实时更新和扩展性方面具有显著优势，但随着用户数据规模和复杂性的不断增加，当前系统也还存在着一些不足的地方和进一步改进的空间。例如，在面对更加复杂的数据特征挖掘需求时，用户画像系统还需要进一步优化算法性能。与此同时，用户画像系统在对于异构数据的处理和跨域数据的整合能力仍需加强，还需不断丰富用户画像的信息维度来提高用户画像的实时性、全面性和准确性。除此之外，用户画像系统在高并发场景下的实时处理能力可能会存在较大的性能瓶颈，仍需要结合流计算框架来不断进行优化处理以达到尽可能好的效果。并且随着人工智能技术的不断发展，充分结合深度学习、强化学习等先进算法进一步提升用户画像的智能化和个性化也成为未来用户画像领域应用与研究的趋势。在科学技术日新月异的今天，用户画像在未来也注定将会在实际生产和工作环境中不断地发挥出更大的应用价值。

6.2 展望

虽然本文在对用户画像的应用研究已经取得了一定的成果，但是就现阶段的这点成果这还远远不够，仍需不断地进行科学探索，探索在数据量爆炸式增长和用户行为日趋复杂这一趋势下系统性能瓶颈的突破，推动用户画像领域的应用与研究在数据处理的效率、个性化服务、用户体验等方面的持续优化并在更多行业中得到更为广泛的应用。本文在对用户画像技术的研究和应用学习过程中的一些心得作了一定总结，未来市场对于用户画像技术的应用也将会越来越广泛和流行，并且将会在如下的两个方面进行进一步的拓展延伸：

（1）随着用户行为的日趋复杂和多样化，与深度学习算法更紧密的结合来进一步提高用户画像的智能化程度，探索出 Spark 与 TensorFlow、PyTorch 等当前最火热的深度学习框架强强结合的契合点，对用户的行为进行更深层次的挖掘，从而开发出更加智能的特征挖掘和画像生成算法来更加精准地预测用户的行为和需求。

（2）当前的用户画像技术在针对多源异构数据的整合与分析还有待提高，还需进一步探索出更加灵活的适配和协同计算方案，推动跨域数据的深度融合，为用户画像的精确化生成提供更加全面的数据支撑。

综上所述，基于 Spark 的用户画像系统将更好地服务于个性化推荐、精准营销以及智慧决策等应用场景，具有十分广阔的发展前景。在技术更迭令人目不暇接的当下，用户画像技术也将在越来越多的领域中大展拳脚，为企业的数字化转型和智能化运营提供有力的技术支撑。

中国知网 https://www.cnki.net

参考文献

[1] 衣洋, 刘登科.我国电子商务发展的现状及未来趋势研究[J].电脑知识与技术, 2020, 16(25): 236-237+240.

[2] 蔡正焱.电子商务中的数据挖掘及其应用[J].互联网周刊, 2023, (07):68-70.

[3] 田娟, 朱定局, 杨文翰.基于大数据平台的企业画像研究综述[J]. 计算机科学, 2018, 45(S2): 58-62.

[4] 屈娟娟.人工智能及大数据技术在数字营销中的应用[J].商业经济研究, 2020, (10):78-80.

[5] 鄢慧丽, 余军, 熊浩.移动旅游应用用户粘性影响因素研究——以网络舆论为调节变量[J]. 南开管理评论, 2020, 23(01):18-27.

[6] 王振东.冯·诺依曼，计算机和力学[J].力学与实践, 2023, 45(04):944-947.

[7] Cooper A. Why high-tech products drive us crazy and how to restore the sanity[M]. S ams Publishing, 2004.

[8] AlanCooper.软件创新之路:冲破高技术营造的牢笼[M].电子工业出版社, 2001.

[9] Zerkouk M, Mhamed A, Messabih B. A user profile based access control model and a rchitecture[J]. arXiv preprint arXiv:1302.1667, 2013.

[10] Ying R, He R, Chen K, et al. Graph convolutional neural networks for web-scale rec ommender systems[C]//Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining. 2018: 974-983.

[11] Ruotsalo T, Mäkelä K, Spapé M M, et al. Feeling positive? predicting emotional ima ge similarity from brain signals[C]//Proceedings of the 31st ACM International Conference on Multimedia. 2023: 5870-5878.

[12] Javari A. User profiling in social networks based on graph data: bridging local and g lobal structures[D]. University of Illinois at Urbana-Champaign, 2021.

[13] Chen L, Zhang J, Peng W. Research on the hierarchical discrete time-cost trade-off pr oblem for program[J]. Journal of Construction Engineering and Management, 2022, 148(7): 422-429.

[14] Yoo H, Zeng Z, Kang J, et al. Ensuring user-side fairness in dynamic recommender s ystems[C]//Proceedings of the ACM Web Conference 2024. 2024: 3667-3678.

[15] 王智囊. 基于用户画像的医疗信息精准推荐的研究[D].电子科技大学, 2016.

[16] 郭光明.基于社交大数据的用户信用画像方法研究[D].中国科学技术大学, 2017.

[17] 吴剑云, 胥明珠.基于用户画像和视频兴趣标签的个性化推荐[J].情报科学, 2021, 39(01):1 28-134.

中国知网 https://www.cnki.net

[18] 吴树芳, 吴崇崇, 朱杰.基于兴趣转移的微博用户动态画像生成[J].情报科学, 2021, 39(08): 103-111.

[19] 袁苗苗, 侯瑞春, 陶冶, 等.基于多数据源融合的用户画像构建方法[J].计算机与数字工程, 2022, 50(04):757-761.

[20] 杨钰.基于个人知识图谱的个性化推荐系统设计与实现[D].东南大学, 2023.

[21] 周峰.基于改进 Bi-Kmeans 聚类算法的人才画像系统的研究与实现[D].南昌大学, 2024.

[22] 刘加新. 数据驱动的用户画像构建研究与系统设计[D].湖南大学, 2020.

[23] 马超.基于主题模型的社交网络用户画像分析方法[D].中国科学技术大学, 2017.

[24] 肖静华, 胡杨颂, 吴瑶.成长品：数据驱动的企业与用户互动创新案例研究[J].管理世界, 2020, 36(03):183-205.

[25] 顾亦然, 郭玉雯.学术资源推荐服务中多维度用户画像构建[J].软件导刊, 2021, 20(04)：101-105.

[26] 黄秀. 基于多模态社交媒体数据源的用户画像构建的研究[D].电子科技大学, 2018.

[27] 刘勇, 吴翔宇, 解本巨.基于动态用户画像的信息推荐研究[J]. 计算机系统应用, 2018, 27(06):236-239.

[28] 阎馨, 吴书文, 屠乃威, 等.基于逻辑回归和增强学习的煤与瓦斯突出预测[J].控制工程, 2021, 28(10):1983-1988.

[29] 周林兴, 魏亮亮, 艾文华.用户画像视角下档案馆知识服务推荐机理研究[J].档案管理, 2019, (05):8-12.

[30] 王彦明, 奉国和, 薛云.近年来 Hadoop 国外研究综述[J].计算机系统应用, 2013, 22(06):1-5+28.

[31] 夏靖波, 韦泽鲲, 付凯, 等.云计算中 Hadoop 技术研究与应用综述[J].计算机科学, 2016, 43(11)：6-11+48.

[32] 刘军, 冷芳玲, 李世奇, 等.基于 HDFS 的分布式文件系统[J].东北大学学报（自然科学版）, 2019, 40(06):795-800.

[33] 宋杰, 孙宗哲, 毛克明, 等.MapReduce 大数据处理平台与算法研究进展[J].软件学报, 2017, 28(03):514-543.

[34] 董春涛, 李文婷, 沈晴霓, 等.Hadoop YARN 大数据计算框架及其资源调度机制研究[J].信息通信技术, 2015, 9(01):77-84.

[35] 周江, 王伟平, 孟丹, 等.面向大数据分析的分布式文件系统关键技术[J]. 计算机研究与发展, 2014, 51(02):382-394.

[36] 邓鹏, 李枚毅, 何诚.Namenode 单点故障解决方案研究[J].计算机工程, 2012, 38(21):40-44.

[37] Vavilapalli V K, Murthy A C, Douglas C, et al. Apache hadoop yarn: Yet another res

中国知网 https://www.cnki.net

ource negotiator[C]//Proceedings of the 4th annual Symposium on Cloud Computing. 2013: 1-16.

[38] Salloum S, Dautov R, Chen X, et al. Big data analytics on Apache Spark[J]. International Journal of Data Science and Analytics, 2016, 1(3): 145-164.

[39] Zaharia M, Chowdhury M, Das T, et al. Resilient distributed datasets: A {Fault-Tolerant} abstraction for {In-Memory} cluster computing[C]//9th USENIX symposium on networked systems design and implementation (NSDI 12). 2012: 15-28.

[40] Chellappan S, Ganesan D, Chellappan S, et al. Introduction to apache spark and spark core[J]. Practical Apache Spark: Using the Scala API, 2018: 79-113.

[41] Armbrust M, Xin R S, Lian C, et al. Spark sql: Relational data processing in spark[C]//Proceedings of the 2015 ACM SIGMOD international conference on management of data. 2015: 1383-1394.

[42] Armbrust M, Das T, Torres J, et al. Structured streaming: A declarative api for real-time applications in apache spark[C]//Proceedings of the 2018 International Conference on Management of Data. 2018: 601-613.

[43] Kalita L. Socket programming[J]. International Journal of Computer Science and Information Technologies, 2014, 5(3): 4802-4807.

[44] Garg N. Apache kafka[M]. Birmingham, UK: Packt Publishing, 2013.

[45] Sultana S, Midi D, Bertino E. Kinesis: a security incident response and prevention system for wireless sensor networks[C]//Proceedings of the 12th ACM Conference on Embedded Network Sensor Systems. 2014: 148-162.

[46] Meng X, Bradley J, Yavuz B, et al. Mllib: Machine learning in apache spark[J]. Journal of Machine Learning Research, 2016, 17(34): 1-7.

[47] Xin R S, Gonzalez J E, Franklin M J, et al. Graphx: A resilient distributed graph system on spark[C]//First international workshop on graph data management experiences and systems. 2013: 1-6.

[48] Venkataraman S, Yang Z, Liu D, et al. Sparkr: Scaling r programs with spark[C]//Proceedings of the 2016 international conference on management of data. 2016: 1099-1104.

[49] 王坚, EB 级大数据计算平台-MaxCompute2.0.浙江省, 阿里云计算有限公司, 2014-12-23.

[50] 罗巍, 刘功总.基于大数据的数据仓库研究现状[J].中国新技术新产品, 2020, (17):38-39.

[51] 阎逸飞, 王智立, 邱雪松, 等.Spark 环境下基于数据倾斜模型的 Shuffle 分区优化方案[J].北京邮电大学学报, 2020, 43(02):116-121.

[52] 杨乾龙, 江凌云.基于机器学习的微服务负载均衡算法研究[J].计算机科学, 2023, 50(05):313-321.

中国知网 https://www.cnki.net

[53] Dosovitskiy A. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.

[54] Han K, Xiao A, Wu E, et al. Transformer in transformer[J]. Advances in neural information processing systems, 2021, 34: 15908-15919.

[55] 任欢, 王旭光.注意力机制综述[J].计算机应用, 2021, 41(S1):1-6.

[56] 周刚刚, 芮艳杰, 马福平, 等.基于前馈神经网络预测猪肉价格的研究[J].中国畜牧杂志, 2023, 59(11):311-316.

[57] 杨琳, 寇勇刚, 白钊, 等.基于改进 RFM 模型对民航客户的细分研究[J].数学的实践与认识, 2021, 51(01):33-39.

[58] 杨俊闯, 赵超.K-Means 聚类算法研究综述[J].计算机工程与应用, 2019, 55(23):7-14+63.

[59] 郭永坤, 章新友, 刘莉萍, 等.优化初始聚类中心的 K-means 聚类算法[J].计算机工程与应用, 2020, 56(15):172-178.

中国知网 https://www.cnki.net